

Agent-based robot 论文分享

一

agent-based robot 定义与定位

二

Manipulate-Anything (UW) 论文分享

三

NovaPlan (CMU) 论文分享

四

本人项目进展与讨论



agent-based robot 定义与定位

“Agent-Based” 的内涵与研究动机

什么是 Agent-Based Robot

以智能体为决策核心、以机器人为物理执行载体的具身系统。



为什么要做 Agent-Based Robot

利用现有大语言模型能力，以期打造具有自进化能力的具身智能体。

一句话总结：

Agent-Based Robot 指无需任何训练，
合理使用分割模型、Grasp 模型、规划模型、视频生成模型等
实现真实世界 zero-shot 的机器人方案。



manipulate-anything (UW) 论文分享

Manipulate-Anything: Automating Real-World Robots using Vision-Language Models



Jiafei Duan^{1*} Wentao Yuan^{1*} Wilbert Pumacay² Yi Ru Wang¹

Kiana Ehsani³ Dieter Fox^{1,4} Ranjay Krishna^{1,3}

¹University of Washington ²Universidad Católica San Pablo

³Allen Institute for Artificial Intelligence ⁴NVIDIA

01

动机 Zero-Shot 完成未知任务

02

方法 VLM 驱动的规划、动作生成与验证

03

实验 14 个仿真任务 & 7 个真实任务验证

Paper: <https://arxiv.org/abs/2406.18915>

Code: <https://github.com/Robot-MA/manipulate-anything>

01

动 机

01 基本背景



北京大学
PEKING UNIVERSITY

Manipulate-Anything Automating Real-World Robots using Vision-Language Models

CoRL 2024

arXiv: 2024.06.27

单位: University of Washington / AI2 / NVIDIA



W
UNIVERSITY of
WASHINGTON



Google Scholar

截至 2026.4.28

引用 116 次

Scholar

Manipulate-anything: Automating real-world robots using vision-language models

J Duan, W Yuan, W Pumacay, YR Wang... - arXiv preprint arXiv ..., 2024 - arxiv.org

Large-scale endeavors like and widespread community efforts such as Open-X-Embodiment have contributed to growing the scale of robot demonstration data. However, there is still an opportunity to improve the quality, quantity, and diversity of robot demonstration data.

Although vision-language models have been shown to automatically generate demonstration data, their utility has been limited to environments with privileged state information, they require hand-designed skills, and are limited to interactions with few object ...

☆ Save 剪 Cite Cited by 116 Related articles All 6 versions 》

GitHub

截至 2026.4.28

Star 55

Fork 4 Star 55

About



Robot-MA / manipulate-anything

Manipulate-Anything: Automating
Real-World Robots using Vision-
Language Models [CoRL 2024]

robot-ma.github.io/

基于示范数据的策略训练 VLA / BC

代表工作：RT-1、Open-X-Embodiment

核心思路：大规模收集机器人示范数据，再训练通用操作策略

问题：人工采集成本高，面对新任务/新物体仍然依赖更多数据

在受限场景中的 Zero-Shot

代表工作：Code-as-Policies、Scaling-up、VoxPoser

核心思路：用 LLM/VLM 在仿真中规划、生成代码或预测 WayPoint

问题：常依赖 privileged state、手工脚本或仿真环境信息

privileged state 特权状态：

即仿真中可直接读取、但真实机器人无法直接获得的物体真值状态，如精确位姿、分割、接触状态等

在真实世界中的Zero-Shot

代表工作：Manipulate-Anything（本文）

核心目标：

不依赖 privileged state 与任务特定训练，在真实环境中完成未知任务

关键要求：

从真实世界视觉观测中完成任务理解、动作生成、结果验证与失败恢复

从受限 Zero-Shot 到真实世界 Zero-Shot

关键要求	Code-as-Policies	VoxPoser	Scaling-up	Manipulate-Anything (本文)
无需特权状态信息 (环境不可知)	×	×	×	☑
无需手工设计底层技能	×	×	×	☑
开放词汇与任意物体操作	×	☑	☑	☑
闭环验证与失败恢复	×	×	×	☑

现有的方法严重依赖仿真特权信息与预设几何形状，且缺乏纠错能力。

02

方 法

02 方法：从任务目标推导系统需求

目标：真实世界 Zero-Shot 操作

给定自然语言任务与 RGB-D 观测，机器人需要在未针对该任务训练的情况下完成操作。


输入：自然语言指令 + RGB-D 观测

输出：机器人可执行动作序列 / 6-DoF 末端位姿



真实世界问题

任务语义抽象
视角遮挡与歧义
物体位姿未知
执行结果不确定




系统能力需求

任务规划生成
多视角状态感知
动作生成与落地
结果验证与恢复

MA 将真实世界 Zero-Shot 操作拆解为：Plan → See → Act → Verify → Retry

02 方法：主要框架与核心价值

MA主要框架：



MA核心价值：

环境无关：摆脱仿真特权状态

不依赖 privileged state，以真实视觉观测驱动任务执行。

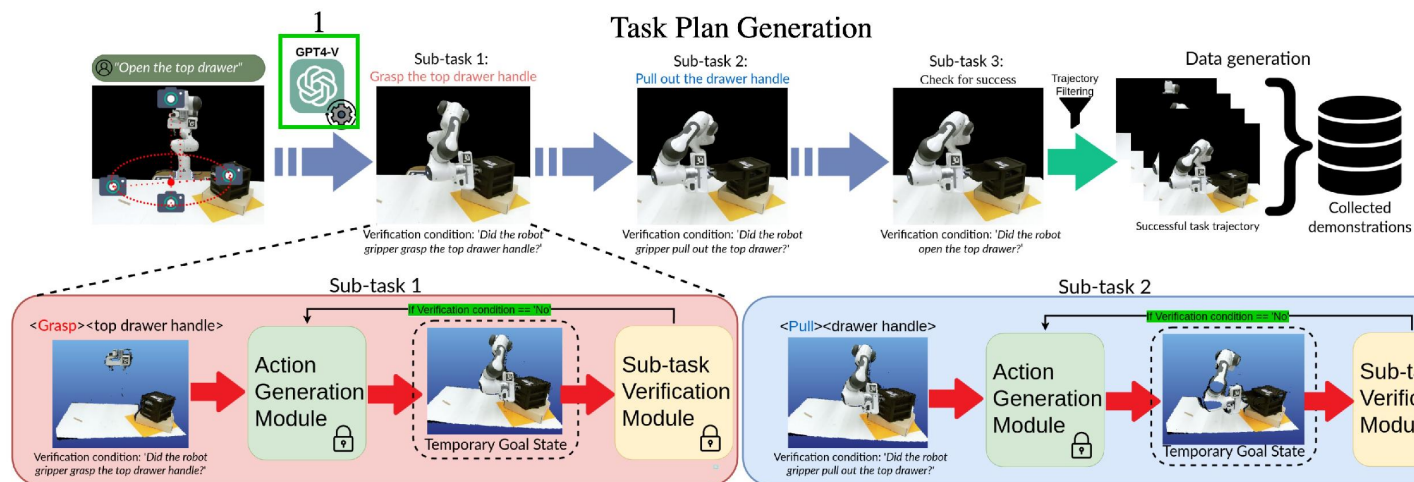
开放操作：面向多样静态物体

不局限于固定物体实例，通过语义理解与抓取候选筛选实现开放物体操作。


闭环恢复：执行后验证并重试

每个子任务执行后由 VLM 验证结果，失败则重新生成动作并恢复。




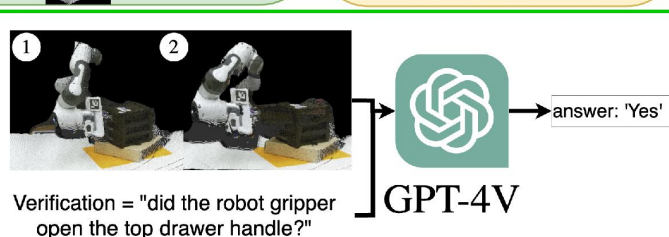


Task Plan Generation



Action Generation Module



Sub-task Verification



02 方法: Task Plan Generation

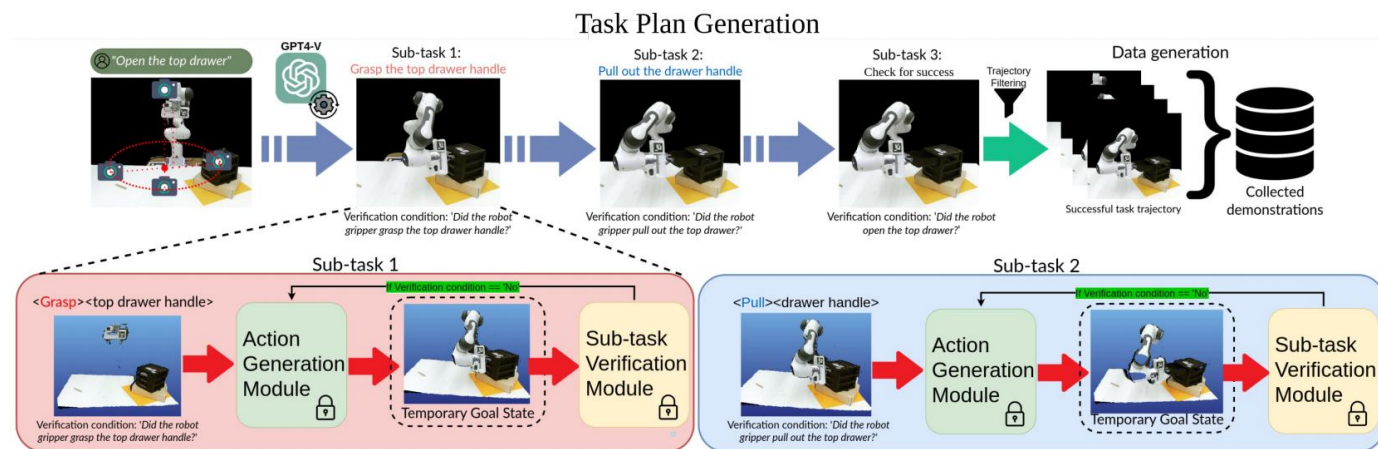
从开放语言任务到可验证子任务序列

$$T \rightarrow \{(T_1, v_1), (T_2, v_2), \dots, (T_n, v_n)\}$$


自然语言
指令

子任务1

验证条件1



自然语言指令 T
+ 场景图像



Task Plan Generation

01
VLM从场景中
找到与任务相
关的对象，作
为环境信息记
录

02
LLM利用环境
信息将任务拆
分为若干子任
务 T_i

03
LLM对每个子
任务生成验证
条件 v_i ，用于
后续检查


GPT-4V

GPT-4V

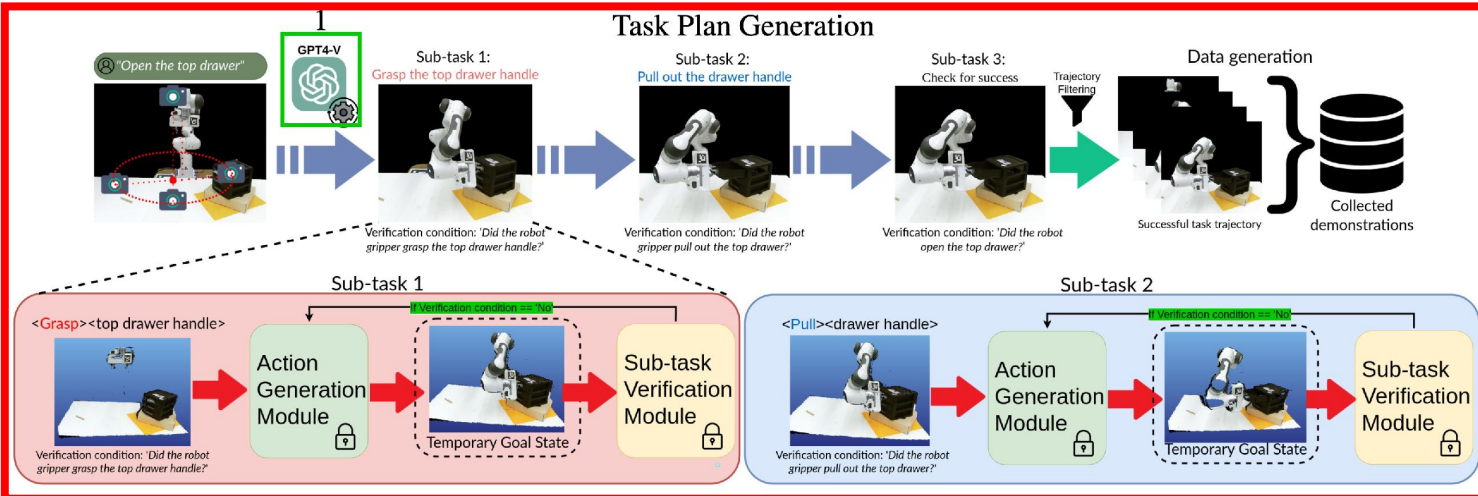
GPT-4V

子动作 子验证


$\{(T_1, v_1), (T_2, v_2), \dots, (T_n, v_n)\}$




Task Plan Generation





Action Generation Module



Sub-task Verification



4




Verification = "did the robot gripper open the top drawer handle?"



answer: 'Yes'

1




task-plan-generation.txt



```
{'primitive_actions': ['pick', 'retract', 'success'], 'Objects': ['top drawer handle', 'None', 'None'], 'pick': [[0, 0, 0, 0], [0, 0, 0, 0], [0, 0, 0, 0], [0, 0, 0, 0]], 'place': [0, 0, 0, 0], 'predict': 1, 'verification': ['did robot gripper grasp onto the top drawer handle?', 'did the robot gripper open the top drawer handle?', 'did the robot gripper open the drawer?'], 'viewpoints': [0, 1], 'SoM': ''}
```

task-plan.txt


2



QWen-VL




Qwen-VL



Target_obj = 'top drawer handle'

 '框出图中只有一个'+
english_to_chinese(Target_obj) +'的位置'

3



multi-viewpoint-selection.txt


 viewpoints: [3]
appended task-plan.txt

02 方法: Multi-viewpoint Selection




北京大学
PEKING UNIVERSITY

从“单视角观察”到“任务条件下的最佳视角选择”

单视角问题: 物体遮挡 & 目标部位不可见 & 验证状态不可靠

→ 真实机器人不能假设总能从一个角度看清任务关键区域


输入




多视角相机视图

Multi-viewpoint Selection

视角 1




视角 2



视角 3



视角 4



拼接为一个帧
(带标注编号)

VLM


GPT-4V

VLM选择理想视角

输出

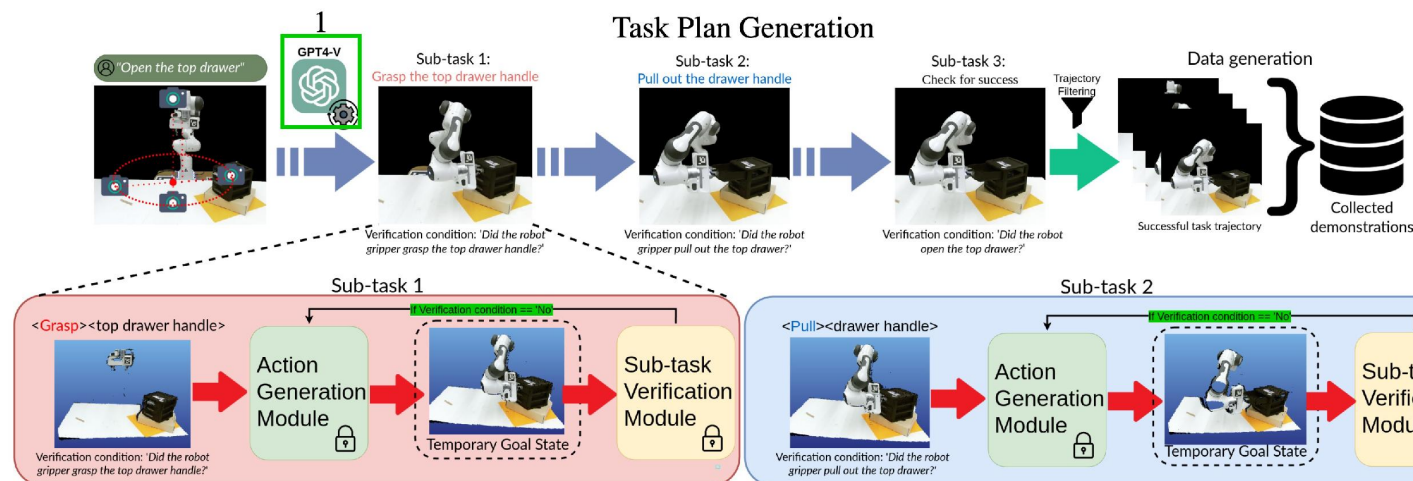
进行动作生成与验证
使用最佳视角(视角3)

从子任务目标到可执行 6-DoF 位姿 / Action Code




★：在此处使用 Multi-viewpoint Selection 模块选择了视角


Task Plan Generation



Action Generation Module



Sub-task Verification




4

action-generation.txt



```
def pull(self, distance=0.15):
    if self.current_pose.is_name:
        print("No previous pose to pull from.")
        return
    # Create a new posestamped message
    action = PoseStamped()
    action.header.frame_id = self.base_frame
    action.pose = self.current_pose #Set pose to current pose
    pull_dir = -np.cross(np.array([1, 0, 0]), self.current_pose.orientation)
    # Adjust x, y, and z coordinate
    action.pose.position.x += x
    action.pose.position.y += y
    action.pose.position.z += z
    # Publish action
    self.execute(action)
```




Verification = "did the robot gripper open the top drawer handle?"



answer: 'Yes'

1




task-plan-generation.txt



```
{'primitive_actions': ['pick', 'retract', 'success'], 'Objects': ['top drawer handle', 'None', 'None'], 'pick': [[0, 0, 0, 0], [0, 0, 0, 0], [0, 0, 0, 0], [0, 0, 0, 0]], 'place': [0, 0, 0, 0], 'predict': 1, 'verification': ['did robot gripper grasp onto the top drawer handle?', 'did the robot gripper open the top drawer handle?', 'did the robot gripper open the drawer?'], 'viewpoints': [0, 1], 'SoM': ''}
```

task-plan.txt


2



Qwen-VL




Qwen-VL



Target_obj = 'top drawer handle'
'框出图中只有一个'+
english_to_chinese(Target_obj) +'的位置'

[400,530,456,555]

3



multi-viewpoint-selection.txt




viewpoints: [3]
appended task-plan.txt

02 方法: Sub-task Verification & Error Recovery

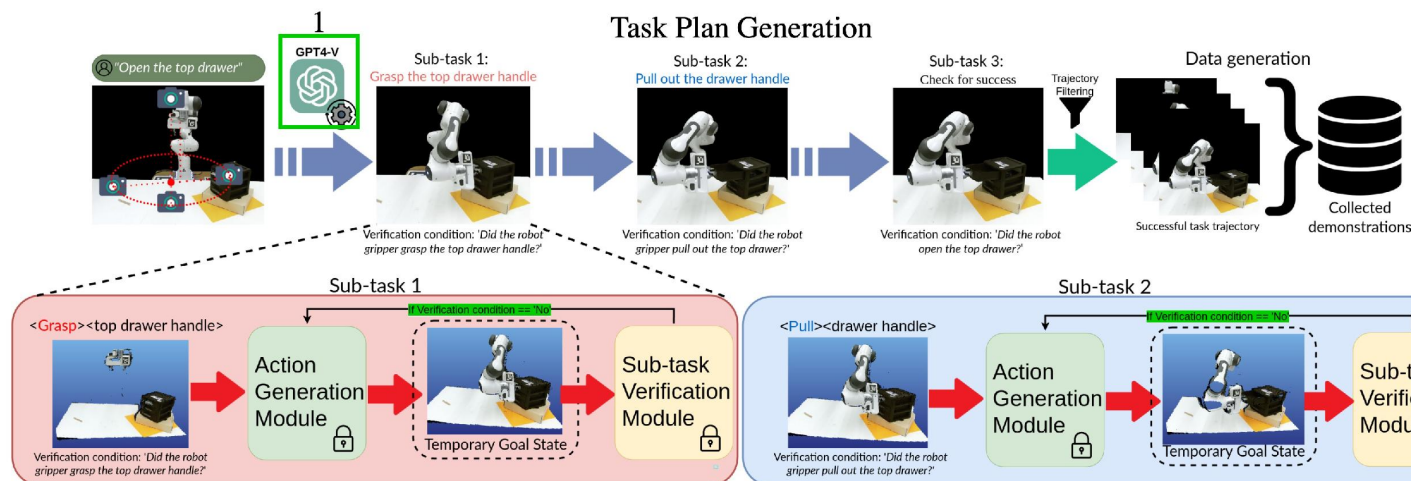


北京大学
PEKING UNIVERSITY


基于多视角状态对比的子任务验证与失败恢复








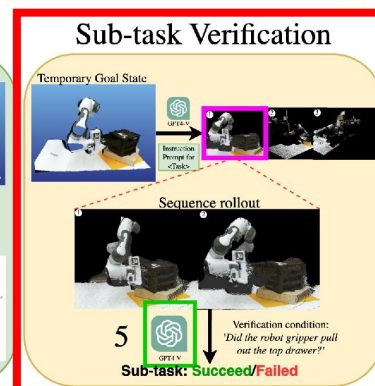
Task Plan Generation



Action Generation Module



Sub-task Verification



03

实 验

03 实验：概览



北京大学
PEKING UNIVERSITY

验证 MA 是否既能**完成未知任务**，又能**产生可训练的机器人示范数据**

Q1: Zero-Shot 能不能做？

在未针对任务训练的情况下，MA 能否完成未知操作任务？

Q2: 生成数据有没有用？

MA 自动生成的 demonstrations 能否训练出有效 BC 策略？

Q3: 真实世界是否成立？

从仿真到真实机器人，系统是否仍然可用？

01

仿真 Zero-Shot

14 个 RLBench 任务
对比 VoxPoser / CAP /
Scaling-up

02

数据生成与 BC 训练

用 MA 生成 demonstrations
训练 PerAct / RVT-2

03

真实世界验证


7 个真实机器人任务
验证真实环境中的可行性

04

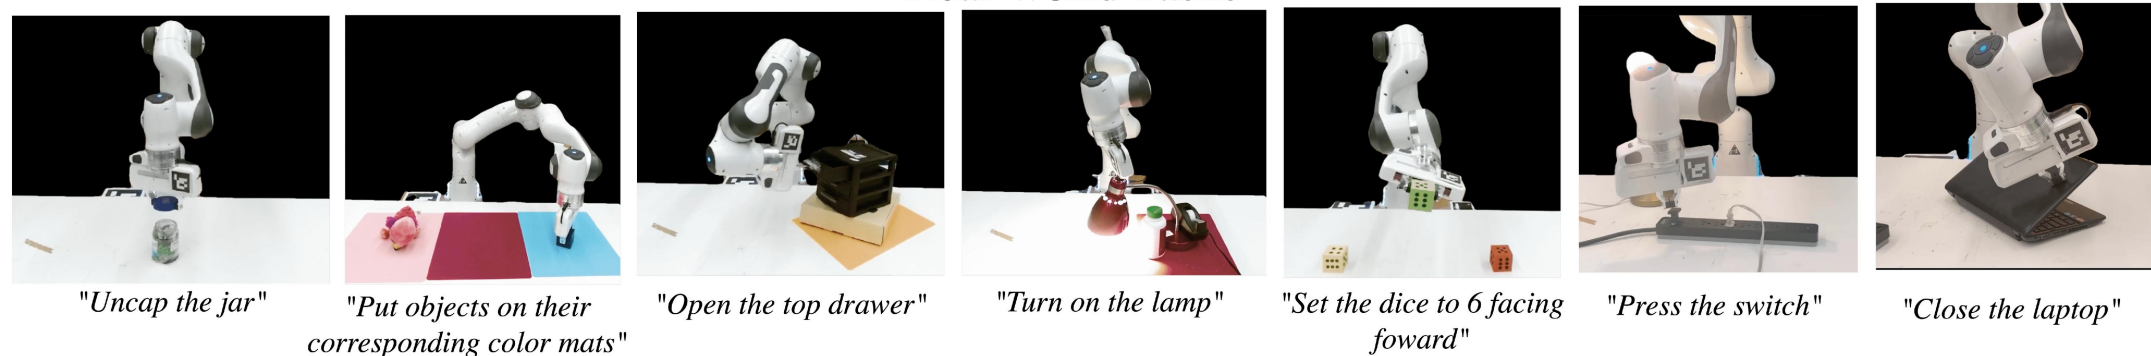
消融与误差分析

多视角选择 / VLM 决策误差

Simulation Benchmark



Real-world Tasks



03 实验：仿真 Zero-Shot

验证 MA 是否能在无任务特定训练下生成成功轨迹

仿真zero-shot实验结果表

仿真平台：
CoppeliaSim + PyRep

仿真模型：
Franka Panda + 平行夹爪

输入观测：
桌面周围 4 路
RGB-D 摄像头

任务来源：
RLBench 语言条件任务

Method	Put_block	Play_jenga	Open_jar	Close_box	Open_box	Pickup_cup	Push_block
VoxPoser [3]	70.70±2.31	0.00±0.00	0.00±0.00	0.00±0.00	0.00±0.00	26.70±14.00	25.33±8.33
CAP [5]	84.00±16.00	0.00±0.00	0.00±0.00	0.00±0.00	0.00±0.00	14.67±4.62	8.00±4.00
Scaling-up [4]	77.33±6.11	0.00±0.00	78.67±11.55	0.00±0.00	0.00±0.00	9.33±2.26	5.33±6.11
MA (Ours)	96.00±4.00	77.33±6.11	80.00±4.00	33.33±12.86	29.00±10.07	82.67±14.04	20.00±4.00

Method	Take_umbrella	Sort_mustard	Open_wine	Lamp_on	Put_knife	Pick_&_lift	Insert_block
VoxPoser[3]	33.33±8.33	96.00±6.93	8.00±4.00	57.30±12.22	92.00±4.00	96.00±0.00	0.00±0.00
CAP[5]	4.00±4.00	0.00±0.00	0.00±0.00	64.00±6.93	14.67±8.33	100.00±0.00	0.00±0.00
Scaling-up [4]	6.67±2.31	41.33±12.86	33.33±20.13	60.00±8.00	24.00±0.00	100.00±0.00	0.00±0.00
MA (Ours)	61.33±20.13	64.00±6.93	42.00±4.00	69.33±6.11	52.00±10.58	84.00±6.93	33.33±4.62

MA 能为全部 14 个任务生成成功轨迹，而 Scaling-up、VoxPoser、CAP 分别只覆盖 10、9、7 个任务；
MA 在 14 个任务中的 10 个任务上超过基线，并相较最强基线 VoxPoser 取得最高 22% 的平均任务优势。

03 实验：数据生成与 BC 训练

仿真BC实验结果表 (10 demo)

验证 MA 能产生可用于训练的机器人示范数据

数据生成：
每个任务生成 10 条成功 demonstrations
(验证少量自动生成成功轨迹是否具备训练价值)

训练模型：
PerAct & RVT-2 (当时 RL Bench 基准测试中性能最高的模型)

核心结果：
MA 生成数据训练的策略在 10/12 个任务上优于其他自动生成数据；此处 RL Bench 的数据是人为收集的，被认为是行为克隆的上限。

对表中成功率进行统计学检验
MA 与人工数据的 $p=0.973$ ，平均差异 0.27%
MA 与 Scaling-up、VoxPoser、CAP 的 $p<0.01$

Data	Models	Put_block	Play_jenga	Open_jar	Close_box	Open_box	Pickup_cup
VoxPoser[3]	PerAct[34]	2.67±2.31	-	-	-	-	4.00±4.00
CAP[5]	PerAct[34]	6.67±2.31	-	-	-	-	14.67±12.86
Scaling-up [4]	PerAct[34]	22.67±15.14	-	5.33±6.11	-	-	14.67±2.31
MA (Ours)	PerAct[34]	85.33 ±10.07	81.33±2.31	21.33±10.07	42.67±8.33	30.67 ±11.55	54.00±12.49
RLBench[33]	PerAct[34]	20.00±18.33	81.33 ±9.24	58.67 ±45.49	68.00 ±24.98	14.67±6.11	54.67 ±23.09
VoxPoser[3]	RVT-2[59]	73.33±2.31	-	-	-	-	2.67±2.31
CAP[5]	RVT-2[59]	78.66±8.32	-	-	-	-	77.33±19.73
Scaling-up [4]	RVT-2[59]	38.67±2.31	-	33.33±2.31	-	-	92.00±4.00
MA (Ours)	RVT-2[59]	85.33±2.31	82.67±2.31	78.67±10.06	82.67 ±2.31	24.00 ±4.00	97.33±2.31
RLBench[33]	RVT-2[59]	86.67 ±2.31	85.33 ±2.31	81.33 ±6.11	76.00±4.00	4.00±4.00	97.33 ±2.31

Data	Models	Take_umbrella	Sort_mustard	Open_wine	Lamp_on	Put_knife	Pick_&_lift
VoxPoser[3]	PerAct[34]	4.00±4.00	0.00±0.00	1.33±2.31	5.33±4.62	1.33±2.31	5.67±1.64
CAP[5]	PerAct[34]	13.33±10.06	-	-	8.00±16.00	9.33±6.11	46.67±2.31
Scaling-up [4]	PerAct[34]	4.00±4.00	0.00±0.00	81.33±12.86	76.00±4.00	5.33±2.31	53.33±10.06
MA (Ours)	PerAct[34]	84.00 ±6.93	53.33±6.11	86.67±6.11	89.33 ±6.11	8.00±4.00	33.33±2.31
RLBench[33]	PerAct[34]	58.67±50.80	53.33 ±34.02	86.67 ±12.86	84.00±13.86	30.67 ±10.07	62.67 ±9.24
VoxPoser[3]	RVT-2[59]	5.33±6.11	1.33±2.31	1.33±2.31	2.67±2.31	1.33±2.31	17.33±2.31
CAP[5]	RVT-2[59]	89.33±6.11	-	-	85.33±8.32	52.00±10.58	82.66±20.53
Scaling-up [4]	RVT-2[59]	94.67±4.62	24.00±4.00	62.67±2.31	21.33±2.31	53.33±2.31	80.00±6.93
MA (Ours)	RVT-2[59]	94.67±2.31	73.33 ±2.31	93.33 ±6.11	84.00±10.58	69.33±12.85	82.67 ±12.22
RLBench[33]	RVT-2[59]	97.33 ±2.31	69.33±8.33	88.00±8.00	93.33 ±4.62	72.00 ±10.58	64.00±10.58

仿真zero-shot实验结果表


Method	Put_block	Play_jenga	Open_jar	Close_box	Open_box	Pickup_cup	Method	Take_umbrella	Sort_mustard	Open_wine	Lamp_on	Put_knife	Pick_&_lift
VoxPoser [3]	70.70±2.31	0.00±0.00	0.00±0.00	0.00±0.00	0.00±0.00	26.70±14.00	VoxPoser[3]	33.33±8.33	96.00±6.93	8.00±4.00	57.30±12.22	92.00±4.00	96.00±0.00
CAP [5]	84.00±16.00	0.00±0.00	0.00±0.00	0.00±0.00	0.00±0.00	14.67±4.62	CAP[5]	4.00±4.00	0.00±0.00	0.00±0.00	64.00±6.93	14.67±8.33	100.00±0.00
Scaling-up [4]	77.33±6.11	0.00±0.00	78.67±11.55	0.00±0.00	0.00±0.00	9.33±2.26	Scaling-up [4]	6.67±2.31	41.33±12.86	33.33±20.13	60.00±8.00	24.00±0.00	100.00±0.00
MA (Ours)	96.00±4.00	77.33±6.11	80.00±4.00	33.33±12.86	29.00±10.07	82.67±14.04	MA (Ours)	61.33±20.13	64.00±6.93	42.00±4.00	69.33±6.11	52.00±10.58	84.00±6.93

仿真BC实验结果表 (10 demo)

Data	Models	Put_block	Play_jenga	Open_jar	Close_box	Open_box	Pickup_cup	Data	Models	Take_umbrella	Sort_mustard	Open_wine	Lamp_on	Put_knife	Pick_&_lift
VoxPoser[3]	PerAct[34]	2.67±2.31	-	-	-	-	4.00±4.00	VoxPoser[3]	PerAct[34]	4.00±4.00	0.00±0.00	1.33±2.31	5.33±4.62	1.33±2.31	5.67±1.64
CAP[5]	PerAct[34]	6.67±2.31	-	-	-	-	14.67±12.86	CAP[5]	PerAct[34]	13.33±10.06	-	-	8.00±16.00	9.33±6.11	46.67±2.31
Scaling-up [4]	PerAct[34]	22.67±15.14	-	5.33±6.11	-	-	14.67±2.31	Scaling-up [4]	PerAct[34]	4.00±4.00	0.00±0.00	81.33±12.86	76.00±4.00	5.33±2.31	53.33±10.06
MA (Ours)	PerAct[34]	85.33±10.07	81.33±2.31	21.33±10.07	42.67±8.33	30.67±11.55	54.00±12.49	MA (Ours)	PerAct[34]	84.00±6.93	53.33±6.11	86.67±6.11	89.33±6.11	8.00±4.00	33.33±2.31
RLBench[33]	PerAct[34]	20.00±18.33	81.33±9.24	58.67±45.49	68.00±24.98	14.67±6.11	54.67±23.09	RLBench[33]	PerAct[34]	58.67±50.80	53.33±34.02	86.67±12.86	84.00±13.86	30.67±10.07	62.67±9.24
VoxPoser[3]	RVT-2[59]	73.33±2.31	-	-	-	-	2.67±2.31	VoxPoser[3]	RVT-2[59]	5.33±6.11	1.33±2.31	1.33±2.31	2.67±2.31	1.33±2.31	17.33±2.31
CAP[5]	RVT-2[59]	78.66±8.32	-	-	-	-	77.33±19.73	CAP[5]	RVT-2[59]	89.33±6.11	-	-	85.33±8.32	52.00±10.58	82.66±20.53
Scaling-up [4]	RVT-2[59]	38.67±2.31	-	33.33±2.31	-	-	92.00±4.00	Scaling-up [4]	RVT-2[59]	94.67±4.62	24.00±4.00	62.67±2.31	21.33±2.31	53.33±2.31	80.00±6.93
MA (Ours)	RVT-2[59]	85.33±2.31	82.67±2.31	78.67±10.06	82.67±2.31	24.00±4.00	97.33±2.31	MA (Ours)	RVT-2[59]	94.67±2.31	73.33±2.31	93.33±6.11	84.00±10.58	69.33±12.85	82.67±12.22
RLBench[33]	RVT-2[59]	86.67±2.31	85.33±2.31	81.33±6.11	76.00±4.00	4.00±4.00	97.33±2.31	RLBench[33]	RVT-2[59]	97.33±2.31	69.33±8.33	88.00±8.00	93.33±4.62	72.00±10.58	64.00±10.58

使用 MA 数据训练得到的策略在所有任务上的标准差为 3.39，低于直接 zero-shot 执行时的标准差 8.48。这说明，相比单纯依赖 zero-shot 部署，先用生成数据训练策略可以带来更稳定的表现

生成数据的动作分布



Chamfer 距离 (Chamfer Distance, CD) 是一种经典的点云相似性度量，广泛用于三维点云完成、配准、模型检索，以及深度学习中的损失函数和评估指标。距离越小，说明越相似。

MA 取得最低 $CD=0.056$ ，说明其生成轨迹在空间分布上最接近专家示范

真实世界 Zero-Shot 与数据训练验证

真实世界zero-shot & 训练 (6 demo) 实验结果表

	Open_drawer	Sort_object	On_lamp	Open_jar	Correct_dice	Press_switch	Close_laptop
CAP (0-shot)	0.00 $\pm$ 0.00	13.33 $\pm$ 5.77	0.00 $\pm$ 0.00	6.67 $\pm$ 5.77	6.67 $\pm$ 5.77	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00
MA (0-shot)	36.67 $\pm$ 5.77	60.00 $\pm$ 10.00	26.67 $\pm$ 11.55	40.00 $\pm$ 10.00	53.33 $\pm$ 5.77	20.00 $\pm$ 10.00	33.33 $\pm$ 5.77
PerAct (MA data)	50.00 $\pm$ 0.00	33.33 $\pm$ 5.77	50.00 $\pm$ 0.00	56.67 $\pm$ 5.77	60.00 $\pm$ 0.00	56.67 $\pm$ 5.77	33.33 $\pm$ 5.77
PerAct (Human data)	53.33 $\pm$ 11.55	36.67 $\pm$ 5.77	60.00 $\pm$ 0.00	76.67 $\pm$ 5.77	80.00 $\pm$ 10.00	33.33 $\pm$ 5.77	53.33 $\pm$ 5.77

使用 Manipulate-Anything 生成的数据进行训练，可以生成比零样本训练更稳健的策略。

对于长时序任务 **sort_object** 由于 模型PerAct 的限制，训练成功率低于zero-shot成功率。

实验设置：

机器人：Franka Panda + 平行夹爪

感知：Kinect-2 RGB-D 相机

任务：7 个真实世界语言条件任务


主要结果：

MA 为全部 7 个真实任务生成成功 demonstrations

最差任务 zero-shot 成功率仍超过 25%

相比 CAP，真实世界 zero-shot 表现提升 38%

数据量增加时的训练效果
Scaling effect with increasing data




扩展性：

随着 demo 数量增加，MA 数据训练效果持续提升；其线性拟合斜率 0.503 高于 RL Bench 专家数据的 0.197。

MA 可能生成了更多样的专家轨迹，使得生成数据具有更强的可扩展训练价值。

错误分析



误差来源：

MA 的主要误差来自两类 VLM 决策：

Perception Error：目标检测 / 视角选择错误；


Reasoning Error：子任务验证判断错误。

将 VLM 决策替换为人工判断后，性能差距反映了各模块的错误贡献。


'Turn on the lamp'



'Open the top drawer'



'Put objects on their colored mat'



(最长程的任务)



NovaPlan (CMU) 论文分享

NovaPlan: Zero-Shot Long-Horizon Manipulation via Closed-Loop Video Language Planning

Jiahui Fu^{*1}, Junyu Nan^{*1,2}, Lingfeng Sun^{*1}, Hongyu Li^{*1,3}, Jianing Qian⁴,
Jennifer Barry¹, Kris Kitani², George Konidaris³

¹Robotics and AI Institute ²Carnegie Mellon University ³Brown University ⁴University of Pennsylvania

^{*}Equal contribution



BROWN



arXiv: 2026.02.23

本文依旧**无需训练 无需示范 直接零样本执行**

Paper: <https://arxiv.org/html/2602.20119v1>

Page: <https://robot-ma.github.io/>

Zero-Shot Long-Horizon Manipulation via Closed-Loop Video Language Planning

研究目标

- 在无 demonstrations、无任务特定训练下
- 实现 zero-shot 长程操作
- 支持闭环验证与失败恢复

核心思想

- 高层：VLM 分解任务并监控执行
- 中层：视频生成模型想象未来步骤
- 低层：从生成视频中提取动作并落地执行

主要亮点


- Closed-loop video language planning
- Dual-flow action extraction
- Zero-shot long-horizon manipulation

关键词： VLM Planner / Video Generation / Object Flow / Hand Flow / Closed-loop Recovery

NovaPlan 将 VLM 推理、视频生成与几何执行整合为闭环系统



核心闭环: Plan → Generate → Extract → Execute → Verify / Recover



NovaPlan 以通用基座模型为核心，无需任务特定训练或 demonstrations


模块	作用	模型 / 组件
VLM Planner / Critic	子目标分解、执行监控、恢复判断	GPT-5.2
Video Generation	生成候选任务视频计划	Wan2.2 / Veo 3.1
Depth Recovery	从视频恢复几何深度	MoGe2 + CVD
Segmentation	目标分割	SAM3
3D Tracking	跟踪关键点与物体流	TAPIP3D
Hand Pose	恢复人手姿态与 hand flow	HaMeR
Grasping	生成抓取候选	GraspGen
Robot Platform	真机执行	Franka Research 3 + Robotiq 2F-85

系统特点

- Zero-shot long-horizon manipulation
- Closed-loop re-planning
- Object / Hand dual-flow grounding
- 无任务特定训练

关键趋势： 借助 VLM + 视频生成模型，实现从“想象未来”到“落地执行”的闭环机器人系统。

从生成视频中同时提取物体流与手部流，并选择更稳定的动作参考



意义：在遮挡、深度误差或物体大幅旋转时，保持更稳定的真机执行。




*"There are four
colored blocks
standing upright
on the table
around the red
base board..."*




Current Obs

Video Language Planning
"Insert colored blocks into
each of their matching sockets."



真实世界 zero-shot 长程任务 实验



实验任务:

Four-layer Block Stacking 四层物块堆叠
 Color Sorting 颜色分类
 Hidden Object Search 寻找隐藏物体

实验设置:

Franka Research 3 + Robotiq 2F-85 夹爪
 前视 RealSense D455 RGB-D 相机

对比方法:

NovaFlow: video-based planning 仅有object flow
 π0.5: VLA model 使用预训练数据 zero-shot
 MOKA: VLM-based planning

注:

“+”表示提供 oracle high-level plan,
 即人工给出高层任务分解,用于公平比较子任务执行能力。


评价指标:

Final Success (S3):
 任务最终完成率


Progression (S1-S3):
 各子步骤推进成功率

Long-horizon Task Rollout (3x Speed)

Four-layer
Block Stacking



Color Sorting



Hidden
Object Search



四

本人项目进展与讨论

为什么现实中的 **Agent-Based Robot** 难形成闭环？

开放世界中的核心问题

- 反馈信号不稳定
- 结果真值不明确
- 任务完成效果难以量化

直接后果

- 机器人更多执行开环动作
- 做完后难以继续修正
- 系统难以持续优化更难实现自进化

开放场景真实而复杂，但也更难提供稳定、可验证的反馈





01 系统原型



北京大学
PEKING UNIVERSITY


科学实验场景，**Agent-Based Robot** 的闭环载体！



科学实验场景的意义，在于同时提供**科学闭环**、**环境闭环**和**软件闭环**，从而为**Agent-Based Robot**的持续优化与自进化创造现实框架。

科学实验场景可能是Agent-Based Robot最合适的现实闭环载体。

感知模块：从“看懂场景”到“给出位姿”




- **任务目标**：输出机械臂可直接调用的目标位姿
- **核心链路**：场景理解 → 像素选点 → 实例分割 → 三维解算
- **验证重点**：模型选型是否合理、输出坐标是否稳定、是否支撑真实抓取

定量液体转移：实验曲线对比 过程差异

Shaping PD

多次回正再下倾
耗时长，阶跃性明显


Shaping PD



PD

改为连续单向调节
效率提升，但容易过冲


PD



Stop PD

加入固定提前截止
能明显减小过冲


Stop PD



Dyn Stop PD

进一步将截止量函数化
停止时机更合理

Dyn Stop PD




定量液体转移实验：实验数据分析 总体结论

**Dyn Stop PD 误差整体最小
综合精度最佳**

误差分析


Pouring error comparison across four methods



**连续控制显著优于震荡式倾倒
效率提升明显**

效率分析

Pouring time comparison across four methods



Agent-PID: 参数搜索过程与总体结论

1. 提出启发

执行层参数的探索与优化, 能否进一步交由 Agent 基于实验反馈自主完成?

2. 实验目标



以 20g 水的倾倒任务为例, 验证系统能否依据实验反馈自主探索调整参数。

3. 实验结果

系统先搜索 K_p 、 K_d , 再引入 Pre_Stop ; 最终得到稳定参数: $K_p = 0.8$, $K_d = 0.4$, $Pre_Stop = 0.5$, 实现了参数层小闭环搜索。

搜索参数曲线

Agent-PID parameter search schematic



02 方法: Agent-PID



北京大学
PEKING UNIVERSITY


Agent-PID: 实测视频



02 方法：动作Skill化

动作Skill化：从固定函数到可复用技能

- 原有执行函数对具体场景依赖较强，环境变化时**适应成本较高**。
- Skill 化将其重构为“Tool + Skill”的组合表达，为后续**泛化与扩展**提供了基础。



Skill化后的动作表示

旧执行函数	原有功能	Skill化	由基础动作组成的典型序列
<code>pick_cup(target)</code>	抓取目标容器	容器抓取Skill	接近抓取点 → 到达抓取点 → 夹爪闭合 → 到达抬升点 → 到达撤离点
<code>place_cup(target)</code>	放置目标容器	容器放置Skill	接近放置点 → 到达放置点 → 夹爪打开 → 到达抬升点 → 到达撤离点
<code>pick_bar()</code>	抓取搅拌棒	搅拌棒抓取Skill	接近抓取点 → 到达抓取点 → 夹爪闭合 → 到达抬升点 → 到达撤离点
<code>place_bar()</code>	放下搅拌棒	搅拌棒放置Skill	接近放置点 → 到达放置点 → 夹爪打开 → 到达抬升点 → 到达撤离点
<code>observe()</code>	到达观察位	观察Skill	到达观察位姿
<code>arm_ready()</code>	到达系统准备位	准备位Skill	到达准备位姿
<code>arm_ready_to_pour()</code>	到达倾倒准备位	倾倒准备Skill	到达过渡位姿 → 到达倾倒位姿
<code>pour_balance(v)</code>	执行定量倾倒	倾倒Skill	截止量与控制参数Skill参数化



科学实验场景的核心价值，在于同时提供**科学闭环**、**环境闭环**与**软件闭环**：

目标可定义，结果可测量，环境可复位，系统可迭代。

三重闭环共同支撑自驱动实验系统，使 Agent-Based Robot 能够从单次执行走向持续反馈、持续优化与自我进化。