



北京大学
PEKING UNIVERSITY

多模态智能体长期记忆 框架及评测

framework & benchmark

汪静雅
2026.07.08



北京大學
PEKING UNIVERSITY

MemVerse: Multimodal Memory for Lifelong Learning Agents

**Junming Liu^{*}, Yifei Sun^{*}, Weihua Cheng, Haodong Lei,
Yirong Chen, Licheng Wen, Xuemeng Yang, Daocheng Fu, Pinlong Cai,
Nianchen Deng, Yi Yu, Shuyue Hu, Botian Shi, Ding Wang[†]**

Shanghai Artificial Intelligence Laboratory

liujunming@pjlab.org.cn wangding@pjlab.org.cn

MemVerse:终身学习agent的多模态记忆

Code: <https://github.com/KnowledgeXLab/MemVerse>


现有长期记忆/多模态记忆的局限：

- **参数化记忆**：具备紧凑的泛化能力和联想召回。但容量固定、重训成本高、存在灾难性遗忘，且是黑盒模型，难以控制和解释。
- **外部显式记忆**：模块化、易扩展，可追溯。但缺乏抽象和整合，导致信息冗余、检索噪声大，且数据库增大会使计算成本飙升。



局限性不在于单一范式本身，而在于它们被孤立使用。根据互补学习系统（CLS）理论，人类大脑也是双轨并行的（海马体保留细节，新皮质压缩经验 VS 参数化支持紧凑的概括，外部存储保留显式和可再访的经验）。因此，AI记忆的关键不在于二选一，**而在于何时以及如何协调两者。**

1. 记忆协调器 (Memory Orchestrator): 根据当前的多模态上下文和推理状态, **动态管理**记忆的添加、更新、检索、整合以及删除。



2. 检索记忆: 短期记忆: 负责存储最近的交互上下文信息。**长期记忆:** 将持久性的知识以多模态知识图谱 (MMKGs) 的形式进行组织与沉淀。

3. 参数记忆 由长期记忆中定期蒸馏沉淀而来, 提供一种快速且可微的知识召回与泛化机制。

Part1. 分层检索记忆 统一数据格式 → “短期缓存” → “定期沉淀” 为多模态知识图谱。

1. Multimodal Processing (多模态处理)

What: 将任意输入的原始多模态数据M (图像、视频、音频等) 转化为统一的文本表征S。

$$S = \mathcal{D}_{\text{text}} \left(\mathcal{A} \left(\mathcal{E}_{\text{mod}}(M) \right) \right),$$

How: 利用预训练的多模态大模型 (MLLM) 把每个模态编码成一串描述性 Token, 并在存入短期记忆前进行长度归一化和冗余过滤。

Why: 统一到文本空间后, 依然保留有指向原始多模态数据和元数据的指针, 因此不会引入不可逆的模态信息损失。文本检索比混杂的多模态向量检索更高效、更精准, 不容易因为主要模态特征的干扰而漏掉细粒度或局部的关键信息。

Part1. 分层检索记忆 统一数据格式→“短期缓存”→“定期沉淀”为多模态知识图谱。

2. Short-Term Memory (短期记忆)

What: 利用滑动窗口机制，缓存最近K轮的交互状态（即对话序列中最接近当前时间的内容）。

$$\{q_1, q_2, \dots, q_t\} \longrightarrow \mathcal{M}_{\text{STM}} = \{q_{t-K+1}, q_{t-K+2}, \dots, q_t\}.$$

Why: 为了避免对长期存储进行频繁、多余的实时检索和连续更新。由于短期内的上下文信息已被窗口捕获，系统只需定期或在积累足够新知识时，再将短期记忆整合到长期记忆中，以此确保效率和稳定性。

Part1. 分层检索记忆 统一数据格式 → “短期缓存” → “定期沉淀” 为多模态知识图谱。

3. Long-Term Memory (长期记忆)

What: 利用大模型将原始文本压缩, 丢弃临时细节并保留核心知识建立图谱。构建一个配对的记忆结构 $\mathcal{M} = (\{\mathcal{G}_k\}, \mathcal{C})$, 其中 $\mathcal{C}$ 存储原始对话文本块, 而 $\mathcal{G}_k$ 则是由大模型提取、针对不同记忆类型建立的多模态知识图谱 (MMKGs)。

其中: $\mathcal{M} = (\{\mathcal{G}_k\}, \mathcal{C}), k \in \{\text{core, episodic, semantic}\}. \quad \mathcal{G} = \Phi_{\text{LLM}}(\mathcal{C}) = (\mathcal{V}, \mathcal{R}),$

- 核心记忆 (Core Memory): 跨会话、持久存在的用户事实。
- 情节记忆 (Episodic Memory): 带有时间戳、依赖特定上下文的互动。
- 语义记忆 (Semantic Memory): 与特定用户无关的、可泛化的抽象知识。

$$\ell_v: \mathcal{V} \rightarrow \mathcal{P}(\mathcal{C}), \quad \ell_v(v) = \{\text{Chunks supporting } v\}, \quad (5)$$

$$\ell_r: \mathcal{R} \rightarrow \mathcal{P}(\mathcal{C}), \quad \ell_r(r) = \{\text{Chunks supporting } r\}. \quad (6)$$

基于用户身份依赖性、时间范围和抽象程度将条目路由到子图。

Why: 在检索时, 一旦图谱中的实体或关系被激活, 就能直接链接追溯回最初的文本 $\mathcal{C}$ 以及关联的原始多模态数据, 保证符号知识 (逻辑) 和感官认知 (原始数据) 同时可达且有据可查。

Part2. 轻量化参数记忆模型

通过模拟检索行为，
把长期记忆里的知识“蒸馏”到一个小模型的权重里。

1. Supervised Fine-tuning (监督微调)

What: 让轻量化语言模型通过监督微调，内化长期记忆 (LTM) 中的知识。

How: 利用基于长期记忆检索过程构建的 $(q, \mathcal{R}, \hat{\mathcal{R}})$ 三元组数据集进行训练，即问题、长期记忆检索得到的答案、小模型自己预测的生成文本。训练目标是最小化预测序列与目标序列的Token级交叉熵损失，让模型根据问题 q 来生成检索答案 $\hat{\mathcal{R}}$ 。

$$\mathcal{L}_{\text{update}} = - \sum_{t=1}^T \log P_{\Theta}(r_t \mid q, r_{<t}),$$

Why: 通过这个过程，将检索到的知识直接嵌入到模型的参数空间中，让小模型在参数空间内学会去模拟、效仿长期记忆的检索行为，从而减少RAG带来的计算开销。

Part2. 轻量化参数记忆模型

通过模拟检索行为，
把长期记忆里的知识“蒸馏”到一个小模型的权重里。

2. Dynamic Memory Expansion (动态记忆扩展)

What: 随着显式知识图谱的不断扩张，参数记忆进行同步的、轻量化的参数渐进式更新。

How: 在每个更新步 t ，直接利用从显式记忆中衍生出的新问题-证据对 $(q_t, \mathcal{R}_t)$ ，对参数模型进行一次轻量化的局部微调，从而得到最新的参数状态。

$$\mathcal{M}_{\text{para}}^{t+1} = \mathcal{M}_{\text{para}}^t + \Delta\Theta_t,$$

Wht: 它不是作为一个独立的长期知识库，而是作为检索记忆的紧凑、快速访问的互补手段。这种持续的动态更新能让参数记忆与显式检索记忆保持步调一致地演进，而不需要对整个模型进行完全的重新训练。

Summary

- **慢通路 (Slow Pathway)** : 运作在层级化的多模态知识图谱上, 持续将智能体的经历转化为核心、情节和语义记忆。→记性好, 有据可查, 但反应慢。
- **快通路 (Fast Pathway)** : 一个轻量级的外部参数化记忆模型, 定期从慢通路的长期记忆图谱中蒸馏知识, 与主LLM完全解耦, 提供超低延迟的快速响应。→反应快、开销低。
- **中央记忆协调器 (Central Memory Orchestrator)** : 根据置信度得分, 自动在快慢通路之间进行路由, 灵活平衡速度与准确率。

Benchmarks

LoCoMo: 一个包含长对话小节的长周期多模态对话数据集;

LongMemEval: 一个包含 500 个对话的大型基准测试, 专门设计用于评估长期记忆处理能力;

ScienceQA: 一个多模态科学推理基准测试;

MSR-VTT: 一个被广泛运用于跨模态理解与检索的视频-文本基准测试。

GPT-4o-mini/Whisper (前处理并建立指针图谱) → Qwen2.5-7B (快通路参数记忆快速响应) → 不同 backbone (下游阅读器综合所有记忆生成最终回答)。

Baselines

基础模型: GPT-3.5-Turbo, GPT-4o-mini, Qwen2.5-7B-Instruct, GPT-5.1

记忆与检索框架: MemoryBank, AMEM, EpMem, Mem0, MemoryOS, MemGPT, Zep, LangMem, LD-Agent, QRRetriever, SimpleMem, Omni-SimpleMem;

推理模型: CoT, HoT-T5-Large, Chameleon;

跨模态多模态大模型: InternVideo, UMT-L, VAST, Clip4Clip, ExCae, CLIP。

Experiments



LoCoMo:

- MemVerse在所有四个评估的主干模型上，均一致达到了业内领先的最高综合F1分数。
- 当主干模型为较小的开源模型时，性能提升幅度相对温和。这主要是由于小模型存在长上下文推理限制，在有效整合和区分高密度记忆流时比较吃力。
- 在极复杂的开放领域（Open Domain）和多步推理（Multi-Hop）场景下也遇到了性能瓶颈（由于开放领域的海量历史的和非结构化性质，检索不可避免地引入了语义噪声，下游生成器产生混淆）。
- **未来改进方向：**引入一个显式的语义重排器来过滤冗余候选记忆，剪枝上下文噪声。

思想自由 兼容并包

Model	Method	Answer Prediction (F1)				
		Single Hop	Multi-Hop	Temporal	Open Domain	Overall
Human	Human (Maharana et al., 2024)	95.1	85.5	92.6	75.4	91.6
Qwen2.5-7B-Instruct	Vanilla	29.3	23.7	8.7	18.1	23.3
	Full Context (Terranova et al., 2025)	10.6	3.4	3.7	8.2	7.7
	RAG (Terranova et al., 2025)	21.7	8.1	4.9	14.5	15.3
	A-Mem (Terranova et al., 2025)	12.7	8.7	6.3	13.9	10.7
	EpMem (Terranova et al., 2025)	17.6	6.4	10.0	2.7	13.0
	Mem0* (Yan et al., 2025)	25.0	20.3	33.2	32.7	26.3
	MemoryOS* (Yan et al., 2025)	29.6	21.0	26.3	40.9	28.0
	MemVerse	40.3	28.1	24.2	25.1	33.8
GPT-4o-mini	Vanilla	8.6	19.0	9.9	13.7	11.1
	Full Context (Xu et al., 2025)	40.4	25.0	18.4	12.0	31.2
	Claude-Mem (Liu et al., 2026a)	10.2	24.5	12.2	21.5	13.9
	A-Mem (Xu et al., 2025)	44.7	27.0	45.9	12.1	39.7
	MemGPT (Xu et al., 2025)	41.0	26.7	25.5	9.2	33.2
	Zep (Chhikara et al., 2025)	35.7	19.4	42.0	49.6	34.9
	LangMem (Chhikara et al., 2025)	35.5	26.0	30.8	40.9	33.1
	Mem0 (Chhikara et al., 2025)	38.7	28.6	48.9	47.7	39.6
	MemoryOS (Kang et al., 2025)	35.3	41.2	20.0	48.6	34.0
	SimpleMem (Liu et al., 2026a)	12.8	30.0	17.8	31.2	18.1
	Omni-SimpleMem (Liu et al., 2026a)	19.6	54.4	17.7	58.8	28.0
	MemVerse	49.2	46.1	29.7	30.8	43.4
GPT-5.1	Claude-Mem* (Liu et al., 2026a)	17.1	28.9	26.4	29.2	22.0
	A-MEM* (Liu et al., 2026a)	16.4	28.7	24.6	28.4	21.1
	MemGPT* (Liu et al., 2026a)	16.5	28.8	24.9	29.4	21.3
	Mem0* (Liu et al., 2026a)	16.0	29.2	26.1	29.8	21.4
	SimpleMem* (Liu et al., 2026a)	17.8	30.5	27.2	30.5	22.9
	Omni-SimpleMem* (Liu et al., 2026a)	36.7	59.8	30.7	67.6	41.6
	MemVerse	49.2	35.6	38.3	26.7	43.0
GPT-3.5-turbo-16k	Vanilla	34.7	32.5	11.0	14.4	28.1
	RAG (Maharana et al., 2024)	44.3	30.6	41.9	40.2	41.0
	MemVerse	69.1	49.6	53.1	34.2	60.0

Experiments



LongMemEval:

- MemVerse 实现了极其高效的记忆索引和检索。尽管检索召回率极高，但下游的回答准确率却遭遇了瓶颈（89.8 VS 68.4）。
- 这种性能差异是由于下游生成器出现了过度推理。面对记忆系统提供的高密度、丰富的记忆输入，下游模型过度解读了某些信息，从而产生了错误的关联。
- 将下游的阅读模型升级为更强能力的GPT-5.1，最终准确率飙升至77.0%。证明了MemVerse能提供高保真的长上下文，此前的瓶颈卡在**下游阅读器的推理能力上**。

ScienceQA: 将MemVerse与GPT-4o-mini配对使用时，创下了85.48%的准确率。这一表现显著超越了强大的思维链基线，并已经逼近了人类的水平。

MSR-VTT（双向视频-文本检索）: MemVerse完胜此前所有的预训练基础模型以及专门的 ViT架构。证明了其结构化的记忆框架在完全无监督的环境下，依然能极其精准地捕获跨模态的对齐特征。

Method	Recall@5 ↑	Accuracy ↑
No History	-	0.0
Long Context	-	57.4
RAG	62.4	63.6
MemoryBank	58.6	59.6
LD-Agent	56.8	59.2
A-Mem	-	55.4
Mem0	-	65.0
MemoryOS	-	58.0
QRRetriever	80.4	66.7
MemVerse	89.8	68.4

Category	Method	Backbone	Acc ↑
Baselines	Human	-	88.40
	GPT-4	-	82.69
LLM-CoT	CoT (UnifiedQA)	223M	74.11
	CoT (GPT-4)	1T+	83.99
	Chameleon (ChatGPT)	175B+	79.93
	HoT-T5-Large	738M	83.38
MemVerse	Qwen2.5-7B	7B	75.62
	Qwen2.5-72B	72B	80.25
	GPT-4o-mini	-	85.48

Cat.	Method	T2V		V2T	
		R@1	R@5	R@1	R@5
Pre-trained	InternVideo	55.2	79.6	57.9	79.2
	UMT-L	58.8	81.0	58.6	81.6
	VAST	63.9	84.3	-	-
ViT	Clip4Clip	46.4	72.1	45.4	73.4
	ExCae	67.7	92.7	69.3	92.5
	CLIP	29.7	48.9	21.4	38.6
MemVerse	GPT-4o-mini	90.4	95.6	89.2	92.7

Ablation:

- 基础模型 + 纯滑窗：表现最差，因为滑动窗口的上下文容量极其有限。
- 引入长期记忆：性能出现实质性暴涨。
- 全功能合体：当通过中央协调器将参数记忆与长期图谱检索融合后，系统达到了最佳的整体性能。

Further Analysis

- 结构化图谱记忆的优势：在多步推理（Multi-Hop）和时序推理（Temporal）中优势最大。这表明层级图谱结构在建模复杂依赖关系时，远比一维的扁平向量检索有效。
- 参数蒸馏的高效性：整个流水线在计算上是高度优化且高产的。虽然总训练时间看起来稍长，但这完全是因为训练轮数多和上下文训练数据量大导致的，记忆模块本身没有任何架构上的低效瓶颈。

Method	S-Hop	M-Hop	Temp.	Open	Over.
<i>GPT-4o-mini</i>					
Vanilla	8.6	19.0	9.9	13.7	11.1
+Short-Term	11.1	17.7	8.9	11.7	11.9
+Param	48.9	28.7	19.9	11.7	36.8
+Long-Term	47.0	40.8	25.9	22.5	39.9
MemVerse	49.2	46.1	29.7	30.8	43.4
<i>Qwen2.5-7B-Ins.</i>					
Vanilla	29.3	23.7	8.7	18.1	23.3
+Short-Term	27.2	24.5	10.2	16.8	22.5
+Param	28.8	24.2	10.1	19.2	23.5
+Long-Term	36.9	29.1	24.8	22.7	32.1
MemVerse	40.3	28.1	24.2	25.1	33.8

Method	S-Hop	M-Hop	Temp.	Open	Over.
Flat RAG	30.3	27.3	18.5	19.3	26.6
MMKG-only	47.0	40.8	25.9	22.5	39.9

Component	Metric	Value
Memory Extraction	Total Time	22.03 s
	Per 1k Tokens	0.20 s
MMKG Construction	Total Time	208.56 s
	Per Chunk	13.03 s
	Per 1k Tokens	16.94 s
Parametric Training	Total Time	978.72 s
	Training Tokens	453,841
	Per 1k Tokens	2.16 s

- **可借鉴：**采用图谱形式存储多模态记忆，利用指针保存和链接文本提示&原始多模态信息；将检索得到的记忆参数化为小模型的“直觉”，两种方式结合。
- 当系统被部署到更长期的真实交互场景中时，记忆图谱会**无休止地持续膨胀**，这将直接导致检索和插入的计算开销大幅增加，那些已经过时、陈旧的历史记忆容易作为**过期噪声**被错误引入，从而干扰当前任务的判断。

作者提出了一个优化思路——**动态时间分片图谱机制（是否合理？）**：

- 放弃维持一张单一的超级大图，而是将记忆动态地切割、拆分到多个不同时间段的子图中。每隔一段时间，系统自动初始化一张全新的空白子图。过去的、老旧的子图并不会被销毁，而是作为历史档案封存，当主模型确实需要翻阅时，可以通过时间索引精准定位并跨图检索这些归档图谱。



北京大學
PEKING UNIVERSITY

M³Exam: Benchmarking Multimodal Memory for Realistic User-Agent Interactions

Zhengjun Huang^{1,7*}, Wenxuan Liu^{2*}, Zhoujin Tian¹, Wei Chen^{3,6}, Junle Chen¹,
Yuqian Wu³, Fangyuan Zhang⁴, Qintian Guo^{5†}, Xiaofang Zhou¹

¹The Hong Kong University of Science and Technology, ²Beijing University of Chemical Technology

³The Hong Kong University of Science and Technology (Guangzhou)

⁴Harbin Institute of Technology (Shenzhen), ⁵Beijing Institute of Technology (Zhuhai)

⁶Tencent Hy, ⁷Peng Cheng Laboratory

zhuangff@cse.ust.hk, qtguo@bit.edu.cn, zxf@cse.ust.hk

对MLLMs和记忆系统的基准测试揭示了跨模态基础、跨会话推理和
积累多模态上下文的效率成本方面的持续差距

Code: <https://anonymous.4open.science/r/M-3-Exam-128D>.


一个可靠的多模态记忆基准必须包含三个相应的难度维度。

- **内容的复杂性 (content)** 持续跟踪和管理不断增长的会话历史中的异构工件(对话、图像、pdf)。
- **推理复杂性 (reasoning)** , 比如将一杯咖啡的视觉状态与过去的PDF联系起来。
- **意图复杂性 (intent)** , 例如从历史推断用户是咖啡师。

Table 1: Comparison of M³Exam with representative conversational-memory benchmarks. **A. Round** = average user–assistant rounds per session; **A. File** = average images and document files per session. **MR** = multimodal reasoning over visual evidence; **SA** = statistical analysis of multimodal graphs; **FM** = file management and retrieval; **FR** = file reasoning over document content. **II** = implicit information inference; **TH** = domain-specific thematic reasoning. ✓ = supported; ✓ = partial / restricted; ✗ = not supported; ~ = N/A.

Benchmark	Memorizing		Reasoning				Interpreting	
	A. Round	A. File	MR	SA	FM	FR	II	TH
LongMemEval (Wu et al., 2025)	5.2	~	✗	✗	✗	✗	✗	✗
MemoryArena (He et al., 2026)	6.9	~	✗	✗	✗	✗	✗	✗
MemoryAgentBench (Hu et al., 2025)	9.6	~	✗	✗	✗	✗	✓	✓
LoCoMo (Maharana et al., 2024)	10.8	3.4	✓	✗	✗	✗	✗	✗
MMDialog (Feng et al., 2023)	4.6	2.6	✓	✗	✓	✗	✗	✗
MMRC (Xue et al., 2025)	12.9	2.9	✓	✗	✓	✗	✗	✗
Mem-Gallery (Bei et al., 2026)	16.5	4.2	✓	✗	✓	✗	✗	✗
M ³ Exam (Ours)	12.7	7.5	✓	✓	✓	✓	✓	✓

现有的基准普遍假设用户信息是完全显式表达的, 忽视了现实中需要结合上下文进行隐式意图推理 (Implicit Inference, II) 和主题推理 (Thematic Reasoning, TR) 的场景。



M³Exam基准测试:
以此来评估智能体在面对复杂的真实多模态历史时，跨模态推理及隐式意图理解的能力。

M³Proctor 记忆方法:
引入模态感知与按需消费机制，解决现有系统盲目引入视觉数据导致的效率低、开销大、关键信息易被淹没的问题。


M³Exam:

1. 问题建模

将智能体 (Agent) 作为答题者, 基于从用户过去对话中积累的多模态记忆” 进行回答。
每个样本实例将一个由多会话组成的对话集合 $\mathcal{D} = (D_1, \dots, D_L)$ 与一个查询问题 x 配对。会话按时间排序, 其中对话轮次与附带的图像、文档页面交织在一起, 共同构成历史记录 $\mathcal{H}$ 。
给定历史 $\mathcal{H}$ 和查询 x , 智能体需生成预测答案 $\hat{a}$ 。这要求智能体必须从 $\mathcal{H}$ 中检索出正确的证据, 跨文本/图像/文档进行定位, 并解读出问题所需的隐式信息。

2. 数据集构建

构建过程基于三个输入源: 画像 $\mathcal{P}$ (姓名、职业、兴趣)、核心事件 $\mathcal{C}$ (画像随时间发展的叙事主线) 以及多模态文件池 $\mathcal{F}$ (图表、照片、PDF)。构建分为三个阶段, 且每阶段均有质量控制。



M³Exam:

2. 数据集构建

2.1 时间线构建

- **核心事件线生成:** 基于 $(\mathcal{P}, \mathcal{C})$, 利用一个LLM生成一条按时间顺序排列的核心事件时间线 $\{e_1, \dots, e_N\}$, 每个事件记录为 $e_i = (idx_i, desc_i, query_i, time_i, kw_i)$, 用于将一个人生事件与该角色在该事件下可能提出的、具有视觉场景约束的查询对应起来, 同时包含严格递增的日期以及一个用于图像检索的关键词。
- **引入干扰项:** 为了模拟真实用户偏离主题的情况, 额外生成了 $\mathcal{M}$ 个与核心主线正交的干扰侧面事件 (如杂事、爱好、闲聊), 并按日期合并到主线中。这些干扰项增加了嘈杂环境下的证据检索难度, 并为隐式推理等问题提供了强负样本。
- **质量审查:** 先通过LLM自检审计画像违规、核心事件偏移和内部矛盾并进行修复, 最后通过人工抽检通过后才能进入合成阶段。

(2) Timeline Generation

Event Timeline

Persona+Core Event

Core Sub-Event 1:
2023-04-18, "Noah practices pulling espresso shots."

Core Sub-Event 2

Side Event 3

Core Sub-Event 3

Core Sub-Event 4

Core Event Line Distractions

Event-Arised Query

Snapshot

2023-04-18,
"Noah asks how to keep crema and flavor more stable.",
"photo of crema espresso"

Thematic File

2023-04-20,
"Noah asks for help on his training slides."
"Barista Training.pdf"

Statistical Graph

2023-04-22,
"Noah asks for statistical opinion on childhood vaccine.",
"Childhood vaccine opinion stats"


Self-Checking & Human Inspection

M³Exam:

2. 数据集构建

2.2 多轮对话生成 (将结构化时间线转换为完整的多轮对话)

- ① **窗口滑动机制**: 采用滑动窗口逐轮遍历时间线, 第k轮对应一个包含 δ 个事件的窗口 $\mathcal{W}_k = (e_{p_k - \delta}, e_{p_k})$,
- ② **LLM生成对话**: 窗口末尾的事件用于驱动用户模拟器生成一个可选的后续追问; 窗口开头的事件则结合其新关联的图像, 生成当前轮的用户查询。 $r_{k+1} \sim \pi_{\text{user}}(\cdot | \mathcal{W}_{k+1}, S_k, \mathcal{P})$.
- ③ **记忆添加**: 每轮对话都会被压缩为一个关键摘要, 并合并入记忆 $S_k = S_{k-1} \cup \{\sigma_k\}$
- ④ **质量审查**:
 - 片段内审核: 检查每个会话片段内部的局部轮次窗口, 发现并修正局部问题;
 - 跨片段审核: 检查跨越不同会话片段边界的错误, 最后再由人工专家进行最终审核。



M³Exam:

2. 数据集构建

2.3 问题库生成

- 在最终构建完成的数据集基础上，我们通过采样上下文窗口并提示LLM生成问题，从而构建一个带类型标注的问题库。
- 每个问题样本表示为一个五元组： $q = (x, A, \mathcal{F}_q, \tau)$
- 整个问题库共包含**八种问题类型，覆盖三类能力**：
 - (1) 记忆能力：SS (Single-Session Retrieval) : 单会话信息检索；FM (File Management) : 文件管理；FJ (Factual Judgment) : 事实判断
 - (2) 推理能力：MS (Multi-Session Analysis) : 跨会话分析；MR (Multimodal Reasoning) : 多模态推理；TR (Temporal Reasoning) : 时间推理
 - (3) 理解能力：II (Implicit Inference) : 隐式推理；TH (Thematic Reasoning) : 主题推理
- **质量审查**：过滤掉所有格式不正确或引用了当前展示上下文之外证据的问题，保证每一个问题都能够仅依据其引用的证据完成回答。

M³Exam:


3. 数据集统计

2.3 数据集统计信息

- 规模结构：包含239个多会话对话，涵盖15个画像场景。
- 交互与问题量：总计包含3,025轮用户-智能体交互，配有5,150个评估问题。
- 跨度与模态：具有长周期特性，每个画像跨越14到18个会话（平均每会话12.7轮），整个对话共积累了1,799个多模态工件。
- 难点分布：问题库侧重推理且分布平衡。其中1,796个问题（34.9%）属于跨模态（FM, MR）
769个问题（14.9%）需要对未明说的上下文进行解读（TH, II）。

M³Proctor:

M³ Proctor : Retrieve on Demand



先前的多模态记忆方法本质上是模态无关的，它们不加区分地注入原始视觉资源会掩埋决定性的证据，并且对于仅靠文本就能解决的查询，会不必要地膨胀 Token 预算。

该工作引入了M3Proctor，这一基准线方法将模态偏置（modality bias，即查询所具体依赖的模态）提升为一级核心信号，它能动态检测查询偏置，仅在有需求时才升级调用原始视觉资源。

M³Proctor:

1. 多模态索引构建

为了让文本检索器能够搜索记忆，同时保留锁定在图像和文档中的证据，我们将**每种原始模态投影为一个文本替代物**，并将其附加到引入该模态的那一轮对话中：

- 图像：一段标题。
- 信息丰富的视觉内容（如新闻图表和表格）：附带对其坐标轴、序列和数值的文本转录。
- 文档页面：将其中文本层与单句摘要配对。

每个数据块还带有一个针对模态集合 $\mathcal{M} = \{I, P, C\}$ （图像, 文档, 图表）的模态标签。该标签是从文本替代物（而非像素）中读取的，这是下游模块进行零成本操作的钩子。

- ✓ 这些文本替代物和模态标签共同为后续的答题机制奠定了基础。因为图表的替代物已经编码了其底层的数量关系，许多图表读取问题仅靠文本内容就更易回答，从而允许级联机制免去重新渲染原始资源的开销，除非模态标签和偏置信号指示必须这样做。

M³Proctor:

2. 模态感知推理

在推理时，M3Proctor利用检索到的块的模态标签以及问题的模态偏置来决定：其低成本的文本替代物是否足够，还是必须调阅原始资源。

2.1 偏置检测与偏置感知重排

① **偏置检测**：利用LLM将问题的模态偏置表示为一个由 $\mathcal{M}$ 索引的二值向量，

$$b(q) = (b_m(q))_{m \in \mathcal{M}} \in \{0, 1\}^{|\mathcal{M}|}$$

其中， $b_m(q)=1$ 当且仅当回答 q 需要检查模态为 m 的资源

② **偏置重排**：仅通过语义相似度对块进行排序，可能会掩埋包含决定性图像但与 q 仅有中等相似度的轮次。因此，我们使用 $b(q)$ 来修正候选池内的排名：

$$s(q, c) = \cos(q, c) + \sum_{m \in \mathcal{M}} \lambda_m b_m(q) 1_m(c)$$

当问题的偏置项 $b_m(q)=1$ 且数据块的模态标签 $1_m(c)=1$ 同时满足时，就会获得奖励分。

M³Proctor:

2. 模态感知推理

在推理时，M3Proctor利用检索到的块的模态标签以及问题的模态偏置来决定：其低成本的文本替代物是否足够，还是必须调阅原始资源。

2.2 成本感知模态级联

重排决定了读取哪些证据，而级联则决定了为此支付多少成本。我们构建了一个级联答题机制，首选最便宜的充足表征，并仅在需要时才为原始模态买单。

① **Stage1**: 仅从文本回答 q ，使用多模态证据的替代物。

② **置信度判断**: 当文本答案不可靠或检索文本未满足模态偏置时，系统会升级：

$$\Phi(\hat{a}_1, q) = 1[u(\hat{a}_1) \vee \beta(q)]$$

③ **Stage2**: 根据每个模态的“融合模态-证据得分”，依序加载模态 m 的**原始资源**

$$e_m(q) = w_r \frac{1}{k} \sum_{c \in \mathcal{R}_k} \mathbb{I}_m(c) + w_b b_m(q) + w_s \sigma_m(q),$$

检索到的相关块里包含该模态的比例 + 问题本身的偏置 + 表面的词汇线索

Models & Baselines

① **前沿多模态大模型**: Claude-Opus-4.6, GPT-5.4, GLM-5.1, Qwen3.6Plus, Gemini-3.1-Pro-Preview, Doubao-Seed-2.0Pro, Kimi-k2.5, Grok-4。

② **智能体记忆系统**

- **纯文本记忆方法**: NaiveRAG, A-Mem, Mem0, MemoryOS。
- **多模态记忆方法**: UniversalRAG, RAGAnything, MemVerse, NGM, MIRIX, Mem0 with vision enabled。

Evaluation Metrics

① **核心评估指标**

- Exact Match (EM): 精确匹配度。
- Token-level F1 score: 词级别的 F1 分数。
- BLEU-1: 文本相似度评估指标。
- LLM-as-a-Judge (LLM-J): 大模型裁判。

② **综合表现度量**

对上述所有评估的答案质量信号进行加权汇总。

Experiments

Agent Type	SS		MS		TR		MR		TH		II		FM	FJ	Overall
	F1	LLM	F1	LLM	F1	LLM	F1	LLM	F1	LLM	F1	LLM	EM	EM	
Frontier MLLMs															
🌟 Claude-Opus-4.6	0.2593	0.6050	0.3678	0.5687	0.3754	<u>0.5813</u>	0.5354	0.7306	0.2387	<u>0.6083</u>	0.2412	0.6501	<u>0.2203</u>	0.9443	0.4937
🌀 GPT-5.4	0.5257	<u>0.7623</u>	0.3276	0.6274	0.4975	0.4950	0.4477	0.6389	0.1683	0.4333	0.3227	0.7125	0.1890	0.9621	0.4823
Z GLM-5.1	<u>0.5409</u>	0.6510	0.6361	0.6066	0.5142	0.5115	0.5515	0.6550	0.5843	0.6193	0.3735	0.5667	0.1667	0.9332	0.5493
🌀 Qwen3.6-Plus	0.4713	0.6354	0.5907	0.6004	<u>0.5218</u>	0.4799	0.5167	0.6406	0.5325	0.5227	<u>0.3347</u>	0.3833	0.1520	0.9800	<u>0.5049</u>
🌟 Gemini-3.1-Pro-Preview	0.5320	0.7693	0.2991	0.5437	0.4926	0.5404	0.3789	0.5111	0.3161	0.4417	0.2870	<u>0.6875</u>	0.2403	<u>0.9666</u>	0.4668
🌀 Doubao-Seed-2.0-Pro	0.5638	0.2917	<u>0.6330</u>	0.3607	0.6514	0.6437	0.7204	0.6586	<u>0.5480</u>	0.1364	0.3005	0.4103	0.1950	0.9532	0.4938
📺 Kimi-k2.5	0.4269	0.6304	0.3410	0.4536	0.4642	0.5050	<u>0.5614</u>	0.6556	0.1987	0.4351	0.2487	0.5589	0.1308	0.8667	0.4493
🌀 Grok-4	0.4383	0.6211	0.3129	<u>0.6125</u>	0.3259	0.5150	0.3912	<u>0.7034</u>	0.1450	0.3667	0.2322	0.6875	0.1871	0.7923	0.4357
🌀 Qwen-2.5-VL-7B	0.2742	0.5468	0.4587	0.3471	0.4378	0.5063	0.5425	0.4682	0.2461	0.0635	0.1672	0.0523	0.2070	0.7904	0.4179
Text-based Agentic-Memory Systems															
NaiveRAG	0.4430	0.6547	0.3117	0.4429	0.2349	0.4167	0.2080	0.2572	0.1321	0.2806	0.1263	0.3202	0.2569	0.7840	0.3249
A-Mem	0.5921	<u>0.7247</u>	0.3998	0.5345	0.1298	0.1697	0.2403	0.3727	0.1361	0.3493	0.1227	0.2872	0.2875	0.9243	0.3450
Mem0 (w/o vision)	0.5343	0.6957	0.3837	0.5448	0.1361	0.1853	0.2471	0.3787	0.1346	0.3843	0.0962	0.3000	0.1544	0.9243	0.3410
MemoryOS	0.5410	0.7047	0.3399	0.5145	0.1248	0.3977	0.2146	0.3299	0.1274	0.3327	0.1162	0.3175	0.3150	<u>0.9733</u>	0.3470
Multimodal Agentic-Memory Systems															
Universal-RAG	<u>0.5858</u>	0.7328	0.4349	0.5769	0.3903	0.4431	0.2938	0.4369	0.2691	<u>0.4872</u>	0.1586	0.5559	0.5367	0.8241	0.4366
RAG-Anything	0.5849	0.6418	0.3940	0.5474	<u>0.4353</u>	0.4465	0.3863	0.4970	<u>0.2782</u>	0.4390	<u>0.1873</u>	<u>0.6201</u>	0.4572	0.8508	0.4481
Mem0 (with vision)	0.4798	0.6457	<u>0.4181</u>	0.5548	0.1511	0.1837	0.4459	0.5607	0.1485	0.3527	0.1286	0.5973	0.1942	0.9176	0.3969
MemVerse	0.4850	0.6406	0.3895	0.5662	0.3229	0.4096	<u>0.4591</u>	0.5613	0.2518	0.4223	0.1849	0.6048	0.5474	0.9042	0.4481
NGM	0.3559	0.5266	0.3453	0.4660	0.1716	0.1601	0.4708	0.5479	0.2288	0.3905	0.1807	0.6060	0.6208	0.9042	0.3813
MIRIX	0.4954	0.6378	0.2853	0.4875	0.4564	0.4949	0.4076	<u>0.5775</u>	0.2999	0.5917	0.1054	0.5375	0.3807	0.8664	<u>0.4560</u>
M ³ Proctor (Ours)	0.4993	0.6924	0.3697	<u>0.5667</u>	0.3952	<u>0.4877</u>	0.4305	0.6063	0.2202	0.4786	0.3021	0.6515	<u>0.5688</u>	0.9844	0.4838

- 最强的前沿多模态大模型（GLM-5.1）在不需要进行前置检索、直接读取人工标注好证据的完美情况下，综合得分也仅有0.549。如果在全上下文不加检索的情况下直接运行，性能还会进一步退化。
- 基于 Qwen-2.5-VL-7B 构建的智能体记忆系统虽然相比基座模型有所提升，但整体上依然落后于前沿大模型。
- 暴露出当前模型和记忆系统尚不具备的能力。

Experiments



Agent Type	SS		MS		TR		MR		TH		II		FM	FJ	Overall
	F1	LLM	F1	LLM	F1	LLM	F1	LLM	F1	LLM	F1	LLM	EM	EM	
Frontier MLLMs															
🌟 Claude-Opus-4.6	0.2593	0.6050	0.3678	0.5687	0.3754	<u>0.5813</u>	0.5354	0.7306	0.2387	<u>0.6083</u>	0.2412	0.6501	<u>0.2203</u>	0.9443	0.4937
🌀 GPT-5.4	0.5257	<u>0.7623</u>	0.3276	0.6274	0.4975	0.4950	0.4477	0.6389	0.1683	0.4333	0.3227	0.7125	0.1890	0.9621	0.4823
Z GLM-5.1	<u>0.5409</u>	0.6510	0.6361	0.6066	0.5142	0.5115	0.5515	0.6550	0.5843	0.6193	0.3735	0.5667	0.1667	0.9332	0.5493
🌀 Qwen3.6-Plus	0.4713	0.6354	0.5907	0.6004	<u>0.5218</u>	0.4799	0.5167	0.6406	0.5325	0.5227	<u>0.3347</u>	0.3833	0.1520	0.9800	<u>0.5049</u>
🌟 Gemini-3.1-Pro-Preview	0.5320	0.7693	0.2991	0.5437	0.4926	0.5404	0.3789	0.5111	0.3161	0.4417	0.2870	<u>0.6875</u>	0.2403	<u>0.9666</u>	0.4668
🌀 Doubao-Seed-2.0-Pro	0.5638	0.2917	<u>0.6330</u>	0.3607	0.6514	0.6437	0.7204	0.6586	<u>0.5480</u>	0.1364	0.3005	0.4103	0.1950	0.9532	0.4938
📺 Kimi-k2.5	0.4269	0.6304	0.3410	0.4536	0.4642	0.5050	<u>0.5614</u>	0.6556	0.1987	0.4351	0.2487	0.5589	0.1308	0.8667	0.4493
🌀 Grok-4	0.4383	0.6211	0.3129	<u>0.6125</u>	0.3259	0.5150	<u>0.3912</u>	<u>0.7034</u>	0.1450	0.3667	0.2322	0.6875	0.1871	0.7923	0.4357
🌀 Qwen-2.5-VL-7B	0.2742	0.5468	0.4587	0.3471	0.4378	0.5063	0.5425	0.4682	0.2461	<u>0.0635</u>	<u>0.1672</u>	<u>0.0523</u>	<u>0.2070</u>	0.7904	0.4179
Text-based Agentic-Memory Systems															
NaiveRAG	0.4430	0.6547	0.3117	0.4429	0.2349	0.4167	0.2080	0.2572	0.1321	0.2806	0.1263	0.3202	0.2569	0.7840	0.3249
A-Mem	0.5921	<u>0.7247</u>	0.3998	0.5345	0.1298	0.1697	0.2403	0.3727	0.1361	0.3493	0.1227	0.2872	0.2875	0.9243	0.3450
Mem0 (w/o vision)	0.5343	0.6957	0.3837	0.5448	0.1361	0.1853	0.2471	0.3787	0.1346	0.3843	0.0962	0.3000	0.1544	0.9243	0.3410
MemoryOS	0.5410	0.7047	0.3399	0.5145	0.1248	0.3977	0.2146	0.3299	0.1274	0.3327	0.1162	0.3175	0.3150	<u>0.9733</u>	0.3470
Multimodal Agentic-Memory Systems															
Universal-RAG	<u>0.5858</u>	0.7328	0.4349	0.5769	0.3903	0.4431	0.2938	0.4369	0.2691	<u>0.4872</u>	0.1586	0.5559	0.5367	0.8241	0.4366
RAG-Anything	0.5849	0.6418	0.3940	0.5474	<u>0.4353</u>	0.4465	0.3863	0.4970	<u>0.2782</u>	0.4390	<u>0.1873</u>	<u>0.6201</u>	0.4572	0.8508	0.4481
Mem0 (with vision)	0.4798	0.6457	<u>0.4181</u>	0.5548	0.1511	0.1837	0.4459	0.5607	0.1485	0.3527	0.1286	0.5973	0.1942	0.9176	0.3969
MemVerse	0.4850	0.6406	0.3895	0.5662	0.3229	0.4096	<u>0.4591</u>	0.5613	0.2518	0.4223	0.1849	0.6048	0.5474	0.9042	0.4481
NGM	0.3559	0.5266	0.3453	0.4660	0.1716	0.1601	0.4708	0.5479	0.2288	0.3905	0.1807	0.6060	0.6208	0.9042	0.3813
MIRIX	0.4954	0.6378	0.2853	0.4875	0.4564	0.4949	0.4076	<u>0.5775</u>	0.2999	0.5917	0.1054	0.5375	0.3807	0.8664	<u>0.4560</u>
M ³ Proctor (Ours)	0.4993	0.6924	0.3697	<u>0.5667</u>	0.3952	<u>0.4877</u>	0.4305	0.6063	0.2202	<u>0.4786</u>	0.3021	0.6515	<u>0.5688</u>	0.9844	0.4838

- 基座模型能够很好地处理单会话推理，但在复杂解读任务上遭遇断崖式下跌。例如基座模型在主题推理 (TH) 上仅为 0.064，在隐式推理 (II) 上仅为 0.052；在跨模态推理 (MR) 和文件管理 (FM) 上也表现薄弱。
- 引入外部记忆模块后，可以大幅挽回这些劣势，甚至接近或超越前沿大模型。这说明瓶颈的根源在于不完善的证据管理，而不是基座模型本身不可逾越的天花板，因而是可以通过技术手段解决的。

Experiments



Agent Type	SS		MS		TR		MR		TH		II		FM	FJ	Overall
	F1	LLM	F1	LLM	F1	LLM	F1	LLM	F1	LLM	F1	LLM	EM	EM	
Frontier MLLMs															
🌟 Claude-Opus-4.6	0.2593	0.6050	0.3678	0.5687	0.3754	<u>0.5813</u>	0.5354	0.7306	0.2387	<u>0.6083</u>	0.2412	0.6501	<u>0.2203</u>	0.9443	0.4937
🌀 GPT-5.4	0.5257	<u>0.7623</u>	0.3276	0.6274	0.4975	0.4950	0.4477	0.6389	0.1683	0.4333	0.3227	0.7125	0.1890	0.9621	0.4823
⚡ GLM-5.1	<u>0.5409</u>	0.6510	0.6361	0.6066	0.5142	0.5115	0.5515	0.6550	0.5843	0.6193	0.3735	0.5667	0.1667	0.9332	0.5493
🌀 Qwen3.6-Plus	0.4713	0.6354	0.5907	0.6004	<u>0.5218</u>	0.4799	0.5167	0.6406	0.5325	0.5227	<u>0.3347</u>	0.3833	0.1520	0.9800	<u>0.5049</u>
🌟 Gemini-3.1-Pro-Preview	0.5320	0.7693	0.2991	0.5437	0.4926	0.5404	0.3789	0.5111	0.3161	0.4417	0.2870	<u>0.6875</u>	0.2403	<u>0.9666</u>	0.4668
🌀 Doubao-Seed-2.0-Pro	0.5638	0.2917	<u>0.6330</u>	0.3607	0.6514	0.6437	0.7204	0.6586	<u>0.5480</u>	0.1364	0.3005	0.4103	0.1950	0.9532	0.4938
📺 Kimi-k2.5	0.4269	0.6304	0.3410	0.4536	0.4642	0.5050	<u>0.5614</u>	0.6556	0.1987	0.4351	0.2487	0.5589	0.1308	0.8667	0.4493
🌀 Grok-4	0.4383	0.6211	0.3129	<u>0.6125</u>	0.3259	0.5150	<u>0.3912</u>	<u>0.7034</u>	0.1450	0.3667	0.2322	0.6875	0.1871	0.7923	0.4357
🌀 Qwen-2.5-VL-7B	0.2742	0.5468	0.4587	0.3471	0.4378	0.5063	0.5425	0.4682	0.2461	0.0635	0.1672	0.0523	0.2070	0.7904	0.4179
Text-based Agentic-Memory Systems															
NaiveRAG	0.4430	0.6547	0.3117	0.4429	0.2349	0.4167	0.2080	0.2572	0.1321	0.2806	0.1263	0.3202	0.2569	0.7840	0.3249
A-Mem	0.5921	<u>0.7247</u>	0.3998	0.5345	0.1298	0.1697	0.2403	0.3727	0.1361	0.3493	0.1227	0.2872	0.2875	0.9243	0.3450
Mem0 (w/o vision)	0.5343	0.6957	0.3837	0.5448	0.1361	0.1853	0.2471	0.3787	0.1346	0.3843	0.0962	0.3000	0.1544	0.9243	0.3410
MemoryOS	0.5410	0.7047	0.3399	0.5145	0.1248	0.3977	0.2146	0.3299	0.1274	0.3327	0.1162	0.3175	0.3150	<u>0.9733</u>	0.3470
Multimodal Agentic-Memory Systems															
Universal-RAG	<u>0.5858</u>	0.7328	0.4349	0.5769	0.3903	0.4431	0.2938	0.4369	0.2691	<u>0.4872</u>	0.1586	0.5559	0.5367	0.8241	0.4366
RAG-Anything	0.5849	0.6418	0.3940	0.5474	<u>0.4353</u>	0.4465	0.3863	0.4970	<u>0.2782</u>	0.4390	<u>0.1873</u>	<u>0.6201</u>	0.4572	0.8508	0.4481
Mem0 (with vision)	0.4798	0.6457	<u>0.4181</u>	0.5548	0.1511	0.1837	0.4459	0.5607	0.1485	0.3527	0.1286	0.5973	0.1942	0.9176	0.3969
MemVerse	0.4850	0.6406	0.3895	0.5662	0.3229	0.4096	<u>0.4591</u>	0.5613	0.2518	0.4223	0.1849	0.6048	0.5474	0.9042	0.4481
NGM	0.3559	0.5266	0.3453	0.4660	0.1716	0.1601	0.4708	0.5479	0.2288	0.3905	0.1807	0.6060	0.6208	0.9042	0.3813
MIRIX	0.4954	0.6378	0.2853	0.4875	0.4564	0.4949	0.4076	<u>0.5775</u>	0.2999	0.5917	0.1054	0.5375	0.3807	0.8664	0.4560
M ³ Proctor (Ours)	0.4993	0.6924	0.3697	<u>0.5667</u>	0.3952	<u>0.4877</u>	0.4305	0.6063	0.2202	0.4786	0.3021	0.6515	<u>0.5688</u>	0.9844	0.4838



- M3Proctor在所有智能体记忆系统中取得了最高的综合得分。其性能提升主要集中在基准测试最难的部分，例如在跨模态推理（MR, 0.606 LLM-J）、隐式推理（II, 0.652）和文件管理（FM, 0.569 EM）上均处于领先地位。
- M3Proctor仅仅运行在一个轻量级的7B基座模型上，且需要自己去检索证据，但它的表现却超越了数个直接读取标准证据的前沿大模型。这使其成为一个极具竞争力的、能以极小算力规模匹敌前沿大模型的多模态记忆系统。

Experiments



Agent Type	SS		MS		TR		MR		TH		II		FM	FJ	Overall
	F1	LLM	F1	LLM	F1	LLM	F1	LLM	F1	LLM	F1	LLM	EM	EM	
Frontier MLLMs															
🌟 Claude-Opus-4.6	0.2593	0.6050	0.3678	0.5687	0.3754	<u>0.5813</u>	0.5354	0.7306	0.2387	<u>0.6083</u>	0.2412	0.6501	<u>0.2203</u>	0.9443	0.4937
🌀 GPT-5.4	0.5257	<u>0.7623</u>	0.3276	0.6274	0.4975	0.4950	0.4477	0.6389	0.1683	0.4333	0.3227	0.7125	0.1890	0.9621	0.4823
⚡ GLM-5.1	<u>0.5409</u>	0.6510	0.6361	0.6066	0.5142	0.5115	0.5515	0.6550	0.5843	0.6193	0.3735	0.5667	0.1667	0.9332	0.5493
🌀 Qwen3.6-Plus	0.4713	0.6354	0.5907	0.6004	<u>0.5218</u>	0.4799	0.5167	0.6406	0.5325	0.5227	<u>0.3347</u>	0.3833	0.1520	0.9800	<u>0.5049</u>
🌟 Gemini-3.1-Pro-Preview	0.5320	0.7693	0.2991	0.5437	0.4926	0.5404	0.3789	0.5111	0.3161	0.4417	0.2870	<u>0.6875</u>	0.2403	<u>0.9666</u>	0.4668
🌀 Doubao-Seed-2.0-Pro	0.5638	0.2917	<u>0.6330</u>	0.3607	0.6514	0.6437	0.7204	0.6586	<u>0.5480</u>	0.1364	0.3005	0.4103	0.1950	0.9532	0.4938
📺 Kimi-k2.5	0.4269	0.6304	0.3410	0.4536	0.4642	0.5050	<u>0.5614</u>	0.6556	0.1987	0.4351	0.2487	0.5589	0.1308	0.8667	0.4493
🌀 Grok-4	0.4383	0.6211	0.3129	<u>0.6125</u>	0.3259	0.5150	<u>0.3912</u>	<u>0.7034</u>	0.1450	0.3667	0.2322	0.6875	0.1871	0.7923	0.4357
🌀 Qwen-2.5-VL-7B	0.2742	0.5468	0.4587	0.3471	0.4378	0.5063	0.5425	0.4682	0.2461	0.0635	0.1672	0.0523	0.2070	0.7904	0.4179
Text-based Agentic-Memory Systems															
NaiveRAG	0.4430	0.6547	0.3117	0.4429	0.2349	0.4167	0.2080	0.2572	0.1321	0.2806	0.1263	0.3202	0.2569	0.7840	0.3249
A-Mem	0.5921	<u>0.7247</u>	0.3998	0.5345	0.1298	0.1697	0.2403	0.3727	0.1361	0.3493	0.1227	0.2872	0.2875	0.9243	0.3450
Mem0 (w/o vision)	0.5343	0.6957	0.3837	0.5448	0.1361	0.1853	0.2471	0.3787	0.1346	0.3843	0.0962	0.3000	0.1544	0.9243	0.3410
MemoryOS	0.5410	0.7047	0.3399	0.5145	0.1248	0.3977	0.2146	0.3299	0.1274	0.3327	0.1162	0.3175	0.3150	<u>0.9733</u>	0.3470
Multimodal Agentic-Memory Systems															
Universal-RAG	<u>0.5858</u>	0.7328	0.4349	0.5769	0.3903	0.4431	0.2938	0.4369	0.2691	<u>0.4872</u>	0.1586	0.5559	0.5367	0.8241	0.4366
RAG-Anything	0.5849	0.6418	0.3940	0.5474	<u>0.4353</u>	0.4465	0.3863	0.4970	<u>0.2782</u>	0.4390	<u>0.1873</u>	<u>0.6201</u>	0.4572	0.8508	0.4481
Mem0 (with vision)	0.4798	0.6457	<u>0.4181</u>	0.5548	0.1511	0.1837	0.4459	0.5607	0.1485	0.3527	0.1286	0.5973	0.1942	0.9176	0.3969
MemVerse	0.4850	0.6406	0.3895	0.5662	0.3229	0.4096	<u>0.4591</u>	0.5613	0.2518	0.4223	0.1849	0.6048	0.5474	0.9042	0.4481
NGM	0.3559	0.5266	0.3453	0.4660	0.1716	0.1601	0.4708	0.5479	0.2288	0.3905	0.1807	0.6060	0.6208	0.9042	0.3813
MIRIX	0.4954	0.6378	0.2853	0.4875	0.4564	0.4949	0.4076	<u>0.5775</u>	0.2999	0.5917	0.1054	0.5375	0.3807	0.8664	0.4560
M ³ Proctor (Ours)	0.4993	0.6924	0.3697	<u>0.5667</u>	0.3952	<u>0.4877</u>	0.4305	0.6063	0.2202	0.4786	0.3021	0.6515	<u>0.5688</u>	0.9844	0.4838

- M3Proctor在所有智能体记忆系统中取得了最高的综合得分。其性能提升主要集中在基准测试最难的部分，例如在跨模态推理（MR, 0.606 LLM-J）、隐式推理（II, 0.652）和文件管理（FM, 0.569 EM）上均处于领先地位。
- M3Proctor仅仅运行在一个轻量级的7B基座模型上，且需要自己去检索证据，但它的表现却超越了数个直接读取标准证据的前沿大模型。这使其成为一个极具竞争力的、能以极小算力规模匹敌前沿大模型的多模态记忆系统。




1. M3Exam与其视觉证据紧密耦合:

(a) 衡量了多模态信息提升：即系统通过访问原始多模态证据，相比仅访问其生成的文本替代物所获得的性能增益。虽然整体提升幅度适中，但在强多模态子集上非常显著，在跨模态推理（MR）上达到了 +0.300，在文件管理（FM）上达到了 +0.116，**说明在这些问题上文本替代物无法取代视觉资源。**


(b) 中的能力画像表现出了一致性：系统在跨模态问答上的差异最大，并且在复杂解读任务上依然保持差距（0.570）。**这证实了该基准测试中最难的问题真正取决于多模态证据和隐式推理，而不是对对话文本的词汇匹配。**

Experiments



2. 模态级联机制在且仅在需要视觉的地方触发：(a) 显示，级联机制在视觉类型问题上的触发频率（文件管理 FM 为 68.0%，跨模态推理 MR 为 51.1%）远高于文本类型问题（15%）。**这表明模态偏置检测能够可靠地识别哪些查询需要原始资源。** (b) 证实了这种升级策略精准地在这些地方取得了回报：激活级联机制使文件管理（FM）的答案质量提升了 0.116，跨模态推理（MR）提升了 0.092，而文本类型问题的表现基本保持不变。因此，**级联机制是以选择性的方式提供多模态证据，而不是不加区分地重新喂入数据。**

Experiments



3. **M3Proctor**以纯文本级别的成本，匹敌多模态级别的准确率：(c) 绘制了索引构建时间与单次查询Token消耗的对比图。结果显示，尽管 M3Proctor是一个多模态记忆系统，但其资源占用却落在了纯文本级别的区间内。这比核心多模态基线方法低了一到三个数量级。这是因为原始视觉资源仅在级联机制发生升级的26.4%的查询中才会进入 Prompt。尽管成本极低，M3Proctor依然在所有系统中取得了最高的性能表现，**这证明了模态感知升级（而非不加区分地注入视觉内容）才是带来多模态准确率的关键所在。**

- **可借鉴：** M3Exam构造相关历史的方式（时间线串联事件&滑动窗口生成对话并插入干扰） M3Proctor衡量模态差异，并在检索时引入模态分数，提供多模态信息时按需披露。
- 尽管M3Exam针对的是逼真的多模态用户-智能体交互场景，但当前的基准测试**主要集中在对累积历史进行的单轮问答**（single-turn QA）上。现实世界中的交互往往包含长周期的多轮对话（multi-turn conversations），并伴随着不断演进的意图以及迭代式的记忆更新，这在所有现有的多模态记忆基准测试中仍未得到充分探索。需要进一步将M3Exam**扩展到更具动态性的多轮记忆评估**中。
- 尽管M3Proctor提高了模态感知的多模态检索和推理效率，但它在解读导向型问题上的能力依然有限。在长期多模态交互中，**如何更好地对隐式用户状态进行建模，以及进行更深层次的上下文解读**，仍然是未来工作的重要方向。