



北京大学
PEKING UNIVERSITY

Rethinking On-Policy Distillation

2026-04-15

Rethinking On-Policy Distillation of Large Language Models: Phenomenology, Mechanism, and Recipe

Yaxuan Li^{*1,2}, Yuxin Zuo^{*†1}, Bingxiang He^{*†1}, Jinqian Zhang¹, Chaojun Xiao^{‡1}, Cheng Qian³, Tianyu Yu¹, Huan-ang Gao¹, Wenkai Yang⁴, Zhiyuan Liu^{‡1}, Ning Ding^{‡1}

¹Tsinghua University ²ShanghaiTech University ³University of Illinois Urbana-Champaign ⁴Renmin University of China

*Equal Contribution. †Project Lead. ‡Corresponding Authors.

🔗 Code: <https://github.com/thunlp/OPD>.

✉ hebx24@mails.tsinghua.edu.cn, {xcj,liuzy,dingning}@tsinghua.edu.cn

汇报人：彭天天

汇报日期：2026/07/22



目录

CONTENTS

1 基本信息

2 研究背景

3 研究思路

4 研究结果

5 结论与讨论

6 创新与启发

Rethinking On-Policy Distillation

2026-04-15

Rethinking On-Policy Distillation of Large Language Models: Phenomenology, Mechanism, and Recipe


Yaxuan Li^{*1,2}, Yuxin Zuo^{*†1}, Bingxiang He^{*†1}, Jinqian Zhang¹, Chaojun Xiao^{‡1}, Cheng Qian³, Tianyu Yu¹, Huan-ang Gao¹, Wenkai Yang⁴, Zhiyuan Liu^{‡1}, Ning Ding^{‡1}

¹Tsinghua University ²ShanghaiTech University ³University of Illinois Urbana-Champaign ⁴Renmin University of China

^{*}Equal Contribution. [†]Project Lead. [‡]Corresponding Authors.

🔗 Code: <https://github.com/thunlp/OPD>.

✉ hebx24@mails.tsinghua.edu.cn, {xcj,liuzy,dingning}@tsinghua.edu.cn



知乎: <https://zhuanlan.zhihu.com/p/2023482883415835093>

2.1 研究背景-On Policy Distillation

FKL 与 RKL


教师分布P 学生分布Q

1. Forward KL (Mode-Covering): $D_{KL}(P||Q) = \sum_x P(x) \log \frac{P(x)}{Q(x)}$

从 P 到 Q 的散度, 学生 Q 试图覆盖老师 P 的所有可能性--P(x)有值的地方, Q(x)也必须有值

2. Reverse KL (Mode-seeking): $D_{KL}(Q||P) = \sum_x Q(x) \log \frac{Q(x)}{P(x)}$

从 Q 到 P 的散度, 学生 Q 试图集中于老师 P 的某一分布--P(x)没值的地方, Q(x)也必须没值



基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

2.1 研究背景-On Policy Distillation

不同的KL与不同的轨迹来源，组合成了不同的蒸馏方式

组合	策略 (Policy)	散度 (Divergence)	含义 (学生 Q vs 老师 P)
1. 监督 KD	Off-Policy (老师的轨迹)	Forward KL (模式覆盖)	要求学生模型 (Q) 在老师的轨迹上，覆盖老师模型 (P) 的整个概率分布。
2. GKD (变体)	On-Policy (学生的轨迹)	Forward KL (模式覆盖)	要求学生模型 (Q) 在自己的轨迹上，覆盖老师模型 (P) 的整个概率分布。
3. On-Policy 蒸馏	On-Policy (学生的轨迹)	Reverse KL (模式寻求)	要求学生模型 (Q) 在自己的轨迹上，其输出分布集中于老师模型 (P) 的高概率模式。
4. (罕见组合)	Off-Policy (老师的轨迹)	Reverse KL (模式寻求)	要求学生模型 (Q) 在老师的轨迹上，其输出分布集中于老师模型 (P) 的高概率模式。

全词表形式的OPD Loss:
$$\text{KL}(\pi_{\theta} || \pi_{\text{teacher}}) = \mathbb{E}_{x \sim \pi_{\theta}} \left[\log \pi_{\theta}(x_{t+1} | x_{1..t}) - \log \pi_{\text{teacher}}(x_{t+1} | x_{1..t}) \right]$$

序列级Loss, 逐token平均:
$$\mathcal{L}_{\text{OPD}}(\theta) = \mathbb{E}_{x \sim \mathcal{D}_x, \hat{y} \sim \pi_{\theta}(\cdot | x)} \left[\sum_{t=1}^T D_{\text{KL}}(p_t || q_t) \right].$$

OPD相比于其它后训练方法的核心优势: 监督信号密集+on-policy->效率高, 效果好
但是在实战中, OPD训出来的模型往往效果不好, why? 本文剖析了OPD的实验现象与机制, 并提出了一些实用建议

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

3 研究思路：现象--机制--方法

现象：OPD成功的两个前提条件——**老师和学生要有相容的思维模式** (thinking pattern)，以及老师必须给学生**带来真正新的知识**，而不只是同一套训练数据在更大模型上的另一个版本。

机制：成功的OPD训练过程中，学生和老师在**高概率token上的overlap ratio会持续扩大**，这些overlap token承载了97%到99%的概率质量，也集中了几乎全部有效的梯度信号。

方法：先SFT预对齐后OPD；使用与教师相同的template。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

📖 Paper Overview

When does OPD succeed or fail?

📊 Phenomenology (§3)

Two empirical patterns distinguish effective OPD:

- Thinking-pattern consistency
- Higher scores $\neq$ new knowledge



Why does OPD work at token level?

⚙️ Mechanism (§4)

Progressive alignment on high-prob tokens governs OPD.

- Overlap tokens grow steadily
- Overlap tokens alone suffice



How to rescue failing OPD?

🧪 Recipe (§5)

Two strategies bridge the thinking-pattern gap:

- Off-policy cold start
- Teacher-aligned prompts

4.1 现象：什么样的学生-教师组合才能得到成功的OPD?

- Thinking pattern要一致**

student: Qwen3-1.7B-Base

teacher: Qwen3-4B vs Qwen3-4B-Base-GRPO

单看数学，Qwen3-4B-Base-GRPO的表现不如Qwen3-4B（右图）。但蒸馏结果（下图）却恰恰相反，跟随 GRPO 老师训练的学生模型最终获得了更显著的性能提升--因为后者输出top-k分布与学生更接近，更能传递有效信号





Figure 3 | Validation performance of the two teachers (Qwen3-4B Non-thinking vs. Qwen3-4B-Base-GRPO) on AIME 2024, AIME 2025, and AMC 2023.



更强的教师不一定带来更好的蒸馏结果

$$\mathcal{M}_{\text{overlap}} \triangleq \mathbb{E}_t \left[\frac{|S_t^{(p)} \cap S_t^{(q)}|}{k} \right].$$

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

4.1 现象：什么样的学生-教师组合才能得到成功的OPD?

- teacher要有新知识，而高分 $\neq$ 新知识

student: DeepSeek-R1-Distill-Qwen-1.5B

teacher: DeepSeek-R1-Distill-Qwen-7B vs Skywork-OR1-Math-7B

student: Qwen3-1.7B

teacher: Qwen3-4B vs Qwen3-4B-RL

基本信息



研究背景

研究思路

研究结果

结论与讨论

创新与启发



分析：单纯teacher规模增大，但预训练数据和配方不变，带来的提升很小。
经过RL后训练后的teacher模型能带来明显提升。

单纯这个实验还不足以说明"新知识"的重要性--RL后的模型本来就比原教师模型强, OPD效果更好难道不是应该的么 (在thinking pattern一致的前提下, 此处并未研究top-k overlap ratio)?

4.1 现象：什么样的学生-教师组合才能得到成功的OPD?

- teacher要有新知识，而高分 $\neq$ 新知识

反向蒸馏实验：

学生：JustRL-1.5B

教师：RL之前的base model (R1-Distill-1.5B) vs R1-Distill-7B（跑分比JustRL-1.5B更高）




Figure 5 | Reverse distillation with JustRL-1.5B as the student and two same-family teachers (R1-Distill-1.5B and R1-Distill-7B). Both runs cause the student to regress to approximately the same level despite R1-Distill-7B scoring higher than JustRL-1.5B, indicating that OPD training dynamics are governed by thinking pattern rather than benchmark performance.

分析：OPD后都导致JustRL-1.5B出现性能下降——俩教师出自相同的训练数据和方案，思考模式类似，且R1-Distill-7B甚至强于学生模型。但是都没有新知识，导致了学生“遗忘”了RL所学到的新知识，退化为原始水平。

结论：OPD 并不是在单纯地“学习高分”，而是在主动提取并复刻 teacher 的概率分布模式。思维模式的一致性保证了这种复刻的可行性，而 teacher 侧真实的增量知识则决定了复刻带来的性能上限。

基本信息

研究背景

研究思路

研究结果

结论与讨论


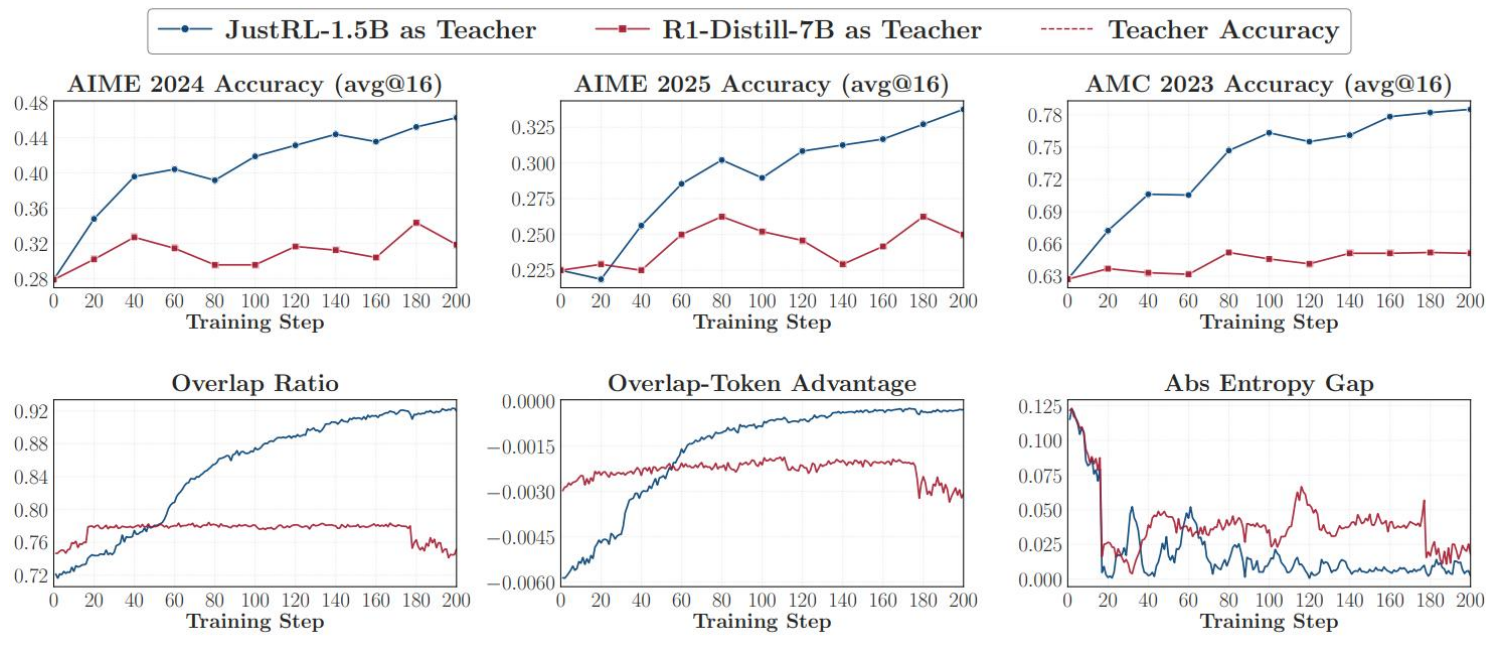
创新与启发

4.2 机制：OPD过程中，token-level发生了什么？

- 教师与学生的overlap ratio不断提高——说到一块去了

学生：R1-Distill-1.5B

教师：JustRL-1.5B vs R1-Distill-7B（跑分比JustRL-1.5B更高）



成功的OPD组合：稳定的overlap ratio上升，overlap-token的优势值缩小，教师-学生熵差距缩小

解释：学生在自己生成的轨迹上，逐步定位到教师也偏好的高概率 Token，而且正在精确校准自身在这些 Token 上的概率，使之与老师保持一致。反观 7B Teacher的失败对照组，这三个指标从一开始就陷入停滞，几乎没有变化。统计后发现，师生重合的 Top-k Token 在词表中只占极小的一部分，但实际承载了96%以上的概率质量（Probability Mass）。这说明，OPD核心是高概率 Token 的对齐。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发


4.2 机制：OPD过程中，token-level发生了什么？

- 消融实验：高概率token的对齐对应了OPD的成功

学生：R1-Distill-1.5B

教师：JustRL-1.5B

把 Top-k 监督信号拆解成两部分：仅在overlap的 Token 上计算蒸馏损失（Overlap Top-k），只在双方不重合的 Token 上计算损失（Non-Overlap Top-k）。



结果：仅在 Overlap Token 上进行优化，就足以完整 OPD 的效果！而在 Non-Overlap Token 训练的模型性能则大幅落后--说明 OPD 的绝大部分有效梯度来自于双方都已经认可的“高概率Overlap Token 集合”，进行精准地概率权重的调整。那些Non-Overlap Token，其实并没有贡献多少有价值的优化信号。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

4.2 机制：OPD过程中，token-level发生了什么？

- 消融实验：高概率token的对齐对应了OPD的成功

小结：

overlap率高--师生在初始阶段的思维模式重合时，老师能够在这些高概率质量的token上进行打分（Reverse-KL 优化）。

教师具有新知识--教师能够在这些overlap token上给出更有学习意义的打分信号。

良性循环：overlap ratio不断提高，边缘 Token 被“挤出”学生的 Top-k 集合 -> 优化信号又因为重合区的扩大而变得更加纯粹和稳定->...

相反，如果初始阶段师生的思维模式严重错位，重合区太小，或者老师在重合区内无法提供高于学生的“新知识”信号，这个飞轮就会从一开始卡死，从而导致我们在失败组里看到的停滞现象。

理清了这套微观机制后，一个非常实际的问题自然浮现：

既然初始的重合度（Overlap Ratio）如此重要，那么当我们拿到一个和学生思维模式差异很大、但又确有真才实学的强力 Teacher 时，能否通过某种工程手段，人为地帮它们把这个“飞轮”先转起来？

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

4.3 方法：如何修复失败的OPD?









- 先SFT冷启动，让学生与教师拥有相似的思维模式

学生：Qwen3-1.7B-Base vs Qwen3-1.7B-Base-SFT

教师：Qwen3-4B

先用Qwen3-4B 离线生成一批回答，对 student (Qwen3-1.7B-Base) 做一次 SFT，强行把学生的生成偏好往teacher的thinking pattern上拽。然后再启动正式的 OPD 训练。

— Qwen3-1.7B-SFT as Student (SFT+OPD) — Qwen3-1.7B-Base as Student (Only OPD)



实验结果：经过 SFT 冷启动的 student 在各项 Benchmark 上都明显更高。

从微观指标分析来看，SFT 直接拉高了训练初始阶段的 Overlap Ratio，降低低了师生之间的熵差距，且一开始Overlap token 的概率质量就能稳稳覆盖teacher高概率的核心区域。这就好比学生提前预习了老师的讲课风格。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

4.3 方法：如何修复失败的OPD?

- 使用与教师相同的后训练prompts

学生：R1-Distill-1.5B

教师：Just-RL-1.5B

DAPO数据集的
原始prompt:


Original DAPO Template

Solve the following math problem step by step. The last line of your response should be of the form Answer: \$Answer (without quotes) where \$Answer is the answer to the problem. {Question} Remember to put your answer on its own line after "Answer:".

Just-RL-1.5B训
练用的prompt:

Teacher-Aligned Template

{Question} Please reason step by step, and put your final answer within \boxed{ }.



结果：使用和教师相同的prompt，训出来的学生模型表现更好，且训练过程中overlap ratio更高

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

4.4 一些其它实验结果

- on-policy带来的负面影响：学生将教师带入不熟悉的地方**

左：设置训练时不同的最大生成长度，发现中等长度最佳（3k-7k）。过短监督信号不够，未监督到关键推理过程；过长，教师越不熟悉当前轨迹，提供的监督信号不准确。

右：在不同长度的学生生成的前缀上，由教师进行续写，看续写带来的准确率提升——越长的前缀，提升越小，说明教师被带偏了，拉不回来。





Figure 11 | (a) Validation accuracy on three benchmarks under different response lengths. (b) Accuracy gain from teacher continuation under different student prefix truncation lengths.



From: The Many Faces of On-Policy Distillation: Pitfalls, Mechanisms, and Fixes

基本信息

研究背景

研究思路

研究结果


结论与讨论

创新与启发

4.4 一些其它实验结果

- 损失的Top-K近似，不同K取值的影响

区别不大，但是top-1明显更差



另一篇文章The Many Faces of On-Policy Distillation: Pitfalls, Mechanisms, and Fixes中分析了top-k估计全词表导致的bias，并提出了一些loss设计上的修正方法

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

5 结论与讨论

结论:

现象: OPD成功的两个前提条件——**老师和学生要有相容的思维模式** (thinking pattern), 以及老师必须给学生**带来真正新的知识**, 而不只是同一套训练数据在更大模型上的另一个版本.

机制: 成功的OPD训练过程中, 学生和老师**在高概率token上的overlap ratio会持续扩大**, 这些overlap token承载了97%到99%的概率质量, 也集中了几乎全部有效的梯度信号.

方法: 先SFT预对齐后OPD; 使用与教师相同的template.

讨论:

本文实验在较小模型上进行, 且模型对选取较少, 结论可能片面, 需要更多实验支持。

启发: 在做OPD相关实验的时候, 要注意

1. Loss实现是否有偏
2. 教师和学生模型的选择比较重要 (但是通常是通过实验去选了才知道哪个好..)
3. 在OPD之前先进行一轮SFT能显著提升效果

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

6 相关资源

OPD codebase:

Rethink OPD: <https://github.com/thunlp/OPD> (基于verl0.7.0版本改的)

verl0.8.0版本已支持OPD算法: <https://github.com/verl-project/verl>

ms-swift最新版本支持OPD算法

其它OPD相关论文的codebase...

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

论文:

- token-level重加权:

Entropy-Aware On-Policy Distillation of Language Models

Tailoring Teaching to Aptitude: Direction-Adaptive Self-Distillation for LLM Reasoning

TIP: Token Importance in On-Policy Distillation

- 多模态OPD:

Vision-OPD: Learning to See Fine Details for Multimodal LLMs via On-Policy Self-Distillation

Visual-Advantage On-Policy Distillation for Vision-Language Models

- 机理分析

The Many Faces of On-Policy Distillation: Pitfalls, Mechanisms, and Fixes

ROSD: Reflective On-Policy Self-Distillation for Language Model Reasoning across Domains

- 特权信息 (PI) OPD, 如自蒸馏, 自进化等
- Agent OPD...