



北京大学
PEKING UNIVERSITY

Co-Evolving Policy Distillation

协同进化策略蒸馏

汇报人：李宏扬

汇报日期：2026/07/29

目录

CONTENTS

1 基本信息

2 研究背景

3 研究思路

4 研究结果

5 结论与讨论



Co-Evolving Policy Distillation

Naibin Gu^{1,2,*}, Chenxu Yang^{1,2,*}, Qingyi Si^{3,*}, Chuanyu Qin^{1,2}, Dingyu Yao^{1,2}
Peng Fu^{1,2,†}, Zheng Lin^{1,2}, Weiping Wang¹, Nan Duan³, Jiaqi Wang³

¹Institute of Information Engineering, CAS, ²School of Cyber Security, UCAS, ³JD.COM

*Equal contribution., †Corresponding author.

Abstract

RLVR and OPD have become standard paradigms for post-training. We provide a unified analysis of these two paradigms in consolidating multiple expert capabilities into a single model, identifying capability loss in different ways: mixed RLVR suffers from inter-capability divergence cost, while the pipeline of first training experts and then performing OPD, though avoiding divergence, fails to fully absorb teacher capabilities due to large behavioral pattern gaps between teacher and student. We propose **Co-Evolving Policy Distillation (CoPD)**, which encourages parallel training of experts and introduces OPD during each expert's ongoing RLVR training rather than after complete expert training, with experts serving as mutual teachers (making OPD bidirectional) to co-evolve. This enables more consistent behavioral patterns among experts while maintaining sufficient complementary knowledge throughout. Experiments validate that CoPD achieves all-in-one integration of text, image, and video reasoning capabilities, significantly outperforming strong baselines such as mixed RLVR and MOPD, and even surpassing domain-specific experts. The model parallel training pattern offered by CoPD may inspire a novel training scaling paradigm.

Correspondence: gunaibin@iie.ac.cn; fupeng@iie.ac.cn; siqingyi.phoebus@jd.com

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发



OPD(On-Policy Distillation) 在线策略蒸馏

- 一种改进的知识蒸馏技术，旨在解决传统离线蒸馏中的“暴露偏差”问题。教师模型直接针对学生实际生成的内容提供逐 token 的密集监督，从而实现了一种迭代式的在线校正

Teacher: It's an **apple** on the **tree**

Student: It's an **egg** on the **table**

对于学生预测next-token与教师不同的情况，对两个句子的每一处token计算损失，未对齐的token（如**apple-egg**）提供更大的损失，基于该损失进行反向传播，调整学生的概率分布，对齐教师整个词汇表的概率分布形状

$$\min_{\theta} \mathcal{L}_{KD}(\theta) = \sum_{t=1}^T D_{KL}(q_t \parallel p_{\theta,t})$$

优化目标为**最小化教师与学生分布的 KL 散度之和** [这等价于教师和学生输出一致性最高]

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

RLVR

基于可验证反馈的强化学习

RLVR 是大模型后训练阶段的自动化对齐范式，通过标准答案为模型生成的推理、执行轨迹提供客观可量化的奖励信号

工作流程

同策略轨迹采样：基于当前模型批量生成多条任务轨迹（如数学解题路径）

自动化奖励校验：验证器通过答案匹配、单元测试等客观规则，输出逐轨迹 / 逐步骤奖励

策略梯度更新：基于采样轨迹与对应奖励，通过 GRPO/PPO 等算法更新模型策略，迭代优化任务表现

常与同策略蒸馏（OPD）组合构建后训练流水线：OPD 快速迁移基础推理范式；RLVR 进一步突破教师模型能力上限，实现性能跃升。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

多能力RL面临的问题

RLVR已成为提升模型推理能力的主流范式

然而，当研究人员试图将多种专家能力（如文本推理、图像推理、视频理解）整合到一个模型中时，传统的训练方法面临着明显的局限性：

直接混合多领域数据进行 RLVR 训练会引发“能力分歧”，导致不同能力之间相互干扰；

而先分别训练领域专家，再通过多教师同策略蒸馏（MOPD）进行合并的静态流水线，又会因为教师和学生行为模式上偏离过远，导致吸收效率低下，最终无法逼近任一教师。



(a) GRPO



(b) OPD

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发



Co-Evolving Policy Distillation

Naibin Gu^{1,2,*}, Chenxu Yang^{1,2,*}, Qingyi Si^{3,*}, Chuanyu Qin^{1,2}, Dingyu Yao^{1,2}
Peng Fu^{1,2,†}, Zheng Lin^{1,2}, Weiping Wang¹, Nan Duan³, Jiaqi Wang³

¹Institute of Information Engineering, CAS, ²School of Cyber Security, UCAS, ³JD.COM

*Equal contribution., [†]Corresponding author.

为了解决这一困境，作者提出了一种名为协同进化策略蒸馏（Co-Evolving Policy Distillation, CoPD）的新范式。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

多任务学习的统一表述

为了统一多种多任务学习方法的效果，作者提出一下表述

假设需要将两种能力（分别由数据集 D_1 和 D_2 代表）整合到一个统一策略中。令 $X(D_1, D_2)$ 表示这两个数据集中包含的总优化信号，即如果两个数据集的信号能够被完美应用于统一策略，所能实现的理想能力增益。作者用以下公式来描述特定范式 $\mathcal{P}$ 的实际效用 $U_{\mathcal{P}}$ ：

$$U_{\mathcal{P}} \approx a_{\mathcal{P}} \cdot X(D_1, D_2) + b_{\mathcal{P}}$$

其中， $a_{\mathcal{P}} \in [0, 1]$ 衡量范式 $\mathcal{P}$ 将理想信号 X 转化为实际能力的有效性（吸收率），而 $b_{\mathcal{P}} \leq 0$ 捕获了范式在不完美转化之外引入的额外损失。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发



局限一

混合数据 RLVR: 作为冲突的能力分歧 当单一模型在 $D_1 \cup D_2$ 上联合优化时, 每步更新的梯度是两个数据集诱导梯度的平均值。由于不同能力倾向于不同的优化方向, 它们的梯度在特定能力的维度上存在分歧, 这种分歧表现为参数更新中的梯度冲突。其效用可表示为:

$$U_{\text{mix}} \approx X(D_1, D_2) - \Phi(D_1, D_2)$$

其中 $\Phi(D_1, D_2) > 0$ 是**能力分歧成本**, 即两种能力优化方向冲突的幅度。

混合数据 RLVR 以“跷跷板效应”支付这一成本: 无论如何调整数据混合比例, 一种能力上的增益总是被另一种能力的干扰所部分或全部抵消。

$$U_{\mathcal{P}} \approx a_{\mathcal{P}} \cdot X(D_1, D_2) + b_{\mathcal{P}}$$

在统一公式中, 这对应于 $a_{\text{mix}} = 1$ 且 $b_{\text{mix}} = -\Phi < 0$ 。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发



局限二:

静态 OPD 流水线: 避免了分歧, 但吸收率低下

静态流水线通过隔离训练每个专家避免梯度冲突, 因此分歧成本被消除。代价转移到了整合阶段。在 OPD 步骤中, 学生模型在其自身的同策略轨迹上进行训练, 教师模型 在每个访问过的状态处提供词元级别的监督:

$$\mathcal{L}_{\text{OPD}}(\theta) = \mathbb{E}_{x, y \sim \pi_{\theta}} \left[\frac{1}{|y|} \sum_{t=1}^{|y|} D_{\text{KL}}(\pi_T(\cdot | x, y_{<t}) \parallel \pi_{\theta}(\cdot | x, y_{<t})) \right]$$

作者指出, 当教师和学生同策略轨迹上表现相似时, 上述公式中的监督最有效。此时, 两者的词元分布大量重叠, 教师的预测能够强化学生本来就有可能生成的词元。

然而, 当多专家在隔离状态下训练至收敛时, 它们的行为已经偏离了共享的基础模型, 其在学生轨迹上的预测与学生自身的预测差异巨大。在这种不匹配下, OPD 信号变得难以吸收, 只有一小部分优化信号被传递。其效用形式为:

$$U_{\text{static}} \approx \eta(\mathcal{O}_{\text{low}}) \cdot X(D_1, D_2)$$

其中 $\eta(\mathcal{O}) \in [0, 1]$ 是依赖于师生行为重叠度 $\mathcal{O}$ 的**吸收效率函数**, $\mathcal{O}_{\text{low}}$ 表示专家在隔离收敛后产生的低重叠度。这对应于 $a_{\text{static}} = \eta(\mathcal{O}_{\text{low}})$ (一个较小的正值), 且 $b_{\text{static}} = 0$ 。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

3 研究思路

为了使上述分析可测试，作者提出了**行为一致性假设**（Behavioral consistency hypothesis）：当教师和学生表现出更相似的行为模式时，OPD 信号更容易被吸收，因为它们的同策略轨迹会访问相似的状态，且教师的预测与学生倾向于生成的词元更加一致。

作者通过同策略轨迹上的 **Top- k 词元重叠度**（Top- k token overlap）来实例化这种行为相似性。给定教师 π_T 和学生 π_θ ，定义如下：

$$\mathcal{O}_k(\pi_\theta, \pi_T) = \mathbb{E}_{x, y_{<t} \sim \mu_\theta} \left[\frac{|\text{Top}_k(\pi_\theta(\cdot \mid x, y_{<t})) \cap \text{Top}_k(\pi_T(\cdot \mid x, y_{<t}))|}{k} \right]$$

其中 $\text{Top}_k(\cdot)$ 表示预测概率最高的 k 个词元的集合， μ_θ 是由学生诱导的状态访问分布。较大的 $\mathcal{O}_k$ 表明在学生实际访问的状态下，教师和学生对哪些词元可能出现持有相同的看法。

作者设计了两个互补的实验来验证上述假设。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

3 研究思路

基本信息


研究背景

研究思路

研究结果

结论与讨论

创新与启发



实验 1：吸收效率 η 随师生重叠度上升 作者固定了一个教师模型（在图像数据上通过 RLVR 获得的专家），并通过使用不同的采样温度对基础模型进行短期训练，构造了一系列与教师具有不同 $\mathcal{O}_k$ 值的学生模型。对每个学生，在相同的预算下进行 OPD 训练，并记录蒸馏前后的能力增益。

结果显示，OPD 后的增益随 $\mathcal{O}_k$ 单调增加，呈现出强线性相关性。这直接支持了行为一致性假设：即使教师固定，行为上更对齐的学生也能更有效地吸收 OPD 信号。当然，如果 $\mathcal{O}_k \rightarrow 1$ ，师生变得无法区分，KL 散度趋于零，OPD 增益必然崩溃。因此，有效的范式必须主动维持师生之间非平凡的行为差距，同时防止差距过大。

3 研究思路

基本信息



研究背景

研究思路

研究结果

结论与讨论

创新与启发



实验 2：标准 RLVR 会将行为重叠度推向低 η 区域 作者测试了静态流水线是否能将 OPD 保持在高 η 区域。他们从共享的基础模型 π_0 初始化，分别在文本数据和图像数据上独立训练两个专家。在固定的间隔内，测量每个专家在同策略轨迹上与 π_0 的 Top- k 重叠度和对称 KL 散度。

结果表明，随着 RLVR 的进行，与共享基础模型的 $\mathcal{O}_k$ 单调下降，而对称 KL 散度上升了一个数量级。这意味着，当专家收敛时，它们已经远离了共享基础模型，其重叠度远低于实验 1 中 η 最高的水平。这证实了静态流水线系统性地运行在低 η 区域。

3 研究思路

基本信息




研究背景

研究思路

研究结果

结论与讨论

创新与启发




方法设计的启示： 为了提高吸收效率，(i) 蒸馏必须在专家训练期间发生，而不是之后；(ii) 教师必须随着学生的进化而继续进化，以主动维持行为重叠；(iii) 特定能力的训练必须继续推开双方的距离，确保监督信号保留学生尚未掌握的信息。

3 研究思路

3. 协同进化策略蒸馏 (CoPD) 方法设计

基于上述启示, 作者提出了 CoPD 框架。以双分支为例, 给定基础模型 π_0 , CoPD 初始化两个平行的学习分支 π_{θ_j} 和 π_{θ_k} , 初始参数 $\theta_j^{(0)} = \theta_k^{(0)} = \theta_0$, 分别关联能力数据集 $\mathcal{D}_j$ 和 $\mathcal{D}_k$ 。训练在两个阶段之间交替进行。



基本信息

研究背景

研究思路

研究结果

结论与讨论


创新与启发

3 研究思路

3.1 分支特定的 RLVR 阶段

在 RLVR 阶段，每个分支 k 独立地在对应能力的数据上执行 GRPO，以深化特定领域的专业知识。对于提示 $x \sim \mathcal{D}_k$ ，分支 k 从其当前策略 π_{θ_k} 中采样一组轨迹 $\{y_i^{(k)}\}_{i=1}^G$ ，这些轨迹由特定能力的奖励函数 r_k 进行评估。分支 k 的 RLVR 目标定义为：

$$\mathcal{L}_{\text{RLVR}}^{(k)}(\theta_k) = \mathbb{E}_{x \sim \mathcal{D}_k} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|y_i|} \sum_{t=1}^{|y_i|} \min \left(\rho_{i,t}^{(k)} \hat{A}_i^{\text{RL}}, \text{clip}(\rho_{i,t}^{(k)}, 1 - \epsilon, 1 + \epsilon) \hat{A}_i^{\text{RL}} \right) \right]$$



其中 $\hat{A}_i^{\text{RL}}$ 是组内标准化的优势值， $\rho_{i,t}^{(k)}$ 是重要性采样比率。这一阶段逐渐将两个分支推向不同的能力前沿，在它们之间打开一个知识差距，供后续的相互蒸馏利用。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发



3 研究思路


3.2 相互 OPD 阶段

在相互蒸馏阶段，每个分支在另一个分支的数据上生成同策略轨迹，并接收来自该分支的词元级监督。由于两个分支从相同的基础模型起步，并定期通过蒸馏对齐，它们的策略在整个训练过程中保持行为上的接近，因此监督信号落在每个分支都熟悉且易于吸收的状态上。

具体而言，分支 k 从分支 j 的数据集采样提示 $x' \sim \mathcal{D}_j$ ，并从 $\pi_{\theta_k}(\cdot | x')$ 生成轨迹。分支 j 随后在词元级别评估这些轨迹。在位置 t ，教师信号定义为：

$$\delta_{i,t}^{(k \leftarrow j)} = \log \pi_{\theta_j}(y_{i,t}^{(k)} | x', y_{i,<t}^{(k)}) - \log \pi_{\theta_k}(y_{i,t}^{(k)} | x', y_{i,<t}^{(k)})$$

跨分支更新的词元级优势值为 $\hat{A}_{i,t}^{(k)} = \beta_k \delta_{i,t}^{(k \leftarrow j)}$ ，其中 β_k 平衡跨分支蒸馏的相对贡献。关键在于，分支特定的 RLVR 在相互 OPD 期间并不暂停，而是交错进行。两个分支在每一步都交替扮演教师和学生的角色。



基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

3 研究思路

3.3 交替训练流程

CoPD 将上述两个阶段组织成 N 个交替周期。在每个周期 $n = 1, \dots, N$ 中, 所有分支依次执行:

阶段 I: 分支特定的 RLVR。 每个分支 k 在其自身数据上执行 S_{RL} 步 GRPO:

$$\theta_k^{(n, \text{I})} = \text{RLVR}(\theta_k^{(n-1)}; \mathcal{D}_k, r_k, S_{\text{RL}})$$

阶段 II: 相互 OPD。 每个分支 k 执行 S_{OPD} 步相互蒸馏:

S_{RL} 和 S_{OPD} 决定了两个阶段之间的节奏。较大的 S_{RL} 允许分支积累更多差异化的发现, 较大的 S_{OPD} 导致更彻底的知识转移。由于所有分支保持紧密耦合, 它们的参数不会发生剧烈发散。训练结束后, 通过简单的参数合并 (Parameter Merging) 即可获得最终的统一模型:

$$\theta^* \leftarrow \text{Merge}(\theta_0, \theta_1, \dots, \theta_{K-1})$$

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

3 研究思路

3.4 实验设置

训练数据与基准测试 作者在双能力分支（文本和图像推理）和能力三支（引入视频推理）设置下评估了 CoPD。

文本推理：使用 Polaris-Dataset-53K，包含高质量数学推理问题。评估基准包括 AIME 2024、AIME 2025、HMMT 2025、MATH-500 和 Minerva Math。

图像推理：使用 MMFineReason-123K。评估基准包括 MMMU、MMMU-Pro、MathVista、MathVision、ZeroBench、WeMath 和 MathVerse。

视频推理：收集并过滤了 40K 中等难度的样本。评估基准包括 Video-Holmes、MVBench、MMVU 和 VideoMathQA。

模型与基线 实验基于 Qwen3-VL-4B-Instruct 模型。对比基线包括：

Text-Expert / Image-Expert / Video-Expert：在各自领域数据上独立通过 RLVR 训练的专家模型。

Mixed RLVR：将所有数据混合到一个池中训练单一模型。

Static OPD ($V \rightarrow T$ / $T \rightarrow V$)：先独立训练专家，然后将一个专家作为固定教师，向另一个分支进行单向 OPD。

MOPD：在三支设置中，所有领域专家联合蒸馏到一个学生模型中。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

4 研究结果

Benchmark	Base	Image-Expert	Text-Expert	Mixed RLVR	OPD _{V→T}	OPD _{T→V}	CoPD
<i>Image Reasoning</i>							
MMMU	65.06	65.28	65.72	66.39	65.94	67.50	66.94
MMMU-Pro	53.03	53.89	53.05	54.28	54.09	54.71	55.10
MathVista	73.20	75.10	73.90	75.10	74.20	76.05	75.75
MathVision	55.07	55.69	55.82	56.96	55.82	56.53	57.88
ZeroBench _{sub}	21.41	21.41	22.01	21.86	21.41	21.71	24.40
WeMath	52.38	59.14	55.24	57.43	60.95	58.86	59.81
MathVerse	57.82	59.84	58.41	57.81	59.50	59.71	58.88
Avg.	54.00	55.76	54.88 [†]	55.69	55.99	56.44	56.97
<i>Text Reasoning</i>							
AIME 2025	46.88	47.50	48.33	44.58	43.54	45.42	49.58
AIME 2024	58.96	55.83	60.21	57.92	59.79	58.33	60.42
HMMT 2025	25.83	21.67	27.50	24.17	25.83	26.67	30.83
MATH-500	92.80	93.90	93.65	93.55	93.45	93.40	94.50
Minerva Math	54.41	58.64	59.74	57.17	58.55	56.62	58.46
Avg.	55.78	55.51	57.89	55.48 [†]	56.23	56.09	58.76
Overall Avg.	54.74	55.65	56.13	55.60 [†]	56.09	56.29	57.71

表 1 展示了文本和图像推理的主要结果。CoPD 在所有基线中取得了最佳的整体性能

能力分歧的验证：与 Text-Expert (57.89%) 相比，Mixed RLVR 在文本推理上的表现下降至 55.48%，证实了联合优化异构数据会产生跨领域干扰。

静态 OPD 的局限性：静态 OPD 避免了这种干扰。在 $V \rightarrow T$ 方向，图像和文本推理均优于 Mixed RLVR，但文本推理 (56.23%) 仍远低于 Text-Expert。在 $T \rightarrow V$ 方向，尽管图像推理受益于文本专家的指导，但 **Text-Expert** 强大的文本能力在蒸馏后的模型中仅保留了 56.09%。这表明，由于专家偏离学生太远，教师的大部分知识未能通过事后蒸馏传递给学生。

CoPD 的优势：相比之下，CoPD 同时提升了图像推理 (56.97%) 和文本推理 (58.76%)，在两侧均超越了专门针对单一领域训练的专家模型，实现了真正的互利共赢。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

4 研究结果

Benchmark	Base	Image-Expert	Text-Expert	Video-Expert	Mixed RLVR	MOPD	CoPD
<i>Image Reasoning</i>							
MMMU	65.06	65.28	65.72	66.17	66.11	66.61	67.78
MMMU-Pro	53.03	53.89	53.05	53.08	54.06	54.64	55.12
MathVista	73.20	75.10	73.90	74.85	75.55	74.75	76.80
MathVision	55.07	55.69	55.82	55.30	56.00	56.99	57.57
ZeroBench _{sub}	21.41	21.41	22.01	22.01	22.60	22.75	23.35
WeMath	52.38	59.14	55.24	53.43	59.05	59.90	59.90
MathVerse	57.82	59.84	58.41	58.16	59.82	58.93	59.34
Avg.	54.00	55.76	54.88	54.71 [†]	56.17	56.37	57.12
<i>Text Reasoning</i>							
AIME 2025	46.88	47.50	48.33	47.29	45.62	46.04	49.38
AIME 2024	58.96	55.83	60.21	56.46	54.17	60.83	60.42
HMMT 2025	25.83	21.67	27.50	30.83	25.83	25.00	31.67
MATH-500	92.80	93.90	93.65	93.45	92.95	93.85	94.35
Minerva Math	54.41	58.64	59.74	56.16	58.36	58.27	57.35
Avg.	55.78	55.51	57.89	56.84	55.39 [†]	56.80	58.63
<i>Video Reasoning</i>							
Video-Holmes	43.28	44.47	42.19	45.35	45.62	43.33	43.77
MVBench	68.27	67.82	65.73	70.86	67.88	67.71	69.16
MMVU(mc)	64.00	67.68	67.04	67.84	69.28	68.80	68.16
VideoMathQA	49.33	53.10	47.19	50.95	55.71	53.43	55.76
Avg.	56.22	58.27	55.54 [†]	58.75	59.62	58.32	59.21
Overall Avg.	55.11	56.31	55.98 [†]	56.39	56.79	56.99	58.12

表 2 将 CoPD 扩展到三分支设置。结果趋势与表 1 一致：CoPD 取得了最佳的整体性能（58.12%），并在主要能力组上优于 MOPD。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

4 研究结果

Method	Image Reasoning								Text Reasoning						All
	MMMU	M-P.	Vista	Vision	ZB _s	WeM.	Verse	Avg.	A'25	A'24	H'25	M500	Min.	Avg.	
CoPD	66.94	55.10	75.75	57.88	24.40	59.81	58.88	56.97	49.58	60.42	30.83	94.50	58.46	58.76	57.71
w/o I-OPD	67.39	55.49	75.30	57.35	21.71	61.71	58.50	56.78	47.50	59.79	29.17	93.25	57.35	57.41	57.04
w/o T-OPD	66.00	54.78	75.00	57.66	22.01	61.33	58.59	56.48	49.38	57.71	28.33	94.10	59.38	57.78	57.02
Text-Branch Only	65.83	54.25	76.10	56.86	24.85	57.62	58.28	56.26	48.96	62.08	30.83	93.85	57.35	58.61	57.24
Image-Branch Only	65.39	54.82	76.15	56.99	24.40	60.29	59.39	56.78	49.38	59.58	25.00	94.10	57.81	57.17	56.94

组件消融：表 3 研究了 CoPD 中各组件的贡献。

移除 I-OPD（来自图像分支的蒸馏）导致文本推理从 58.76% 降至 57.41%；

移除 T-OPD 导致图像推理从 56.97% 降至 56.48%。这证实了双向相互 OPD 的必要性。

作者还对合并（Merge）操作进行了消融。即使不进行合并，仅保留文本分支或图像分支，其单分支的整体性能（57.24% 和 56.94%）也已经超越了表 1 中的静态 OPD 变体，**表明协同进化本身就能产生能力全面的分支。合并操作进一步巩固了互补优势。**

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发



4 研究结果

基本信息




研究背景

研究思路

研究结果

结论与讨论

创新与启发



训练期间的行为模式一致性：图 4 (a) 和 (b) 追踪了训练期间两个分支之间的 Top-k 词元重叠度和对称 KL 散度。在静态 OPD（虚线）基线中，重叠度单调下降，KL 散度上升了一个数量级。而在 CoPD（实线）中，Top-k 重叠度在每个 RLVR 阶段下降，但在相互 OPD 期间恢复，整个训练过程中保持在 0.90 以上。对称 KL 散度始终保持在低位。这证实了 CoPD 的核心设计：RLVR 创造了使蒸馏具有信息量的分歧，而相互 OPD 恢复了使其易于吸收的接近度。

5.总结与讨论

本文探讨了一个核心问题：如何更好地将多个专家的能力吸收到一个单一模型中？

作者发现，传统的混合数据 RLVR 面临能力分歧成本，而传统的静态 OPD 流水线则面临吸收效率低下的问题。为此，本文提出了协同进化策略蒸馏（CoPD），其核心思想是：**专家之间的蒸馏应该在训练期间发生，而不是在训练之后；多个专家模型应该互为师生，协同进化。**

每个专家的对应分支在自身数据上执行 RLVR 以探索能力前沿，并穿插来自其他专家的相互 OPD 以拉近行为模式，使其更易于相互学习。实验验证了 CoPD 实现了多专家能力的全能整合，甚至优于各自的专家模型。CoPD 展现出的强大性能提供了一个视角：模型并行训练可能成为进一步拓宽模型能力边界的一种极具前景的扩展范式。

基本信息

研究背景

研究思路

研究结果

结论与讨论



北京大学
PEKING UNIVERSITY

汇报完毕， 敬请老师同学批评指正！

汇报人：李宏扬

汇报日期：2026/07/29