



北京大学
PEKING UNIVERSITY

Just-In-Time Reinforcement Learning: Continual Learning in LLM Agents Without Gradient Updates

即时强化学习：LLM智能体的持续学习，
无需梯度更新

汇报人：彭莘尧

汇报日期：2026/08/19



目录

CONTENTS

1 基本信息

2 研究背景

3 主要方法

4 研究结果

5 结论与讨论

6 创新与启发

Just-In-Time Reinforcement Learning: Continual Learning in LLM Agents Without Gradient Updates

Yibo Li¹ Zijie Lin¹ Ailin Deng¹ Xuan Zhang¹ Yufei He¹ Shuo Ji¹ Tri Cao¹ Bryan Hooi¹

Abstract

While Large Language Model (LLM) agents excel at general tasks, they inherently struggle with continual adaptation due to the frozen weights after deployment. Conventional reinforcement learning (RL) offers a solution but incurs prohibitive computational costs and the risk of catastrophic forgetting. We introduce **Just-In-Time Reinforcement Learning (JitRL)**, a training-free framework that enables test-time policy optimization without any gradient updates. JitRL maintains a dynamic, non-parametric memory of experiences and retrieves relevant trajectories to estimate action advantages on-the-fly. These estimates are then used to directly modulate the LLM's output logits. We theoretically prove that this additive update rule is the exact closed-form solution to the KL-constrained policy optimization objective. Extensive experiments on WebArena and Jericho demonstrate that JitRL establishes a new state-of-the-art among training-free methods. Crucially, JitRL outperforms the performance of computationally expensive fine-tuning methods (e.g., WebRL) while reducing monetary costs by over 30×, offering a scalable path for continual learning agents. The code is available at <https://github.com/liushiliushi/JitRL>.




Figure 1. While standard RL performs policy gradient updates during training using previous trajectories, JitRL operates at test time. Specifically, it retrieves trajectories relevant to the current state to estimate advantages A , subsequently refining the output logits through a KL-regularized policy optimization objective.

same errors due to their failure to learn, whereas humans can adapt to their environment, including by learning from their mistakes. Highlighting the importance of this issue, Hendrycks et al. (2025) proposes an “AGI Score” assessing progress toward artificial general intelligence and finds that current AI systems are most deficient in their “capability to continually learn new information”.

【发表会议】：ICML

【发表时间】：2026.01

【被引数量】：8

【录用等级】：Oral

【arxiv】：arxiv.org/pdf/2601.18510

【机构】：NUS

【git】：github.com/liushiliushi/JitRL

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发



2.1 研究背景

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

核心问题——LLM智能体的持续自适应能力缺失

LLM智能体在通用任务上表现优异，但模型部署后权重处于冻结状态，不具备人类“边做边学”的即时适应能力。在陌生、动态的部署环境中，智能体无法从错误中积累经验，会反复出现同类失误；相关 AGI 能力评估也指出，持续学习新信息的能力，是当前 AI 系统迈向通用人工智能最薄弱的环节

传统强化学习

虽然RL是提升智能体能力的经典路径，但其存在三大核心缺陷：

- 成本高昂：需要大量训练数据和资源；为保持模型时效性需要频繁更新；
- 灾难性遗忘：参数更新导致模型已习得能力退化；
- 实际适配效果有限：在持续自适应的真实部署场景下，传统强化学习带来的性能提升十分有限。

上下文学习

通过提示词工程、历史上下文拼接将过往经验融入思维链，实现测试阶段的学习。

但这类方法存在明显瓶颈：

- 受限上下文窗口长度：智能体任务往往包含长交互序列，随着历史信息增加，模型对检索信息的注意力和利用效率显著下降；
- 泛化能力弱：提示词依赖文本描述，难以掌握无法用文字精准表述的技能。

2.2 问题提出

问题提出：我们能否在无需昂贵参数更新的前提下，让智能体实现灵活的持续学习？

总的来说，使用RL方法，如PPO、GRPO，虽然可以得到效果不错的模型，但成本极大，且训练出的是静态模型；使用ICL的方法，如Reflexion、EvoTest等，尽管成本低，但效果较差，且局限于提示词工程，缺乏数学支持。

基于上述技术路径的局限，领域内存在核心待解问题：**能否在无需昂贵参数更新的前提下，让智能体实现灵活的持续学习？**本文提出的 JitRL 框架正是针对这一问题，兼顾RL 的奖励优化学习范式，同时规避梯度更新带来的高成本与遗忘问题，还建立了可靠的数学理论支撑。

基本信息

研究背景


研究思路

研究结果

结论与讨论

创新与启发

3.1 流水线图



基本信息

研究背景


研究思路

研究结果

结论与讨论

创新与启发

3.1 流水线图




3.2 基础框架

基础框架由三部分组成：基于已完成轨迹的记忆构建、测试时价值估计和基于估计的优势值更新 LLM 的策略 logits：

- 记忆构建：

- 初始记忆库为空；
- 每一个episode结束后，使用LLM评估器对轨迹 τ 的每一步都进行打分： $\tau \rightarrow \{r_t\}_{t=1}^T$ ；
- 计算每一步的价值： $G_t = \sum_{u=t}^T \gamma^{u-t} r_u$ ；
- 将每一步交互以三元组的形式加入记忆库 M 中，三元组为 (s_t, a_t, G_t) 。其中 s_t 并非原始轨迹，而是经过大模型进行总结得到的结构化文本。



基本信息

研究背景

研究思路

研究结果


结论与讨论

创新与启发

3.2 基础框架

• 价值估计:

- 使用LLM获得当前观察 o_t 的摘要 s_t 作为当前状态;
- 对当前状态 s_t 使用Jaccard相似度检索, 取k近邻 $\mathcal{N}(s)$;
- 状态 s_t 的价值 $\hat{V}(s)$ 定义为该邻域内所有回报的期望: $\hat{V}(s) := \frac{1}{|\mathcal{N}(s)|} \sum_{i \in \mathcal{N}(s)} G_i$.
- 接下来估计动作价值, 若存在历史证据 (即 $|\mathcal{N}(s, a)| > 0$) , $\hat{Q}(s, a) := \frac{1}{|\mathcal{N}(s, a)|} \sum_{j \in \mathcal{N}(s, a)} G_j$; 若不存在, 以概率 λ 赋予价值 $\hat{Q}(s, a) := \hat{V}(s) + \frac{\alpha}{|\mathcal{N}(s)|}$, $1-\lambda$ 赋予价值 $\hat{Q}(s, a) := 0$ 以避免过度搜索。




3.2 基础框架

策略更新：

- 基于上述价值估计，策略更新可以形式化为一个约束优化问题，寻求最优策略：

$$\pi^* = \underset{\pi'}{\operatorname{argmax}} \left(\mathbb{E}_{a \sim \pi'} [A(s, a)] - \frac{1}{\beta} D_{KL}(\pi' \| \pi_\theta) \right)$$
 其中 β 为温度超参数。这是经典的RLHF目标函数，在最大化目标奖励的同时引入KL散度保留模型的语言连贯性。

- 该目标闭式解为 $\pi^*(a|s) \propto \pi_\theta(a|s) \exp(\beta A(s, a))$ ，设基础 LLM 的 logits 为 $z(s, a)$ ，满足 $\pi_\theta(a|s) = \operatorname{Softmax}(z(s, a))$ 。对闭式解取对数，可得到加法形式的更新规则： $z'(s, a) = z(s, a) + \beta \cdot \hat{A}(s, a)$ ，对更新后的 logits $z'(s, a)$ 施加 Softmax 函数，即可得到最优策略分布 π^* 。



3.2 基础框架

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

Step-wise Reward Evaluation System Prompt

You are evaluating web agent actions for a training database.

EVALUATION PROCESS:

1. Analyze: What happened after this action? What was the result?
2. Determine: Was this action **USEFUL** or **HARMFUL** (or neither)?
3. Assess: How **CERTAIN** are you? (certain / somewhat uncertain / very uncertain)
4. Score: Based on usefulness **AND** certainty

SCORING GUIDE (−3 to +3):

For USEFUL actions:

- +3: Clearly useful **AND** you are certain
- +2: Useful but you are somewhat uncertain
- +1: Might be useful but you are very uncertain

For HARMFUL/USELESS actions:

- -3: Clearly harmful/useless **AND** you are certain
- -2: Harmful/useless but you are somewhat uncertain
- -1: Might be harmful/useless but you are very uncertain

For NEUTRAL actions:

- 0: Cannot determine **OR** no real effect **OR** effect immediately undone

MANDATORY FORMAT:

Result: [what happened].

Usefulness: [useful/harmful/neutral].

Certainty: [certain/somewhat
uncertain/very uncertain].

Score: [score] – [repeat/avoid]

PPT中仅展示WebArena的部分prompt, 其他benchmark所用prompt原理相同, 予以省略

3.2 基础框架

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

Trajectory Context Extraction System Prompt

You are an expert at extracting effective action sequences to identify unique page states.

YOUR MISSION: We want to find similar page states from past browsing sessions to reuse successful actions. We already found pages with the SAME URL, but the same URL can have DIFFERENT STATES (e.g., different filter settings, form values, etc.). Your job: Extract the MINIMAL action sequence that DEFINES the current page state. This action sequence will be used to match against historical states.

WHAT TO KEEP:

- Actions whose effects are VISIBLE in the final page
- Actions that DETERMINE what content appears (filters, dropdowns, form inputs)

WHAT TO REMOVE:

- Actions whose effects are NOT visible (overwritten/replaced)
- Actions that don't affect final state

EXAMPLES:

Example 1 – Filter defines state:

Actions: `click(Refresh) → select_option(Show By, Year) → click(Refresh)`

Final page: Shows “Show By: Year” in dropdown

→ Output: `select_option(<combobox[Show By:]>, "Year")`

Example 2 – Overwritten input:

Actions: `fill(From, "2020") → fill(From, "2023")`

Final page: Shows “From: 2023”

→ Output: `fill(<textbox[From:]>, "2023")`

OUTPUT FORMAT:

Step 1: Reasoning – Examine final page and check each action's visibility

Step 2: Final Answer – [Action sequence separated by “→”, or “No action”]

3.2 基础框架


Jaccard相似度计算：

$$J(s, s_i) = \frac{|T(s) \cap T(s_i)|}{|T(s) \cup T(s_i)|}$$

其中 $T(s_i)$ 和 $T(s)$ 表示两条字符串的词元集合。

例子：

- 句子1： AI is our friend and it has been friendly.
- 句子2： AI and humans have always been friendly.



为什么不用余弦相似？：引入额外embedding模型；本文只需对结构化状态文本做基础分词，使用Jaccard即可。附录中对比了两种方法，Jaccard更优。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

3.3 算法流程

Algorithm 1 JitRL: Test-Time Policy Optimization

Input: LLM π_θ , hyperparameters $k, \beta, \lambda, \alpha, \gamma$

Initialize: Memory $\mathcal{M} \leftarrow \emptyset$

for each episode **do**

Initialize trajectory $\tau \leftarrow []$

while episode not done **do**

Observe state o ; abstract to $s \leftarrow \text{AbstractState}(o)$

// Step 1: Retrieve similar experiences

$\mathcal{N}(s) \leftarrow \text{Top-}k \text{ neighbors from } \mathcal{M} \text{ by Jaccard}(s, s_i)$

// Step 2: Estimate state value (baseline)

$V(s) \leftarrow \frac{1}{|\mathcal{N}(s)|} \sum_{(s_i, a_i, G_i) \in \mathcal{N}(s)} G_i$

// Step 3: Construct augmented candidate set

Get LLM candidates $\mathcal{C}_{\text{LLM}}$ with logits $z(s, a)$

$\mathcal{C} \leftarrow \mathcal{C}_{\text{LLM}} \cup \{a_i : (s_i, a_i, G_i) \in \mathcal{N}(s)\}$.

for $a \in \mathcal{C} \setminus \mathcal{C}_{\text{LLM}}$ **do**

$z(s, a) \leftarrow 0$

end for

// Step 4: Estimate value for each candidate

for $a \in \mathcal{C}$ **do**

$\mathcal{N}(s, a) \leftarrow \{(s_i, a_i, G_i) \in \mathcal{N}(s) : a_i = a\}$

if $|\mathcal{N}(s, a)| > 0$ **then**

$Q(s, a) \leftarrow \frac{1}{|\mathcal{N}(s, a)|} \sum_{(s_i, a_i, G_i) \in \mathcal{N}(s, a)} G_i$

else

if $\text{rand}() < \lambda$ **then**

$Q(s, a) \leftarrow V(s) + \alpha / |\mathcal{N}(s)|$

else

$Q(s, a) \leftarrow 0$

end if

end if

end for

// Initialize logit for memory-only actions

// Known action

// Exploration bonus

// Neutral value

// Step 5: Compute normalized advantage

for $a \in \mathcal{C}$ **do**

$A(s, a) \leftarrow Q(s, a) - V(s)$

end for

$A_{\max} \leftarrow \max_{a' \in \mathcal{C}} |A(s, a')| + \epsilon$

for $a \in \mathcal{C}$ **do**

$\tilde{A}(s, a) \leftarrow A(s, a) / (A_{\max} + \epsilon)$

end for

// Step 6: Closed-form policy update

for $a \in \mathcal{C}$ **do**

$z'(s, a) \leftarrow z(s, a) + \beta \cdot \tilde{A}(s, a)$

end for

Sample $a \sim \text{Softmax}(z')$; append (s, a) to τ

end while

// Step 7: Memory update after episode ends

$\{r_t\}_{t=0}^T \leftarrow \text{Evaluator}(\tau)$

for $t = 0$ **to** T **do**

$G_t \leftarrow \sum_{u=t}^T \gamma^{u-t} r_u$

$\mathcal{M} \leftarrow \mathcal{M} \cup \{(s_t, a_t, G_t)\}$

end for

end for

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

数学支持:

上述方法面临一个风险，即：内存中大量样本来自过去的旧策略，这些样本的分布与当前策略 π_t 不匹配，从而引入分布偏移误差。如果策略更新速度过快，历史样本将不再能够为当前策略的价值提供有效信号。为此，本文提出三条定理：

- 策略更新的最优性：设 π_θ 为参考策略，其logit为 $z(s, a)$ 。考虑求解最优策略 π^* ，该策略需要在 KL 散度

惩罚约束下最大化期望优势函数： $\pi^* = \arg \max_{\pi'} \left(\mathbb{E}_{a \sim \pi'} [\hat{A}(s, a)] - \frac{1}{\beta} D_{KL}(\pi' \| \pi_\theta) \right)$ ，其精确闭式解为：

$z'(s, a) = z(s, a) + \beta \cdot \hat{A}(s, a)$. 接下来证明即使在非平稳条件下 $\hat{V}_t$ 、 $\hat{Q}_t$ 、 $\hat{A}_t$ 收敛至其真实值。

$$\hat{V}_t(s) \xrightarrow{p} V^{\pi_t}(s),$$

- 价值与优势估计的一致性：在一定假设条件下，当 $t \rightarrow \infty$ 时： $\hat{Q}_t(s, a) \xrightarrow{p} Q^{\pi_t}(s, a)$,

$$\hat{A}_t(s, a) \xrightarrow{p} A^{\pi_t}(s, a).$$

- 策略更新的一致性：固定状态 s ，定义： $\pi_t^*(a|s) \propto \pi_\theta(a|s) \exp(\beta A^{\pi_t}(s, a))$, $\hat{\pi}_t(a|s) \propto \pi_\theta(a|s) \exp(\beta \hat{A}_t(s, a))$. 在上述定理下，当 $t \rightarrow \infty$ ，有： $\hat{\pi}_t(\cdot|s) \xrightarrow{p} \pi_t^*(\cdot|s)$ 。我们可以得出结论：本文的策略更新会收敛到由真实优势函数 A^{π_t} 导出的 KL 正则化最优策略。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发



3.4 数学证明

定理1：策略更新的最优性

对于一个KL策略约束的优化目标： $\pi^* = \arg \max_{\pi'} \left(\mathbb{E}_{a \sim \pi'} [\hat{A}(s, a)] - \frac{1}{\beta} D_{\text{KL}}(\pi' \parallel \pi_{\theta}) \right)$,

在固定s下简记： $\pi'(a) := \pi'(a|s)$, $\pi_{\theta}(a) := \pi_{\theta}(a|s)$, $\hat{A}(a) := \hat{A}(s, a)$.

目标函数： $J(\pi') = \sum_a \pi'(a) \hat{A}(a) - \frac{1}{\beta} \sum_a \pi'(a) \log \frac{\pi'(a)}{\pi_{\theta}(a)}$.

引入拉格朗日乘子 λ ： $\mathcal{L}(\pi', \lambda) = \sum_a \pi'(a) \hat{A}(a) - \frac{1}{\beta} \sum_a \pi'(a) (\log \pi'(a) - \log \pi_{\theta}(a)) + \lambda (\sum_a \pi'(a) - 1)$.

则有 $\frac{\partial \mathcal{L}}{\partial \pi'(a)} = \hat{A}(a) - \frac{1}{\beta} (1 + \log \pi'(a) - \log \pi_{\theta}(a)) + \lambda = 0$.

解得 $\log \pi'(a) = \beta \hat{A}(a) + \log \pi_{\theta}(a) + (\beta \lambda - 1)$, 即 $\pi'(a) = \pi_{\theta}(a) \exp(\beta \hat{A}(a)) \exp(\beta \lambda - 1)$.

令 $Z(s) = \sum_{a'} \pi_{\theta}(a'|s) \exp(\beta \hat{A}(s, a'))$, 得到 $\pi^*(a|s) = \frac{\pi_{\theta}(a|s) \exp(\beta \hat{A}(s, a))}{\sum_{a'} \pi_{\theta}(a'|s) \exp(\beta \hat{A}(s, a'))}$

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发



3.4 数学证明

定理1：策略更新的最优性

上式简记为 $\pi^*(a|s) \propto \pi_\theta(a|s) \exp(\beta \hat{A}(s, a))$.

基础模型的策略可写作： $\pi_\theta(a|s) = \text{Softmax}(z(s, a)) = \frac{\exp(z(s, a))}{\sum_{a'} \exp(z(s, a'))}$.

则有 $\pi^*(a|s) \propto \exp(z(s, a)) \exp(\beta \hat{A}(s, a))$

等价于 $\pi^*(a|s) \propto \exp(z(s, a) + \beta \hat{A}(s, a))$

定义 $z'(s, a) = z(s, a) + \beta \hat{A}(s, a)$

则有 $\pi^*(\cdot | s) = \text{Softmax}(z'(s, \cdot))$.

以上证明了 若优势估计正确，则该更新策略精确优化了一开始的优化目标。

然而，它并不自动证明优势估计一定正确，如果估计不正确呢？

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发



3.4 数学证明

定理2：价值与优势估计的一致性

前面的pipeline中，策略更新时的优势函数来源于记忆模块，记忆条目是： (S_i, A_i, G_i)

对 s 检索最近的 k 个状态邻居 $N(s)$ ，估计：
$$\hat{V}_t(s) = \frac{1}{|N(s)|} \sum_{i \in N(s)} G_i,$$

再在“邻居中恰好采取了候选动作 a 的子集 $N(s,a)$ 上估计：
$$\hat{Q}_t(s, a) = \frac{1}{k_a} \sum_{i \in N(s,a)} G_i, \quad k_a = |N(s, a)|.$$

最后 $\hat{A}_t(s, a) = \hat{Q}_t(s, a) - \hat{V}_t(s)$.

该定理意图证明，在若干条件下：
$$\hat{V}_t(s) \xrightarrow{p} V_t^{\pi_t}(s), \quad \hat{Q}_t(s, a) \xrightarrow{p} Q_t^{\pi_t}(s, a), \quad \hat{A}_t(s, a) \xrightarrow{p} A_t^{\pi_t}(s, a).$$

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

定理2：价值与优势估计的一致性

假设如下：

- 状态正则性：相似状态应有相似的价值， $|Q^\pi(s, a) - Q^\pi(s', a)| \leq L_Q d(s, s')$ ，并且 V 也满足类似的 Lipschitz 条件。换言之，检索到状态相近的历史经验，可以为当前状态提供可靠的价值信息。
- 回报噪声模型：将历史回报写成真实动作价值加零均值噪声： $G_i = Q^{\pi_{t(i)}}(S_i, A_i) + \epsilon_i$ ， $\mathbb{E}[\epsilon_i | S_i, A_i] = 0$ ， $\text{Var}(\epsilon_i | S_i, A_i) \leq \sigma^2$ 。这里把环境随机性、有限轨迹回报波动，以及 evaluator 打分噪声都压缩进 ϵ_i 。
- kNN 渐近条件与覆盖： $N(t) \rightarrow \infty$ ， $k \rightarrow \infty$ ， $\frac{k}{N} \rightarrow 0$ 。前两者确保近邻平均能降低噪声；后者则确保检索半径趋小，不会把越来越远的样本也纳入局部估计。并且状态分布必须覆盖查询区域。
- 动作频率： $k_a = |N(s, a)| \xrightarrow{p} \infty$ 。仅仅状态邻居数量增长还不够，在检索邻居中真正执行动作 a 的样本数也要增长。因为如果某动作几乎从未被采样，那么 $Q(s, a)$ 仍没有足够数据来估计。
- 慢策略漂移： $\Delta_t = \max_{i \in N(s)} \sup_{s'} TV(\pi_{t(i)}(\cdot | s'), \pi_t(\cdot | s'))$ ，并假设 $\Delta_t \rightarrow 0$ 。这避免记忆被很陈旧、来自完全不同策略的数据主导。
- 策略正则性：如果策略相近，它们诱导的 Q 和 V 也相近： $|Q^\pi(s, a) - Q^{\pi'}(s, a)| \leq L_\pi \sup_{s'} TV(\pi(\cdot | s'), \pi'(\cdot | s'))$ 。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发



3.4 数学证明

定理2：价值与优势估计的一致性

在上述全部假设下，对时刻 t 任意固定的查询状态 s 和动作 a ，当 $t \rightarrow \infty$ ：

$$\hat{V}_t(s) \xrightarrow{p} V^{\pi_t}(s), \quad \hat{Q}_t(s, a) \xrightarrow{p} Q^{\pi_t}(s, a), \quad \hat{A}_t(s, a) \xrightarrow{p} A^{\pi_t}(s, a).$$

证明如下：

$$\hat{Q}_t(s, a) := \frac{1}{k_a} \sum_{i \in \mathcal{N}(s, a)} G_i.$$

代入噪声模型：

$$\hat{Q}_t(s, a) - Q^{\pi_t}(s, a) = \frac{1}{k_a} \sum_{i \in \mathcal{N}(s, a)} (Q^{\pi_{t(i)}}(S_i, a) - Q^{\pi_t}(s, a)) + \frac{1}{k_a} \sum_{i \in \mathcal{N}(s, a)} \epsilon_i.$$

将第一项做分解：

$$Q^{\pi_{t(i)}}(S_i, a) - Q^{\pi_t}(s, a) = \underbrace{Q^{\pi_{t(i)}}(S_i, a) - Q^{\pi_{t(i)}}(s, a)}_{\text{状态失配项}} + \underbrace{Q^{\pi_{t(i)}}(s, a) - Q^{\pi_t}(s, a)}_{\text{策略漂移项}}.$$

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发



3.4 数学证明

定理2：价值与优势估计的一致性

- 状态失配项：
 - 由状态正则假设： $|Q^\pi(s, a) - Q^\pi(s', a)| \leq L_Q d(s, s')$ ，则 $|Q^{\pi_{t(i)}}(S_i, a) - Q^{\pi_{t(i)}}(s, a)| \leq L_Q d(S_i, s)$. 在 k 近邻机制下，近邻的平均距离依概率收敛到 0，因此该项趋于消失。
 - 策略偏移项：
 - 由策略正则性假设： $|Q^{\pi_{t(i)}}(s, a) - Q^{\pi_t}(s, a)| \leq L_\pi \Delta_t \rightarrow 0$.
 - 噪声方差项：
 - 在给定 $\{(S_i, A_i)\}$ 的条件下，噪声均值为 0，方差上界为 σ^2/k_a ；又 $k_a \rightarrow \infty$ ，方差趋于 0。
- 综合以上三项，得到 $\hat{Q}_t(s, a) \xrightarrow{p} Q^{\pi_t}(s, a)$ ， $\hat{V}_t$ 证明同理。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

3.4 数学证明

定理3：策略更新的一致性

结合上一节定理，我们得到：策略更新会收敛到由真实优势函数定义的 KL 正则化最优策略。本定理证明闭式策略更新的一致性：

固定状态 s ，定义： $\pi_t^*(a|s) \propto \pi_\theta(a|s) \exp(\beta A^{\pi_t}(s, a))$, $\hat{\pi}_t(a|s) \propto \pi_\theta(a|s) \exp(\beta \hat{A}_t(s, a))$ 。

定义映射 $\Phi: \mathbb{R}^{|\mathcal{A}|} \rightarrow \Delta(\mathcal{A})$: $\Phi(x)(a) = \frac{\pi_\theta(a|s) \exp(\beta x(a))}{\sum_{a' \in \mathcal{A}} \pi_\theta(a'|s) \exp(\beta x(a'))}$ 。当动作集合 $\mathcal{A}$ 为有限集， Φ 是连续函数（由连续函数复合得到，分母恒严格大于 0）。

在定理 2 的假设条件下，向量 $\hat{A}_t(s, \cdot)$ 的每个分量依概率收敛到 $A^{\pi_t}(s, \cdot)$ ，因此作为整体向量也依概率收敛。

由连续映射定理（收敛随机变量的连续变换依旧收敛；）： $\hat{\pi}_t(\cdot|s) = \Phi(\hat{A}_t(s, \cdot)) \xrightarrow{p} \Phi(A^{\pi_t}(s, \cdot)) = \pi_t^*(\cdot|s)$ 。

即当 $t \rightarrow \infty$ ， $\hat{\pi}_t(\cdot|s) \xrightarrow{p} \pi_t^*(\cdot|s)$ 。

该结论对有限候选动作集成立；更一般地，若 $\hat{A}_t(s, \cdot)$ 在候选动作集上一致收敛，结论同样成立。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

4.1 实验设置

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

- Benchmarks:
 - WebArena: 模拟真实网页环境, 包含五个网站域 (Admin, GitLab, Map, Reddit, Shopping), 分别包含不同类型的任务。
 - Jericho: 交互式小说游戏基准测试, 智能体仅通过文本指令完成交互。本文中选用Library, Zork1, Zork3三个游戏, 它们难度递进, 且覆盖了不同类型的学习场景。
- Baselines: 主要分为无训练方法、权重更新方法
 - 静态基线: 静态模型, 不提供历史交互记录
 - 记忆基线: 静态模型, 将历史完整交互记录填入上下文窗口
 - Reflexion: 基于提示词, 每个 episode 结束后智能体生成结构化文本反思, 指导后续尝试。
 - AWM: 从成功经验中提取可复用的标准化 workflow, 指导后续任务执行。
 - EvoTest: 进化式测试时优化框架, 迭代改写提示词、更新状态- 动作记忆、动态调参。
 - 权重更新方法: 针对 WebArena, 直接使公开的 SFT、WebRL 预训练权重, 二者基于 Llama- 3.1- 70B- Instruct。针对 Jericho, 使用基于 GRPO、针对每个游戏单独训练得到的 Qwen3- 32B 权重。训练细节见附录 E。

4.2 主要性能对比

Table 1. Main results on WebArena. We report average (**Avg**) and final (**Final**) success rate (%) for each domain. The gap between Final and Avg reflects learning efficiency. The final column (Average) is calculated as the micro-average across all tasks from all websites.

Method	Admin		GitLab		Map		Reddit		Shopping		Average	
	Avg	Final	Avg	Final	Avg	Final	Avg	Final	Avg	Final	Avg	Final
Static	39.46	39.67	38.92	38.24	30.62	31.25	39.60	42.86	24.06	25.00	35.63	36.30
Memory	47.91	47.80	39.31	40.20	30.47	32.81	53.02	55.04	30.16	33.16	41.36	43.00
Reflexion	48.46	50.55	38.43	40.69	29.38	27.34	54.88	56.59	30.83	31.25	41.08	42.12
AWM	49.46	51.09	37.94	40.20	34.38	32.81	55.66	58.14	23.12	22.40	39.37	40.32
EvoTest	44.51	47.80	37.94	39.22	33.59	41.41	51.78	54.26	26.67	29.17	39.24	42.49
JitRL	52.31	56.59	40.78	45.00	37.66	42.19	57.64	61.98	41.67	45.83	46.98	51.35

Table 2. Comparison of **Final** success rate (%) with weight-update methods on **WebArena-Lite**, the held-out test set. The remainder of WebArena was used to train WebRL.

Method	Admin	GitLab	Map	Reddit	Shopping	Average
SFT	20.00	20.00	26.70	52.60	13.30	23.00
WebRL	58.33	47.06	32.26	62.50	30.43	46.06
JitRL	65.71	56.67	53.57	78.95	53.33	60.00

- Jitrl 全面超越所有免训练基线，在 Shopping任务上提升最为显著；
- jitrl 的 Final-Avg 差值最大，说明该方法确实在多轮迭代中学到了东西；
- 此外，Reflexion在Map任务由于生成了误导性文本，性能相较static甚至下降了。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

4.2 主要性能对比




Figure 3. Learning curves on Jericho games. JitRL shows consistent improvement across episodes.

Table 3. Results on Jericho games. We report: **Avg**: average score across 50 episodes; **Final**: final episode score.

Method	Library		Zork1		Zork3	
	Avg	Final	Avg	Final	Avg	Final
Static	10.0	10	8.5	10	0.2	0
Memory	13.2	14	22.9	25	1.0	1
Reflexion	15.4	18	26.1	35	1.4	1
AWM	12.7	10	38.8	44	1.9	2
EvoTest	21.5	26	46.8	54	2.6	4
GRPO	13.6	11	16.2	10	1.1	2
JitRL	25.9	30	53.0	69	3.1	5

- Jitrl方法同样在所有任务上达到最优，同时遥遥领先于GRPO，这说明在长程问题中，GRPO需要密集奖励信号才能传播；
- 从效率上讲，JitRL 初期学习速度快，后续收敛时性能更好，后期指标波动小，策略稳定。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

4.3 泛化能力

Table 4. Comparison of average (Avg) and Final success rate between JitRL and baseline methods across different backbone LLMs.

Method	Admin		Reddit	
	Avg	Final	Avg	Final
<i>Gemini-2.5-flash</i>				
Static	39.46	39.67	39.60	42.86
Memory	47.91	47.80	53.02	55.04
Reflexion	48.46	50.55	54.88	56.59
AWM	49.46	51.09	55.66	58.14
EvoTest	44.51	47.80	51.78	54.26
JitRL (Ours)	52.31	56.59	57.64	61.98
<i>GPT-5-mini</i>				
Static	37.07	37.50	47.29	46.51
Memory	43.04	45.65	50.54	51.94
Reflexion	40.43	41.30	49.15	49.61
AWM	40.00	40.22	50.23	51.94
EvoTest	42.93	43.48	51.94	53.49
JitRL (Ours)	48.04	51.63	54.26	57.36
<i>DeepSeek-V3.2</i>				
Static	32.07	32.61	42.02	43.41
Memory	37.07	45.65	51.47	56.28
Reflexion	38.04	40.22	55.04	56.59
AWM	42.07	44.02	52.71	55.04
EvoTest	44.35	45.65	50.85	53.49
JitRL (Ours)	50.65	54.35	54.42	61.24

Table 5. Generalization to Unseen Tasks. We report the average success rate (%) where the agent is restricted to retrieving memories exclusively from disjoint tasks.

Method	Admin	GitLab	Map	Reddit	Shopping
Static	36.96	37.25	31.19	36.43	23.44
Memory	47.83	37.75	33.03	50.39	26.04
Reflexion	46.74	34.80	31.19	48.84	31.77
AWM	47.28	36.27	34.86	53.49	23.44
EvoTest	43.48	35.78	34.86	49.61	18.75
JitRL	48.37	38.73	35.78	55.04	36.98

Table 6. Distribution (%) of cross-task memory utilization.

Admin	GitLab	Map	Reddit	Shopping	Avg
40.54	38.47	37.64	56.31	62.19	47.03

- 换用不同模型均有提升；
- 47%检索到的记忆来自其他任务，说明学到了抽象知识而非死记硬背。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

4.4 其他结果

Table 8. Ablation: Logit update vs. prompting on WebArena.

Method	Admin	Reddit
JitRL (Prompt Update)	49.46	53.02
JitRL (Logit Update)	52.31	57.64

使用相同的记忆检索内容，更新 Logit（本文方法）优于直接将记忆拼接到文本中。

Table 9. Comparison of training cost.

Metric	Static	Memory	Reflexion	AWM	EvoTest	WebRL	JitRL
Cost	\$200	\$230	\$220	\$250	\$220	~\$9900	\$290

相较于WebRL，成本优势显著，且效果也有提升；相较于其他非参数更新方法，花费接近但效果显著提升。

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

5.1 结论

基本信息

研究背景

研究思路

研究结果

结论与讨论

创新与启发

JitRL证明了RL的数学本质不需要梯度，通过记忆检索 + logit调制就可以实现训练时的持续RL，且无需梯度更新。

- RL精确解： $z'(s, a) = z(s, a) + \beta \hat{A}(s, a)$ 是KL约束的策略优化目标

$$\pi^* = \arg \max_{\pi'} \left(\mathbb{E}_{a \sim \pi'} [\hat{A}(s, a)] - \frac{1}{\beta} D_{\text{KL}}(\pi' \| \pi_{\theta}) \right) \text{的闭式解};$$

- 零梯度SOTA：无需梯度更新，在WebArena和Jericho上达到SOTA，并超越了需要梯度更新的RL方法；
- 成本开销极低的RL替代：

Table 9. Comparison of training cost.

Metric	Static	Memory	Reflexion	AWM	EvoTest	WebRL	JitRL
Cost	\$200	\$230	\$220	\$250	\$220	~\$9900	\$290



5.2 不足之处

01不足

依赖基模能力，只能在基模提出的候选集中调整权重，不能引导发现基模不会生成的动作。

03不足

依赖文本相似度，对于难以文本化的任务效果有限

01

02

03

02不足

依赖打分模型能力，评估器由LLM+Prompt构成，缺乏可靠性保证。

6 创新与启发

基本信息

研究背景

研究思路


研究结果

结论与讨论

创新与启发

创新

- 给出RL带KL散度策略优化目标的精确闭式解，说明了RL的数学本质不需要梯度；
- 0梯度在一些任务上达到SOTA，成本性能双优势。



启发

- 可不可以通过教师模型存储记忆，学生模型进行检索 + Jitrl，去实现更简单的蒸馏；
- 让智能体持续适应，并不一定要更新模型参数



北京大学
PEKING UNIVERSITY

汇报完毕， 敬请老师同学批评指正！

汇报人：彭莘尧

汇报日期：2026/08/12