



北京大學
PEKING UNIVERSITY

MOPD: Multi-Teacher On-Policy Distillation for Capability Integration in LLM Post-Training

MIMO

汇报人：彭鑫霖

汇报日期：2026/08/26

目录

CONTENTS

1 基本信息

2 研究背景

3 研究思路

4 研究结果

5 结论与限制

6 进一步讨论

Xiaomi MIMO



MOPD: Multi-Teacher On-Policy Distillation for Capability Integration in LLM Post-Training

Wenhan Ma^{1,2*} Jianyu Wei² Liang Zhao² Hailin Zhang² Bangjun Xiao^{1,2}
Lei Li^{2,3} Qibin Yang^{1,2} Bofei Gao^{1,2} Yudong Wang^{1,2}
Rang Li^{1,2} Jinhao Dong^{4,2} Zhifang Sui^{1†} Fuli Luo^{2†}

¹Peking University ²LLM Core, Xiaomi

³University of Hong Kong ⁴Renmin University of China

MIMO技术报告 【发表时间】：2026.06

【被引数量】：20

【DOI】：<https://arxiv.org/pdf/2606.30406>

基本信息

研究背景

研究思路

研究结果

结论与限制

进一步讨论

2.1 Challenge: 用户需要的不是多个专家模型，而是一个统一全能模型

Post-training专业化

不同能力往往依赖不同的 RL 训练方式



基本信息

研究背景

研究思路

研究结果

结论与限制

进一步讨论

2.2 现有方法

	方法	问题
Mix-RL	把不同domain的 prompt 混在一起做 joint RL，每个样本仍用自己的domain reward	不同reward会 互相干扰 （奖励跷跷板）
Cascade RL	按顺序训练（SFT->Math RL->Code RL->Instruction RL）	灾难性遗忘
Param Merge	得到多个expert model，直接平均参数或者组合task vector	weight space并不兼容， 能力融合并不稳定
Off-policy SFT	teacher生成teacher轨迹，然后给student学，离线蒸馏	训推分布不一致

	Dense optimization	On-policy	Parallelisable
Param-Merge	×	—	✓
Off-Policy Finetune	✓	×	✓
Mix-RL	×	✓	×
Cascade RL	×	✓	×
MOPD (ours)	✓	✓	✓

我们需要一个同时满足**奖励稠密**，**在线**，**可并行**的方法，也就是**MOPD**

基本信息

研究背景

研究思路

研究结果

结论与限制

进一步讨论

3 MOPD: 多个老师教一个学生




Figure 1 Overview of the three-stage MOPD pipeline. Stage 1 produces a shared SFT checkpoint; Stage 2 trains the per-domain teachers in parallel; Stage 3 repeatedly (i) samples a prompt from the domain mixture, (ii) routes it to the matching teacher, (iii) has the student roll out, (iv) prefills the teacher on the rollout to obtain token-level log-probabilities, and (v) updates the student using the teacher signal.

基本信息

研究背景

研究思路

研究结果

结论与限制

进一步讨论

3 如何把轨迹交给对应的专家 (Routing)

本质上是**直接根据prompt类型**，把轨迹交给对应的专家（每个prompt只有一个teacher来教）

基本信息

研究背景

研究思路

研究结果

结论与限制

进一步讨论

证明这个数学问题 → math teacher

写python代码 → code teacher

训练数据一开始就知道某个prompt来源于什么domain，所以**直接查表**就能做到路由



3 如何实现（目标函数）

$$\mathcal{L}_{\text{rev-KL}} = \mathbb{E}_{x, y \sim \pi_{\theta}} \left[\frac{1}{|y|} \sum_t \sum_v \pi_{\theta}(v) \log \frac{\pi_{\theta}(v)}{\pi_{\phi_d}(v)} \right],$$

这里：

- π_{θ} : Student
- π_{ϕ_d} : 当前 prompt 对应的 domain teacher
- x : prompt
- $y \sim \pi_{\theta}$: Student 自己生成的 response
- $y_{<t}$: Student 已经生成的前缀
- v : 整个 vocabulary 中某一个 token

严格写出来其实是：

$$\pi_{\theta}(v) = \pi_{\theta}(v | x, y_{<t})$$

和

$$\pi_{\phi_d}(v) = \pi_{\phi_d}(v | x, y_{<t}).$$

基本信息

研究背景

研究思路

研究结果

结论与限制

进一步讨论

3 Implementation

Policy Gradient

$$\mathcal{L}_{\text{rev-KL}} = \mathbb{E}_{x, y \sim \pi_{\theta}} \left[\frac{1}{|y|} \sum_t \sum_v \pi_{\theta}(v) \log \frac{\pi_{\theta}(v)}{\pi_{\phi_d}(v)} \right],$$

$$\nabla_{\theta} \mathcal{L} = -\mathbb{E}_{x, y} \left[\frac{1}{|y|} \sum_t \log \frac{\pi_{\phi_d}(y_t)}{\pi_{\theta}(y_t)} \nabla_{\theta} \log \pi_{\theta}(y_t) \right],$$

$$\hat{A}_{\text{MOPD}, t} = \text{sg}[\log \pi_{\phi_d}(y_t) - \log \pi_{\theta}(y_t)].$$

Surrogate loss:

$$\mathcal{L}_{\text{MOPD}}^{\text{PG}}(\theta) = -\mathbb{E}_{x, y} \left[\frac{1}{|y|} \sum_t \hat{A}_{\text{MOPD}, t}^{\text{clip}} \log \pi_{\theta}(y_t) \right].$$

这里只能用sampled token的信息近似，
损失了分布里的其他token的信息（**方差很大**）

top-k distillation

直接选择教师模型的top-K截断：

$$\sum_{v \in T_t} \pi_S(v) \log \frac{\pi_S(v)}{\pi_T(v)}, \quad T_t \text{ 是截断后的token集合}$$

这个时候对截断后的Loss求梯度，**最优点不再一定满足** $\pi_S(v) = \pi_T(v)$ ，因为

Original loss:

$$\mathcal{L}_{\text{rev-KL}} = \mathbb{E}_{x, y \sim \pi_{\theta}} \left[\frac{1}{|y|} \sum_t \sum_v \pi_{\theta}(v) \log \frac{\pi_{\theta}(v)}{\pi_{\phi_d}(v)} \right],$$

Surrogate loss:

$$\mathcal{L}_{\text{MOPD}}^{\text{TopK}}(\theta) = \mathbb{E}_{x, y} \left[\frac{1}{|y|} \sum_t \sum_{v \in \mathcal{T}_t^d} \left[\pi_{\theta}(v) \log \frac{\pi_{\theta}(v)}{\pi_{\phi_d}(v)} - \pi_{\theta}(v) + \pi_{\phi_d}(v) \right] \right],$$

基本信息

研究背景

研究思路

研究结果

结论与限制

进一步讨论



3 Implementation: top-k distillation

1. 为什么截断后最优点不一定teacher-student策略一致：top-k之后，**各个token概率近似相互独立**

完整 KL:

$$D_{KL}(p||q) = \sum_v p_v \log \frac{p_v}{q_v}$$

有一个性质:

$$D_{KL}(p||q) \geq 0$$

并且:

$$D_{KL}(p||q) = 0 \iff p = q$$

所以:

$$\boxed{p = q}$$

一定是最优解。

2. **不能截断后归一化**，再算KL:

- 破坏top-k的分布形状，改变绝对概率值 (0.5,0.3) - > (0.625,0.375)
- 丢失top-k之外的信息

$$L = p_1 \log \frac{p_1}{q_1} + p_2 \log \frac{p_2}{q_2}$$

求导:

$$\frac{\partial L}{\partial p_1} = \log \frac{p_1}{q_1} + 1$$

令梯度为 0:

$$\log \frac{p_1}{q_1} + 1 = 0$$

得到:

$$\frac{p_1}{q_1} = e^{-1}$$

所以:

$$p_1 = \frac{q_1}{e}$$

例如:

$$q_1 = 0.6$$

那么最优:

$$p_1 = 0.22$$

而不是:

$$0.6$$

基本信息

研究背景

研究思路

研究结果

结论与限制

进一步讨论

4 实验设置

- **模型选择:** Qwen3-30B-A3B-Base, MIMO-V2-Flash (工业验证)
- **Tasks:** Math (AIME25,26) , Instruction following (IFBench, IFEval) , Software Engineering (SWE-bench)
- **Baseline:** Mix-RL, Cascade RL, Off-Policy Finetune, Param-Merge
- **Evaluation Metric:** (避免直接对最后评估结果取平均)

对于每个领域 $d \in D$:

- s_s^d : Stage-1 SFT Student accuracy (起点)
- s_t^d : Stage-2 Specialist Teacher accuracy (上限)
- s_d : 待评价方法在该领域的 accuracy

定义:

$$\tilde{s}_d = \frac{s_d - s_s^d}{s_t^d - s_s^d}$$

基本信息

研究背景

研究思路

研究结果

结论与限制




进一步讨论

4 实验结果 (Qwen3-30B-A3B)

Table 2 Qwen3-30B-A3B: multi-domain capability integration. Per-benchmark columns are accuracy (%); higher is better. “RL Teacher” is the Stage-2 specialised RL teacher for that domain. The **Norm. score** column is the normalised score defined in §4.1; higher is better. Within the six integration methods we **bold** the column best and underline the runner-up.

Method	Math		Instruction Following		SWE	Norm. score
	AIME25	AIME26	IFBench	IFEval	SWE-bench Verified	
Student (SFT-only)	45.42	54.48	42.69	84.17	35.80	0.0000
RL Teacher	54.79	63.65	78.40	95.50	51.20	1.0000
Mix-RL	52.71	63.75	75.00	94.58	<u>48.80</u>	0.8818
Cascade RL	48.54	61.88	77.11	<u>95.80</u>	47.80	0.7752
Off-Policy Finetune	<u>51.56</u>	63.44	80.95	93.35	45.80	0.8241
Param-Merge (Avg.)	47.81	59.58	53.74	88.79	39.60	0.3280
Param-Merge (Task Arith.)	49.38	<u>63.96</u>	<u>78.23</u>	95.81	<u>48.80</u>	0.8574
MOPD (ours)	51.46	65.31	77.89	93.84	50.40	0.9373
$\Delta(\text{MOPD} - \text{RL Teacher})$	-3.33	+1.66	-0.51	-1.66	-0.80	-0.0627

- MOPD可以缓解多奖励跷跷板，可以更好逼近teacher上限 (学习信号更加稠密)
- 在所有baseline中，Mix-RL其实效果最好（多reward方向冲突）
- 参数融合（Param-Merge）如果直接做平均，效果很差，方法敏感
- MOPD非常 **sample-efficient**



基本信息

研究背景

研究思路

研究结果

结论与限制

进一步讨论

4 实验结果: (MIMO-v2-Flash 309B)

Table 3 MiMo-V2-Flash: integration via the full MOPD pipeline. All teachers are RL-trained.

	AIME25	HMMT25	LCB	IFBench	SWE-Bench V.	τ^2 -Bench	τ^2 -Telecom
Student	89.3	76.9	77.5	55.4	67.8	75.9	92.7
Teacher	93.9	82.6	82.6	68.9	74.2	79.6	95.0
MOPD	94.1	84.4	83.2	66.7	73.4	80.3	95.3
Δ	+0.2	+1.8	+0.6	-2.2	-0.8	+0.7	+0.3

MOPD之后, 不仅接近Teacher model, 甚至超过teacher model了, MOPD可能不仅仅是能力简单复制, 甚至可能是**融合促进**

基本信息

研究背景

研究思路

研究结果

结论与限制

进一步讨论

4 分析：实验设置1-teacher选择和Loss选择

Table 4 Distillation loss variants and teacher distribution alignment on Qwen3-30B-A3B. Per-benchmark columns are accuracy (%); the last column is the normalised score defined in §4.1. The top two rows use the RL teachers from the default MOPD pipeline; the bottom two rows replace the Math teacher with Qwen3-235B-A22B, a stronger but distributionally different model. Both loss variants use $k = 64$ for top- k .

Math Teacher	Loss Variant	Math		Instruction Following		SWE	Norm. score
		AIME25	AIME26	IFBench	IFEval	SWE-bench Verified	
RL Teacher	Policy gradient	51.46	65.31	77.89	93.84	50.40	0.9373
	Top- k distillation	51.77	64.79	75.85	93.07	50.20	0.9093
Qwen3-235B-A22B	Policy gradient	45.63	51.56	79.25	93.99	50.60	0.6003
	Top- k distillation	0.94	0.42	72.96	88.97	51.20	-1.1898

- 学生还是Qwen3-30B-A3B，上面两行用经过强化学习后的RL-teacher，下面两行其他保持一样，把math teacher换成一个更大更强的模型（Qwen3-235B-A22B）。
- top-K蒸馏选择K = 64

基本信息

研究背景

研究思路

研究结果

结论与限制

进一步讨论

4 分析：结果分析1-teacher选择和Loss选择

Table 4 Distillation loss variants and teacher distribution alignment on Qwen3-30B-A3B. Per-benchmark columns are accuracy (%); the last column is the normalised score defined in §4.1. The top two rows use the RL teachers from the default MOPD pipeline; the bottom two rows replace the Math teacher with Qwen3-235B-A22B, a stronger but distributionally different model. Both loss variants use $k = 64$ for top- k .

Math Teacher	Loss Variant	Math		Instruction Following		SWE	Norm. score
		AIME25	AIME26	IFBench	IFEval	SWE-bench Verified	
RL Teacher	Policy gradient	51.46	65.31	77.89	93.84	50.40	0.9373
	Top- k distillation	51.77	64.79	75.85	93.07	50.20	0.9093
Qwen3-235B-A22B	Policy gradient	45.63	51.56	79.25	93.99	50.60	0.6003
	Top- k distillation	0.94	0.42	72.96	88.97	51.20	-1.1898

基本信息

研究背景

研究思路

研究结果

结论与限制

进一步讨论

- 按理说更大的模型数学能力应该更强，但是数学老师变强后数学能力反而下降。（teacher和student分布差异太大了，效果其实不好）
- 换了math teacher，其他能力反而可能提升（没有分析）
- gradient loss其实影响没有teacher选择大
- 为什么top-k在换了更大size的teacher之后掉点严重？因为分布差异大，top-k给的更新大





Figure 3 Training dynamics across the four runs in Table 4 on the Math domain of Qwen3-30B-A3B. **Left:** Math accuracy (%). **Middle:** per-token student-teacher reverse KL divergence. **Right:** student policy entropy. The two same-origin teacher runs (solid) show smooth, stable optimization; the two external-teacher runs (dashed) exhibit progressively unstable training, with the top- k variant collapsing catastrophically around step 18.

4 分析2: MOPD不是只能做一轮

Multi-round Student-Teacher Evolution (多轮学生-教师进化)

MOPD 不止做一轮: Student 提升后, 可以继续训练更强的 Teacher, 再进行下一轮蒸馏



单轮 MOPD 已能吸收大部分能力



更强的 Student
可以训练出更强的 Specialist Teacher



多轮迭代可持续缩小
Student-Teacher gap

图例: headroom 说明

Student  → Teacher

headroom = 剩余可提升空间



headroom 越小, 表示 Student 越接近 Teacher

4 分析2: MOPD不是只能做一轮

Table 5 Multi-round student-teacher evolution on Qwen3-30B-A3B. Per-benchmark columns are accuracy (%); the last column is the normalised score defined in §4.1. Iter-2 RL Teacher is the per-domain RL teacher initialised from the Iter-1 MOPD student; Iter-2 MOPD is the student produced from those teachers. No new SWE teacher was trained at Iter 2; the SWE scores reflect only indirect effects of Math/IF distillation.

Round	Math		Instruction Following		SWE	Norm. score
	AIME25	AIME26	IFBench	IFEval	SWE-bench Verified	
Iter 1 MOPD	51.46	65.31	77.89	93.84	50.40	0.937
Iter 2 RL Teacher	54.27	65.52	81.46	95.65	50.40	1.030
Iter 2 MOPD	53.44	64.90	79.76	95.44	50.20	0.986

1. Teacher不是固定的
2. MOPD可以迭代扩展能力
3. 能力提升存在递归效应

基本信息

研究背景

研究思路

研究结果

结论与限制

进一步讨论



5.1 Discussion and Limitation

- **MOPD不是一种算法，而是一种后训练范式**（已经扩展到多模态，logits换成velocity，Flow-OPD）：
基础模型 -> 多专家模块 -> 能力融合（递归增强）

- **多专家并行发展（效率层面）**：算力足够可以同时进行，没有固定顺序
- **训练recipe层次解耦**：解决了不同的domain之间的算法，reward，infra的gap
- **风险隔离**：不同领域的RL互相隔离，训练风险也互相隔离

Limitation:

- **成本高**：训练teacher**成本很高**，需要针对不同domain都要训练expert
- **teacher维度和数量**：本文讨论的是LLM，考虑的domain有math，code等等，但是如果维度很多（多模态），会导致teacher数量剧增。
- **teacher选择**：分布不能差异太大

基本信息

研究背景

研究思路

研究结果

结论与限制

进一步讨论

6 Reward See-Saw (多奖励跷跷板)

之前论文里同源不同size模型teacher-forcing后的结果

(a) Entropy-JSD Geometry





Figure 4: Quadrant statistics under $H_w = \ln 2$ and $JSD = \frac{3}{4} \ln \frac{4}{3}$, reporting token fraction, top-1 mismatch rate, within-quadrant Spearman correlation, and mean JSD.

32B和1.5B

- **OPD可以缓解跷跷板现象**：RL后的teacher和student**大部分token分布差异其实不大**，因为奖励很**稠密**，所以其实OPD修改的token**不会很多**。
- **RL优化冲突更剧烈**：RL因为奖励稀疏存在credit assignment的问题，可能会导致**很多token发生改变**，Mix-RL会导致token的分布变化更加剧烈，所以跷跷板现象更加严重

基本信息

研究背景

研究思路

研究结果

结论与限制

进一步讨论



6 Rethink RL and Reward model

Mix-RL 效果其实也不错，RL其实在MOPD范式中相当于MOPD的**上游任务**

关于多模态奖励模型的演进（RLHF）：

- **纯打分器**（直接输出绝对分数scalar reward）：CLIP, Pickscore, HPSv2

所有的prompt共享一个reward function，绝对分不准，缺少可解释性

- **Bradley-Terry model/Pairwise Reward Model**：HPSv3, VideoReward

从直接打绝对分到给偏好（输入prompt+图像对，输出A比B好）

- **VLM-as-a-Judge**：Prompt+Image -> Reasoning -> Preference

RL的缺点（从奖励模型视角）：

- **奖励信号稀疏** -> process reward model (PRM)
- **多奖励互相干扰（奖励跷跷板）** -> unified reward model (统一不同domain, 模态, 任务)
- **Reward很贵，采样效率比较低** -> 蒸馏reward model/节省中间步骤
- **容易牺牲通用能力/reward hacking** -> policy distribution shift, 探索到了RM没见过的情況

基本信息

研究背景

研究思路

研究结果

结论与限制

进一步讨论



6 Rethink RL and Reward model

可以做的一些方向：

- **从pairwise data如何得到pointwise reward**（pairwise的数据更容易获得，而且偏差更小，pointwise reward更有利于训练），BT-model缺少一个anchor
 - 现有方法比较粗暴，而且**不是真正的纯pairwise**，
 - 比如pairwise和pointwise混合训练（UnifiedReward）
 - 用专家VLM替代人类打分（PaTaRM）
- **Rubric-based reward**
 - 在vlm reasoning层面，模型自动设计评价维度（auto-rubric as reward）
- **diffusion-native reward**
 - 用diffusion模型/表征作为reward model（DiT-reward）
 - **太强的启发性**
- **reward model的蒸馏**：Z-reward（造相团队）：学打分分布的期望，老师reasoning，学生不reasoning，直接学老师最后得到的分数的分布
- **多维度奖励模型设计/多奖励融合**：scalar reward很难刻画多维奖励，但是有利于训练
- **Agent增强的Reward Model**：把memory和skill等等融入reward model中

policy model能做的VLM/LLM-based reward model上都能再做一次



北京大学
PEKING UNIVERSITY

汇报完毕， 敬请老师同学批评指正！

汇报人：彭鑫霖

汇报日期：2026/08/26