



北京大学
PEKING UNIVERSITY

Beyond Reactive VLA: Closing the Action-World Loop

超越被动式 VLA：闭合“动作-世界”循环

How Robots Use Action Consequences to Improve Future Decisions
机器人如何利用动作后果改善未来决策

汇报人：高瑀阳

汇报日期：2026/09/09

目录

CONTENTS

1 问题与范围

2 a.经验演化

3 b.因果交互

4 c.后果预测


5 小结

6 持续进化

1 问题与范围

回顾：Vision-Language-Action (VLA)

□ VLA: 观测 O_t + 语言指示 $l \rightarrow$ 动作序列 $[a_1, a_2, \dots, a_T]$



问题与范围

a. 经验演化

b. 因果交互

c. 后果预测

小结

持续进化

1 问题与范围

从动作生成到世界反馈

1 VLA 的核心映射

基于当前观测和语言指令，VLA输出动作。

$$\square \quad O_t + l \xrightarrow{VLA} a_t$$

VLA 回答的是：What should I do now?

2 但动作输出并不是终点

对真实机器人而言,动作进入环境之后,真实世界会产生新的状态变化与观测反馈。

$$\square \quad O_t \xrightarrow{a_t} O_{t+1}$$


3 动作后果 (Action Consequence)

这个由动作引起的状态变化，就是机器人从交互中获得的新证据。

- ✓ 任务结果：动作是否成功？
- ⚙ 物理响应：世界发生了什么变化？
- 💡 学习信号：这次交互告诉了机器人什么？

Every action generates new evidence about the world.

动作不是决策的终点，而是下一轮认知的起点。



问题与范围

a. 经验演化

b. 因果交互

c. 后果预测

小结

持续进化

1 问题与范围

“动作后果”能做什么？

How Can Robots Use “Action Consequences” ?

问题与范围

a. 经验演化

b. 因果交互

c. 后果预测

小 结

持续进化



Abstract

LabEvolver

$Trajectory \rightarrow Experience$

What did I learn?

从完整任务中总结经验



Observe

Zeva

$(S_t, a_t, S_{t+1}) \rightarrow \text{Action Effect}$

What did happened?

从单步交互中观察动作效果



Predict

LeWorldModel

$(s_t, a_t) \rightarrow \hat{s}_{t+1}$

What would happen?

在行动前预测动作后果

After a Task
LabEvolver

After an Action
Zeva

Before an Action
LeWorldModel

动作后果的三种利用方式

1 问题与范围

VLA vs. Memory vs. World Model

Reactive, Retrospective, Predictive

问题与范围

a. 经验演化


b. 因果交互

c. 后果预测

小结

持续进化


被动动作



What Should I do?

直接从观测与指令预测动作


主动总结



What did happened?
What can I learn from it?

从已发生的交互中总结经验
Labevolver + Zeva

主动预测



What would happen
if I do this?


在行动前预测动作后果
LeWorldModel

Memory 与 World Model 或许是机器人利用“动作后果”的两种方式。

1 问题与范围

本报告范围

Scope of This Talk



本报告关注：机器人如何利用与真实世界交互产生的后果，改善未来决策。

问题与范围

a. 经验演化

b. 因果交互

c. 后果预测

小结

持续进化

LabEvolver: Training-Free Experience Evolution for Safe and Grounded Wet-Lab Agents

arXiv: 2026.08.31



Training-Free Experience Evolution for Safe and Grounded Wet-Lab Agents

Jingya Wang^{2*} Yuyang Gao^{3*} Liuzhenghao Lv³ Yonghong Tian^{1,2,3†} Yuyang Liu^{1,2†}

* Equal contribution · † Corresponding authors



北京大学
PEKING UNIVERSITY

¹ School of AI for Science, Peking University

² School of Electronic and Computer Engineering, Peking University

³ School of Computer Science, Peking University

问题与范围

a. 经验演化

b. 因果交互

c. 后果预测

小 结

持续进化

Paper: <https://arxiv.org/abs/2607.27690>

Page: <https://andygao6186.github.io/LabEvolver/>

2.a 经验演化

LabEvolver: Training-Free Experience Evolution for Safe and Grounded Wet-Lab Agents

核心问题：机器人完成一次现实实验之后，如何利用交互经验，在不更新模型参数的情况下，使得执行持续变聪明？

问题与范围

a. 经验演化

b. 因果交互

c. 后果预测

小 结

持续进化

现有机器人系统更多体现的是“存量智能”

能力主要来自预训练模型、人工流程或已有数据
能在单次任务中纠错，但经验很难跨任务保留
想进一步提升能力，往往仍需重新收集数据并训练

真正缺少的是“增量智能”

能否在不更新模型参数的情况下，
将一次次现实交互沉淀为经验，
持续提升后续的技能、策略与安全性？

The image shows the LabEvolver experimental setup, which includes a Robotic Arm, pH-EC Sensor, Depth Camera, Liquid Dispensing Rack, 250ml Beaker, 50ml Test Tube, Stirring Rod, Electronic Balance, Liquid Dispensing Pump, Two-Finger Gripper, To PC, and Stock Solution. The task is to prepare a solution with pH 5.0 ± 0.2 .

Performance comparison:

Act	ReAct	LabEvolver
No state-grounded feedback	Reactive feedback correction	Experience-guided closed-loop execution
Totally Failed	Succeeded after 8 additions	Succeeded after only 2 additions!


Additional actions shown: Grab Tube, Add Liquid, Pour Liquid, Stir Liquid, Measure.

From static intelligence to incremental intelligence

从“存量智能”走向“增量智能”

2.a 经验演化

方法：内环确保安全执行 × 外环实现跨轮进化



内环负责当前实验的稳定执行，通过状态追踪、参数化动作与安全门控，使智能体能够驱动机械臂完成长时间、闭环的现实操作；
外环负责跨实验进化，将完成的实验轨迹提炼为技能、策略和安全经验，并在后续任务中检索和复用。

问题与范围

a. 经验演化

b. 因果交互

c. 后果预测


小结

持续进化

2.a 经验演化

方法：内环确保安全执行 × 外环实现跨轮进化

基于状态追踪的感知、执行与安全门控



执行 ∞ 安全门控图




1. Observe & Perceive
Initialize state




2. Move & Grab
Pick up tube 3





3. Move & Add
Get 45ml water




4. Pour
Pour 30g water



5. Move & Grab
Safe Gate Warning




6. Move & Place
Place tube 3




7. Move & Grab
Pick up stirring bar



8. Stir
Stir the liquid



9. Move & Place
Place stirring bar



10. Move & Grab
Pick up PH sensor



11. Measure
Get solution quality



n. Closed-loop Execution

问题与范围

a. 经验演化

b. 因果交互

c. 后果预测

小结

持续进化


2.a 经验演化

实验：ALFWorld @ 连续 134 个任务

我们应该回溯多少条记忆？

回溯记忆数量与 成功率 & 步数 的关系

- 少量历史经验即可显著提升决策效率：
相比 ReAct，各检索设置均取得更高的 Success@20。
- 随着检索规模增大，性能先提升后下降：
K=48 时 Success@20 达到最高的 94.03%。
- 更多记忆并不一定带来更好决策：
过多弱相关经验会引入检索干扰，因此后续实验采用 K=48。



不同记忆回溯规模下的成功率与步数表

Limit	Success@20 ↑	Step@20 ↓	Success@50 ↑	Step@50 ↓	Mean Recalled	Max Recalled	Stored
3	87.31%	11.239	99.25%	12.754	2.925	3	163
6	85.82%	11.030	98.50%	12.672	5.828	6	169
12	88.81%	10.963	98.50%	11.806	11.485	12	151
24	90.30%	10.754	100.00%	11.791	18.701	24	155
48	94.03%	10.246	99.25%	11.082	21.776	48	149
96	91.04%	10.478	99.25%	11.336	25.097	96	165
192	91.04%	10.179	98.50%	11.141	22.963	105	155

Table 10: Full retrieval-scale ablation on ALFWorld. Success@20 and Success@50 denote success rates under 20- and 50-action budgets. Step@20 and Step@50 denote average episode steps under the same budgets.

问题与范围

a.经验演化

b.因果交互

c.后果预测

小 结

持 续 进 化

2.a 经验演化


实验：ALFWorld @ 连续 134 个任务 (经验回溯 max=6 条)

- 经验增益跨模型成立：
Claude/GPT-5/DeepSeek/Qwen
均有稳定提升
- 弱模型受益更显著：
基础规划能力越弱，历史经验带来的补偿越明显
- 核心提升在于早期决策效率：
20-step 预算下优势更突出，能更快找到有效操作路径。
- 不同任务的经验收益存在差异：
搜索型任务更依赖探索效率，流程型任务更受益于顺序与前置经验。

不同基座模型下的跨模型泛化性能对比表

Backbone	Method	Success@20 ↑	Step@20 ↓	Success@50 ↑	Step@50 ↓
Claude-Sonnet-4.6	Act	80.6%	12.433	97.8%	14.254
Claude-Sonnet-4.6	ReAct	76.9%	12.910	96.3%	16.022
Claude-Sonnet-4.6	LabEvolver	84.3%	11.851	97.0%	13.895
GPT-5	Act	70.2%	13.955	95.5%	17.896
GPT-5	ReAct	76.9%	13.000	96.3%	15.970
GPT-5	LabEvolver	81.3%	11.448	100.0%	12.985
DeepSeek-V4-Pro	Act	72.4%	12.142	93.3%	16.420
DeepSeek-V4-Pro	ReAct	79.1%	13.052	98.5%	15.780
DeepSeek-V4-Pro	LabEvolver	85.8%	11.030	98.5%	12.672
Qwen3.5-35B-A3B	Act	65.7%	12.455	67.9%	22.300
Qwen3.5-35B-A3B	ReAct	65.7%	15.410	99.3%	18.365
Qwen3.5-35B-A3B	LabEvolver	73.9%	11.746	79.1%	18.626
Qwen3.5-35B-A3B	Cross-model experience	64.9%	15.328	94.0%	20.040

Table 9: Full ALFWorld results across backbone models. Success@20 and Success@50 denote task success rates under 20- and 50- action budgets, respectively. Step@20 and Step@50 denote average episode steps under the same budgets.



问题与范围

a.经验演化

b.因果交互

c.后果预测

小结

持续进化

2.a 经验演化

实验：ALFWorld @ 连续 500 个任务 (经验回溯 max=48 条)

(a) 500 任务中的持续成功率

经验持续积累带来稳定收益。

500 个任务后，LabEvolver 累计成功率达到 **91.4%**。

(b) 不同 Backbone 下的经验增益

经验增益跨模型成立。

Claude、GPT-5、DeepSeek、Qwen 上均取得最高 **Success@20**。

(c) 500 任务中的记忆库增长

经验演化有效抑制记忆膨胀。

500 个任务后，MemP 记忆量达 **1177**，而LabEvolver 保持 **300** 以内。

问题与范围

a.经验演化


b.因果交互

c.后果预测


小 结

持续进化


LabEvolver 在 ALFWorld 上的持续学习、跨模型泛化与记忆增长图



(a)



(b)



(c)

2.a 经验演化

实验：ALFWorld @ 连续 500 个任务 (经验回溯 max=48 条)

1. 记忆增长由“线性累积”转向“逐渐收敛”。
2. 记忆压缩并未牺牲执行效率。
3. 有效经验存在一个较稳定的工作区间。
4. 软遗忘不仅控制规模，也提升记忆质量。

问题与范围

a. 经验演化


b. 因果交互

c. 后果预测


小结

持续进化

连续任务流中的记忆增长与执行效率



不同记忆规模下的决策性能



2.a 经验演化

实验：真机倾倒 | “技能经验”的自进化与迁移

1. 物理反馈可以转化为控制经验：

40 次自探索后，20 g 水倾倒**平均误差**降至 **0.083 g**。

2. 自进化参数优于人工调参：

相比人工调参最好方法，**误差降低 37.5%，耗时降低 45.1%**。

3. 技能经验可以跨条件迁移：

Water、Sucrose、Olive oil 与不同目标质量下均保持较低误差。


4. 迁移的不是固定参数，而是参数选择经验：

不同液体与目标质量对应不同的 K_p 与 pre-stop。


20 g 水倾倒的控制
器性能对比

Method	MAE (g) ↓	SD (g) ↓	Time (s) ↓
Fixed PD	0.500	0.100	21.035
Adaptive pre-stop PD	0.133	0.153	20.360
CLAIRify	0.867	0.379	61.930
LabEvolver (Ours)	0.083	0.117	11.179

Table 1: Controller comparison for 20 g water pouring.



跨液体与目标质量的倾倒误差与参数



(a)

(b)

问题与范围

a.经验演化

b.因果交互

c.后果预测

小 结

持续进化

2.a 经验演化

实验：真机倾倒 | “技能经验”的自进化与迁移

问题与范围

a. 经验演化

b. 因果交互

c. 后果预测

小 结

持 续 进 化

跨液体与目标质量的技能自适应完整结果

Material	Target (g)	k_p	k_d	Pre-stop (g)	Search Trials	Validations	MAE (g) ↓	Time (s) ↓
Water	10	1.3	0.5	0.80	12	4	0.050	18.284
Water	20	1.1	0.5	2.50	40	6	0.083	11.179
Water	30	1.0	0.5	2.50	3	4	0.125	9.513
Water [†]	40	1.0	0.5	2.55	13	4	0.075	9.623
Sucrose solution	10	1.3	0.5	0.75	7	4	0.075	18.566
Sucrose solution	20	1.0	0.5	1.80	6	3	0.133	13.235
Sucrose solution	30	0.9	0.5	2.40	8	3	0.100	10.474
Sucrose solution [†]	40	1.0	0.5	3.30	19	3	0.067	9.349
Olive oil	10	1.1	0.5	0.80	3	3	0.033	21.537
Olive oil	20	1.0	0.5	1.70	5	3	0.033	13.831
Olive oil	30	1.0	0.5	2.30	3	3	0.067	10.166
Olive oil [†]	40	1.3	0.5	0.50	22	3	0.133	13.145

Table 11: Full skill adaptation results across liquids and target masses. Conditions marked with [†] are close to the tube-capacity boundary.

2.a 经验演化

实验：真机 pH 调节 | “策略经验”的自进化与迁移

1. 同目标复用显著减少探索：

pH=5 第二次实验由 3 次加液降至 2 次，且不再触发安全门。

2. 历史经验提升策略选择效率：

已有轨迹为试剂方向与粗粒度剂量提供先验。


3. 策略经验能够跨目标迁移：

pH=6 与 pH=9 均可复用已有经验完成新的目标调节。

4. 迁移不是固定配方的直接复现：

每次加液后仍根据最新 pH 测量进行闭环重规划。

pH 调节中的同目标进化与跨目标迁移



问题与范围

a. 经验演化

b. 因果交互

c. 后果预测

小结

持续进化

实验：真机 pH-EC 调节 | “策略经验” 的复杂任务迁移

1. 完整经验显著提升执行效率与安全性。

相比无经验，耗时降低 55.0%，安全拦截降至 0。

2. 单目标经验可以组合迁移到多目标任务。

仅加入 pouring 与单目标 pH 经验，就已经能改善 pH-EC 联合调节。

3. 跨目标迁移不是轨迹复现，而是策略先验复用。

不同 pH-EC 目标呈现不同执行路径，也会出现“先偏离、再纠正”的非单调轨迹。

问题与范围

a. 经验演化


b. 因果交互

c. 后果预测


小结

持续进化

pH-EC 耦合调节的逐步执行轨迹



不同经验水平下的 pH-EC 调节效率与跨目标表现



2.b 因果交互

Zeva: In-Context Causal Learning for Generalizable Embodied Manipulation

arXiv: 2026.08.31

Zeva: In-Context Causal Learning for Generalizable Embodied Manipulation

A robot foundation model that keeps improving after deployment — no gradient updates, no weight changes, only interaction memory.

Fu Chen^{*}, Xin Ding^{*,†}, Bingjia Huang, Xiangyu Li, Mingju Wang, Jiawei He, Kun Li, Wei Sun, Yunxin Liu, Hao Wu^{†,‡}, Ting Cao^{†,§}

^{*} Co-first authors · [†] Corresponding authors · [§] Project lead · [‡] Work done during a visit to AIR, Tsinghua

Institute for AI Industry Research (AIR), Tsinghua University; Z-Trans AI



清华大学 智能产业研究院
Institute for AI Industry Research, Tsinghua University

LabEvolver 总结一次任务的经验
Zeva 研究每次动作带来的后果

Paper: <https://arxiv.org/abs/2608.30880>

Page: <https://air-embodied-brain.github.io/Zeva/>

问题与范围

a. 经验演化

b. 因果交互

c. 后果预测

小 结

持续进化

2.b 因果交互






Zeva: In-Context Causal Learning for Generalizable Embodied Manipulation

核心问题：机器人能否从自身交互中学习“动作 → 状态变化”，并在不更新策略参数的情况下改善后续动作？

Zeva: In-Context Causal Interaction Learning

Zeva 的核心思想：

- 预训练无法覆盖所有真实物理条件。
- 交互本身就是新的物理证据。
- Zeva 将这种证据作为 Context，而不是更新权重。



— GT — Zeva w/ Human Demonstration
— Zeva w/o Human Demonstration

Zeva 不是“记住我看见过什么”，而是“记住我做了什么，以及世界因此发生了什么”。

问题与范围

a. 经验演化

b. 因果交互

c. 后果预测

小结

持续进化

2.b 因果交互

方法: Action-Effect $\rightarrow$ Causal Memory $\rightarrow$ Causal Prompt

- Policy 保持冻结

不更新参数, 保留原有感知与动作能力。

- 交互编码为因果信号


$$(s_t, a_t, \Delta s_t) \rightarrow (p_t, e_t)$$

- 双时间尺度记忆

BIT 记当前尝试, PIM 记跨尝试经验。

- 因果经验注入动作生成

检索相关记忆, 组成 Causal Prompt, 引导下一步动作。



问题与范围

a. 经验演化

b. 因果交互

c. 后果预测

小结

持续进化

2.b 因果交互

实验：仿真与真机上的整体性能对比

- 仿真任务上整体性能最佳。
- 真机原子操作优势最稳定。
- 短序列任务中仍保持领先。
- 长程任务中更能体现过程推进能力。

RoboCasa365-Atomic5 仿真任务性能

TABLE II
RESULTS ON THE ROBOCASA365-ATOMIC5 (ATOMIC5) BENCHMARK [35]. WE REPORT TASK SUCCESS RATE (SR) OVER 50 RANDOMIZED EPISODES AND THE MACRO-AVERAGE. BEST RESULTS ARE IN **BOLD**.

Method	TurnOn ElectricKettle	CloseToaster OvenDoor	TurnOn Microwave	CoffeeSetup Mug	OpenStand MixerHead	Avg.
LingBot-VA [8]	63	60	70	35	48	55.2
Xiaomi-Robotics-1 [36]	17	16	82	6	35	31.2
τ_0 -WM [37]	15	32	63	12	23	29.0
Fast-WAM [34]	88	66	60	54	94	72.4
Cosmos3-Nano [18]	76	74	76	6	92	64.8
Zeva	78	86	84	44	92	76.8

TABLE I

REAL-WORLD EVALUATION ON CHEMLAB-EVO. THE LEFT BLOCK REPORTS SUCCESS RATE (SR, %) OVER 20 RANDOMIZED EPISODES, WITH MACRO-AVERAGES FOR EACH DIFFICULTY LEVEL. THE RIGHT BLOCK REPORTS THE AVERAGE PERCENTAGE OF ORDERED TASK STAGES COMPLETED ON THE TWO LONG-HORIZON TASKS. BEST PROCESS SCORES ARE IN **BOLD**.

Method	Success Rate (SR, %)										Process Score (%)		
	Level 1 (Atomic)				Level 2 (Short-sequence)			Level 3 (Complex)			Long-horizon		
	Pick Up Test Tube	Place Beaker	Pour Water	Avg. (%)	Titration	Prepare Salt Solution	Avg. (%)	Balance Weighing	Extraction	Avg.	Balance Weighing	Extraction	Avg.
LingBot-VA [8]	80	70	65	71.7	55	75	65.0	5	0	2.5	28.75	40.00	34.38
Fast-WAM [34]	85	70	75	76.7	45	55	50.0	0	0	0.0	22.50	58.57	40.54
$\pi_{0.5}$ [14]	95	60	65	73.3	60	50	55.0	0	0	0.0	33.75	31.43	32.59
Cosmos3-Nano [18]	80	70	60	70.0	45	60	52.5	0	0	0.0	38.75	50.71	44.73
Zeva	100	70	80	83.3	70	70	70.0	5	10	7.5	47.50	67.14	57.32

ChemLab-Evo 真机任务性能

问题与范围

a. 经验演化

b. 因果交互

c. 后果预测

小结

持续进化

2.b 因果交互

实验：交互经验能否带来持续自进化？

- 交互经验能够持续提升任务完成率：

RoboCasa365 累计成功率由 26% → 73%。

- 真机任务呈现一致的自进化趋势：

Pick Up 65→100%，Place 25→70%，Pour 30→80%。

- 性能增长来自 **Context**，而不是参数更新：

模型始终冻结，变化的是跨 attempt 累积的 causal interaction evidence。

- 实验设置：

Fixed Episode：每次失败后恢复相同初始状态

Online Evolution：每一步交互后立即更新 BIT / PIM

Memory Protocol：BIT 每次 attempt 清空，PIM 跨 attempt 保留；新 episode 重新清空

RoboCasa365 上的部署后能力增长




Fig. 3. Post-deployment capability scaling on RoboCasa365. Each of the five tasks contributes 20 randomized episodes, yielding 100 equally weighted task-seed pairs. Evolve 1–4 denote selected evolution milestones.

ChemLab-Evo 真机任务中的持续自进化




Fig. 4. Post-deployment capability scaling on three ChemLab-Evo tasks using separately selected fixed episodes. Evolve 1–4 denote selected evolution milestones.

问题与范围

a. 经验演化

b. 因果交互

c. 后果预测

小结

持续进化

2.b 因果交互

消融：BIT 与 PIM 分别贡献了什么？

- 1. BIT 与 PIM 缺一不可：

完整 Zeva 在 5 个任务上均取得最高成功率。

- BIT：连续动态 / 阶段依赖越强，作用越大：

Pour Water、Titration：均贡献 +30 pt。

- PIM：跨原子任务组合的复杂任务，作用越大：

Prepare Salt Solution 是唯一 PIM 增益高于 BIT 的任务：
+20 vs. +15 pt。

- 实验设置：

ChemLab-Evo 5 个真机任务，每种配置 20 个随机 episodes。

分别移除 BIT、PIM，比较任务成功率。

TABLE III

REAL-WORLD ABLATION OF BIT AND PIM ON FIVE CHEMLAB-EVO TASKS. CHECKMARKS INDICATE ENABLED COMPONENTS. ENTRIES REPORT TASK-LEVEL SR (%) OVER 20 RANDOMIZED EPISODES; BEST RESULTS ARE IN **BOLD**.

Method		Pick Up	Place	Pour	Titr.	Salt
		Test Tube	Beaker	Water		Solution
BIT	PIM					
✓	✓	100	70	80	70	70
	✓	80	50	50	40	55
✓		85	60	70	60	50
		65	40	45	25	35

问题与范围

a. 经验演化

b. 因果交互

c. 后果预测

小 结

持续进化

2.b 因果交互

实验：一次示教能否“热启动”因果记忆？

实验设置：

One-shot Human Warm-up

每个 fixed episode 开始前，先给 1 次人类示教；示教轨迹经 CTE 编码后写入 PIM，Policy 参数仍保持冻结。

- 一次示教即可初始化有效的因果经验。
- Warm-up 主要提升早期自进化效率。
- 示教不是直接复制动作轨迹。

一次人类示教对称量任务的记忆热启动




Fig. 5. One-shot human warm-up for Balance Weighing. Rows show (a) the human-guided demonstration used to initialize PIM, (b) Zeva after one-shot memory warm-up, and (c) the baseline without memory warm-up. Frames in each row form a timeline ordered from left to right. The 3D plot compares the corresponding end-effector trajectories; stars and triangles denote grasp and placement events, respectively.

—○— Self-Evolve —□— Human demonstration + Self-Evolve




Fig. 6. One-shot human-demonstration warm-up on three atomic ChemLab-Evo tasks. Each evaluated fixed episode is paired with one task-matched human demonstration before autonomous self-evolution. Solid lines show self-evolution without warm-up, while dashed lines show human warm-up followed by self-evolution. Each panel uses its own y-axis range to keep within-task changes legible.

Human Warm-up 对自进化过程的增益

2.b 因果交互

实验：因果交互经验能否跨任务迁移？

1. 跨任务因果经验可以直接复用。

Pick Up 仅由 100% → 95%，Pour Water 仍保持 80%。

2. 有效迁移来自“相似后果”，而不是随机历史。

随机替换后仅剩 55% / 45%，性能显著下降。

3. CTE 更关注动作造成的物理变化。

不同对象、视角和任务中，Pouring / Closing / Lifting 仍能检索到功能等价的 interaction。

跨任务 Causal Signal 替换实验




Fig. 7. Quantitative replacement with cross-task causal interaction signals on ChemLab-Evo. Zeva uses the retrieved task-local interaction signal, Cross-task substitutes its nearest counterpart from another task, and Random uses a randomly selected interaction signal from the same cross-task pool. The frozen policy and all other inputs remain unchanged.

CTE Latent Space 中的跨任务因果检索

Pouring

Closing

Lifting






Fig. 8. Cross-task retrieval in the latent space of CTE causal interaction signals. Each block shows a left-to-right state transition. Blue outlines denote queries, and teal outlines denote their two nearest cross-task matches. Rows group transitions by physical effect despite changes in objects, viewpoints, and instructions.

问题与范围

a. 经验演化

b. 因果交互

c. 后果预测

小 结

持续进化

LeWorldModel: Stable End-to-End Joint-Embedding Predictive Architecture from Pixels

arXiv: 2026.03.13

Citations: 166 (as of 2026.09.09)

LeWorldModel:

Stable End-to-End JEPA from Pixels

Lucas Maes^{*1}, Quentin Le Lidec^{*2}, Damien Scieur^{1,3}, Yann LeCun², Randall Balestriero⁴,

¹Mila & Université de Montréal, ²New York University ³Samsung SAIL ⁴Brown University

^{*}Equal Contribution



Z e v a 做完以后理解后果
LeWorldModel 做之前先预测后果

Paper: <https://arxiv.org/pdf/2603.19312>

Page: <https://le-wm.github.io/>

问题与范围

a. 经验演化

b. 因果交互

c. 后果预测

小 结

持续进化

2.c 后果预测

方法：从像素中学习 Action-Conditioned Latent Dynamics

1. 从像素编码当前世界。

$$O_t \xrightarrow{\text{Encoder}} z_t$$

2. 给定动作，预测下一时刻的 latent。

$$(z_t, a_t) \xrightarrow{\text{Predictor}} \hat{z}_{t+1}$$



3. 用真实下一状态监督预测。

$$L_{pred} = \|\hat{z}_{t+1} - z_{t+1}\|_2^2$$

4. SIGReg 防止 latent collapse。

约束表示保持分散、接近各向同性高斯，而不是所有状态都编码成同一个向量。

LeWorldModel 的端到端 JEPA 训练框架



问题与范围

a. 经验演化

b. 因果交互

c. 后果预测

小结

持续进化

2.c 后果预测

方法：在 Latent Space 里 “先想后做”

1. 编码当前状态与目标。

$$o_1 \rightarrow z_1, \quad o_g \rightarrow z_g$$

2. 在模型里 “试走” 一串动作。

$$(z_1, a_1, \dots, a_H) \rightarrow \hat{z}_H$$

3. 看预测结果离目标有多远。

$$C = \|\hat{z}_H - z_g\|$$

4. 不断修改动作，直到找到更好的方案。

Solver 根据 cost 更新 $a_1, \dots, a_H$ ，形成 “预测 → 优化 → 再预测” 的循环。

LeWorldModel 的 Latent Planning 流程




Figure 4: Latent Planning with LeWorldModel .

问题与范围

a. 经验演化

b. 因果交互

c. 后果预测

小结

持续进化

2.c 后果预测

实验：实验任务

问题与范围

a. 经验演化


b. 因果交互

c. 后果预测

小 结

持续进化

1. Two-Room: 2D Navigation
2. Reacher: 2D Control
3. Push-T: 2D Manipulation
4. OGBench-Cube: 3D Robotic Manipulation



2.c 后果预测

实验：规划效率与控制性能评估

1. Latent 表征显著降低规划开销。

LeWM 的完整规划仅需 0.98 s, DINO-WM 约 47 s, 接近 48× 加速。

2. 相同 FLOPs 下, 轻量表示换来更充分的搜索。

Push-T: 90% vs. 13%; OGBench-Cube: 74% vs. 48%。

3. 复杂控制任务上保持较强性能。

Reacher、Push-T 上均优于 PLDM 与 DINO-WM。

4. OGBench-Cube 上仍略逊于 DINO-WM。

复杂 3D 视觉环境中, 端到端 Encoder 缺少预训练视觉先验。

5. Two-Room 暴露了 SIGReg 的局限。

环境内在维度过低, 与 SIGReg 的高维 Gaussian 约束存在失配。

固定计算预算下的规划效率与性能




Figure 3: Planning time and performance under fixed compute.

不同控制环境下的规划成功率




Figure 6: Planning performance across environments.

问题与范围

a. 经验演化

b. 因果交互

c. 后果预测

小结

持续进化

2.c 后果预测

实验：LeWM是否真正理解物理世界？

实验设置：

对同一条轨迹构造三种情况：

- Unperturbed：正常轨迹
- Color Change：只改变物体颜色
- Teleportation：把物体瞬移到随机位置

然后用预测未来与真实未来之间的误差作为 surprise。

1. 正常轨迹的 Surprise 保持较低。

说明模型能够预测正常的状态演化。


2. 对纯视觉变化反应较弱。

颜色突变会带来误差，但总体增幅较小且不显著。

3. 对物理连续性破坏

反应显著。

Teleportation 在
TwoRoom / PushT
/ Cube 上都产生明显
surprise spike,
且提升显著。



Violation-of-Expectation: 物理违背检测实验






Figure 8: Violation-of-expectation evaluation across three environments.

问题与范围

a. 经验演化

b. 因果交互

c. 后果预测

小结

持续进化

3 小结

小结：机器人如何利用 Action Consequence?

LabEvolver	Zeva	LeWorldModel
任务级经验沉淀	动作级因果提取	模型级未来推演
$Trajectory \rightarrow Experience$	$(S_t, a_t, S_{t+1}) \rightarrow \text{Causal Memory}$	$(S_t, a_t) \rightarrow \hat{S}_{t+1}$
What did I learn?	What did happened?	What would happen?
把一次完整任务压缩成可复用经验	从真实交互中提取 action-effect	在执行前预测未来状态

Action Consequence

三篇工作实际上对应机器人利用“动作后果”的三个时间视角：**过去、现在与未来。**

问题与范围

a. 经验演化

b. 因果交互


c. 后果预测

小 结

持续进化

4 持续进化

持续进化：Closing the Action–World Loop



LabEvolver:

会积累经验，但没有显式
dynamics model;

Zeva:

会在线更新 causal context，但
主要是 episode 内 adaptation;

LeWM:

会预测 dynamics，但 world
model 主要离线训练。

目前真正缺少的：真实交互产生的新证据，能否持续修正机器人的世界模型？

真正的持续进化，不只是记住过去或预测未来，而是让每一次真实后果都持续修正机器人对世界的认识。

问题与范围

a. 经验演化

b. 因果交互

c. 后果预测

小 结

持 续 进 化



北京大学
PEKING UNIVERSITY

汇报完毕， 敬请老师同学批评指正！

汇报人：高瑀阳

汇报日期：2026/09/09